JOURNAL CLUB · 2026.11.05 13:00–14:00 JST

AI は人間の行動を どこまで再現できるか?

人間模型・行動介入・社会的協働・事業エージェントを「測定」から読む

人間データ | シミュレーション | 介入 | 評価

成田 大祐 ｜ 人間行動・協働・事業エージェントの方法と評価

今日の問いは、三つ

分野の整理 → 代表論文 → 評価の落とし穴 → 今後の研究

01

何をシミュレーションしている?

個人の回答／選択／相互作用／長期の変化

02

何をもって「正しい」とする?

自然さ、分布、個人差、介入効果は別

03

現実の意思決定へ使える?

比較対象・不確実性・移植・害を見る

二つの「エージェント」を混ぜない

人を演じる模型と、人のために行動する AI は別の役割

人間・世界モデル

「どう反応しそうか?」

プロフィール＋履歴＋状況 → 反応の分布

方策・実行エージェント

「何をするべきか?」

目標＋予測＋制約 → 発言・変更・待機

[R12] [R13]

人間行動シミュレーションの共通構造

人口を作るだけでは、行動モデルは完成しない

01 実人間の情報 › 02 個人・集団の表現 › 03 反応モデル › 04 相互作用・時間 › 05 集計・比較

参照データと照合し、適用範囲を更新する

観測データで検証し、模型に戻す。すべての方式が全層を持つわけではない。

[R01] [R02] [R07]

人間行動シミュレーションは、LLMより前からある

一つの直線的な発展ではなく、複数の研究伝統が合流している

1996

ABM・Sugarscape

少数の行動規則から
集団・社会の構造を生成

→

2023

Generative Agents

LLM＋記憶・計画・
振り返りで仮想社会を生成

→

2024–25

個人模型・実験回答学習

面接・調査と大規模な
実人間回答で反応を推定

→

2026

効果予測・評価の厳密化

未見研究・因果効果・
一般化と限界を検証

問い：それらしい社会を作ることと、現実の人や介入効果を予測することは同じか？

Epstein & Axtell 1996 / Park et al. UIST 2023 / Kolluri et al. EMNLP 2025

神経科学の言葉に置き換えると、何をモデル化するのか

内部状態・観測・行動・方策・結果を区別すると、分野全体が見えてくる

潜在状態 s

意欲・信念・疲労・記憶

直接は見えず、行動や報告から推定

観測 o

発話・選択・調査回答

モデルが再現しようとする外部データ

方策 $\pi(a|s)$

何を選ぶか・いつ介入するか

行動や介入を選択する規則

評価・介入 do(a)

予測と因果効果は異なる

モデルが現実の結果と一致するか検証

ただし、脳回路の機序を説明することと、社会・消費・対人行動を予測することは別の検証課題。

Conceptual analogy: state-space models / decision models / causal inference

方法の違いは「何を学び、何を固定するか」

排他的な五択ではなく、組み合わせる設計要素

系統	主な表現・入力	強み／主な検証課題
統計・選択モデル	数値特徴、選択肢、効用	単純な基準／未知の文脈への移植
エージェントベース	状態・規則・ネットワーク	相互作用／規則の根拠
LLM ＋ペルソナ	属性・指示・会話	言語の柔軟性／型にはめた反応
インタビューで個人を表現	本人の自己報告・記憶	個人固有の文脈／未知の結果
行動データで追加学習	実験・調査・行動の記録	共有表現／リークと一般化

[R01] [R02] [R03] [R09]

起点① Generative Agents： 記憶から行動へ

Park et al., UIST 2023 ｜ 25 体のエージェントの仮想社会

01 観察 › 02 記憶ストリーム › 03 関連記憶を検索 › 04 振り返り・計画 › 05 行動

参照データと照合し、適用範囲を更新する

示したのは、構成要素が「もっともらしい振る舞い」に寄与すること。

[R01]

起点② 実際の人の情報で個人模型を作る

Park et al., arXiv v3 （2026-06-28） | 1,052 人の米国成人

01 本人の情報 › 02 面接／調査／両方 › 03 LLM へ文脈として入力 › 04 隠した項目を予測 › 05 本人の回答と比較

参照データと照合し、適用範囲を更新する

新しい人の予測とは限らない。「本人の未提示の結果」を何で測ったかが重要。

[R02]

起点③ Socrates： 反応を追加学習する

Kolluri et al., EMNLP 2025 | SocSci210

01 210 の公開実験 › 02 条件＋属性＋回答 › 03 事前学習済み LLM › 04 SFT ／ DPO 等 › 05 未見の研究で評価

参照データと照合し、適用範囲を更新する

約 290 万回答・ 400,491 参加者。「行数」と「人数」と「研究数」は別。

[R03]

起点④ 条件間の差を予測する

Ashokkumar et al., Nature 2026 ｜社会科学実験の効果予測

データ

70 実験／ 469 効果

事前登録された米国調査実験。119,330 参加者。

方法

刺激を条件別に提示

模擬回答の条件間差から、介入効果を予測。

重要な限界

相関は高いが過大推定

強い相関だけで、効果の大きさが正しいとは言えない。

[R04]

企業の違いを、入出力と検証から読む

ここは企業公式説明。原理の比較であり、独立した性能ランキングではない。

組織	公表している主なアプローチ	読むべき未確認点
Aaru	人口を構成し、非 LLM の中核行動モデルで応答	対象範囲・時間制約・分布と実行動
Simile	実人間データで行動モデルと信頼度を学ぶ	信頼度の検証・データ更新・移植
Rothko / Artificial Societies	事前学習モデルを変更し、意思決定を出力	非公開の構造・学習データ・独立再現

[R07] [R08] [R09]

Aaru： 2,993 問で「集団分布」を検証する

対象集団 → 人工人口 → 回答比率 → 人間調査との距離

調整前の平均 TVD

7.62 pt

2,993 問を等重みで平均

標本誤差調整後

5.98 pt

調整前と定義が異なる

信頼度上位約 51%

4.54 pt

1,525 問だけで評価

核心：誤差の小ささと「答えられる範囲」を同時に示す

Aaru の公開結果は一問ごとの回答分布が中心。同じ人の複数回答や未見介入の効果まで保証しない。

Simile： 人の「行動」と「理由」を同時に使う

購買ログだけ、インタビューだけ、では答えられない「なぜ変わったか」

WHAT ｜実行動
購入、閲覧、取引など

WHY ｜自己報告
インタビュー、調査

CHANGE ｜実験
条件変更後の反応

Human Behavior Foundation Model

内部評価
10,000+
人間の参照があるシナリオ

信頼度評価
約 8,600 問
5 分割交差検証の報告

Simile research https://www.simile.com/blog/evals /blog/what-if-machine /blog/confidence?v=2

Rothko ／ AS： 人間らしさは「平均」だけではない

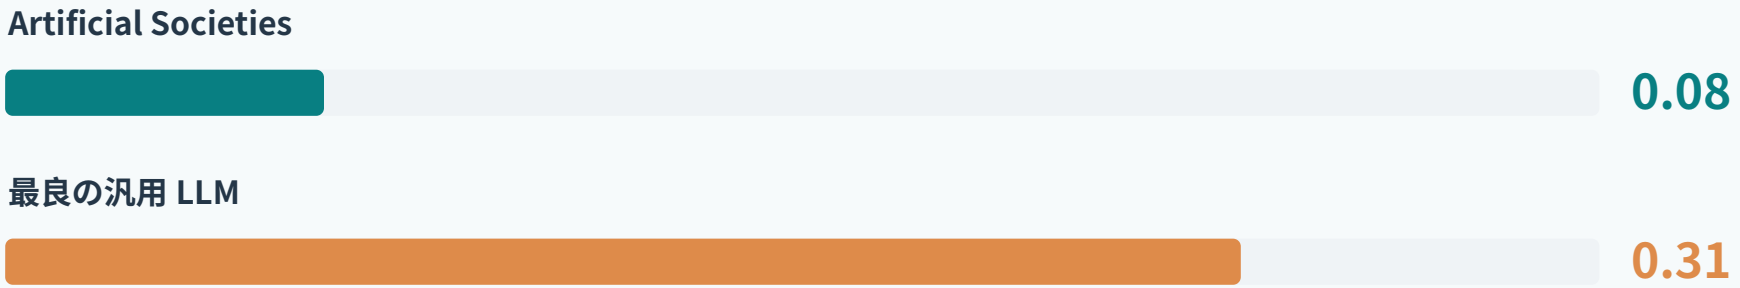
11 の検査で、回答・項目間の関係・条件変化を別々に採点

① 回答過程
再回答、順序、言い換え、情報提示

② 測定構造
同じ特性を測る質問同士の関係

③ 外的な一致
集団・個人差・実験効果

企業による 7 ソースの分布 TVD 比較（低いほどよい）



同一の公開共通ベンチマークでの他社全比較ではない

AS Benchmark arxiv.org/abs/2609.30030 / Vendor comparison societies.ai/as-benchmark

Listen Twins： 本人の言葉を、本人の「未見回答」で測る

Twins の個人内評価と、 StyleFits の実売上を混同しない

本人と面接	回答の一部を保留	Twin に予測させる	本人の答えと比較
1 : 1	holdout	predict	score

別の実行実験： StyleFits （ Listen Labs の自己報告）

2,000	100	$1,293	$2,000
インタビュー	製品案	収入	広告費

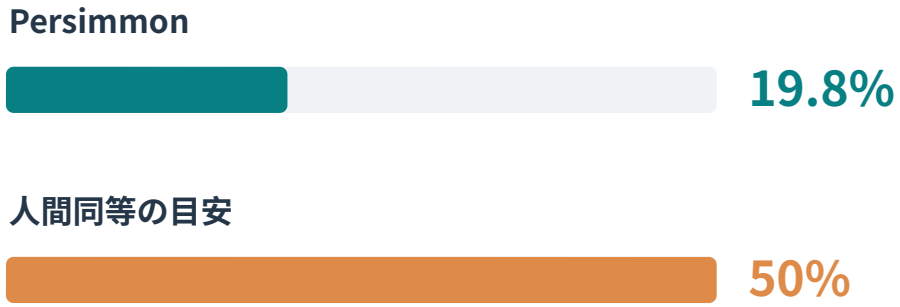
広告費だけを引いて − $707 。本人 Twin の精度試験とは別の証拠。

Listen Twins: https://listenlabs.com/twins / Listen closed-loop: https://listenlabs.com/blog/closed-loop

Persimmon： 人の会話を模し、長い文脈に耐える

「人間と見分けにくい」は、購買行動の正答率ではない

人間らしい会話の識別試験



どう学習する?

① 既存の大規模モデル
② 実際の人々の会話
③ 自己生成に対する強化学習
④ 80 ターンなど長期整合性の検査

Turing Test の成功率 ≠ 個人の未来行動の正答率

Persimmon research: https://persimmon.humansand.ai/blog/persimmon.html

Ampersand： 模擬ユーザーから協働の「方策」を学ぶ

Persimmon がユーザー役、 Ampersand が発言・質問・待機を選ぶ

Persimmon
模擬ユーザーの次の反応

→

長い会話・社会環境
相手の目的、反発、変化

→

Ampersand
返す・尋ねる・待つ・行動

長期協働・内部シミュレーションの得点（高いほどよい）

Ampersand	vs	基盤 GLM 5.3
12.94		9.89

内部シミュレーション ≠ 実際の人への介入の因果効果

Ampersand model card: https://ampersand.humansand.ai/blog/model-card.html

独立研究が突きつける、まだ解けていない問題

「人間らしく見える」模型でも、個人の未知行動を外す

独立したツイン評価
19 研究
164 の事前登録結果

個人回答との平均相関
≈0.20
独立研究の報告

SimBench
20 データ
最良 LLM 40.80/100

モデルへの入力が多い ≠ 未来の個人行動を正しく再現できる

五つの典型的な歪み：個人差の圧縮／ステレオタイプ／代表性／思想的偏り／過度の合理化

Critical study: pmc.ncbi.nlm.nih.gov/articles/PMC13537255 / SimBench: ICLR 2026

「人間らしい」から「役立つ」まで、証拠は飛べない

一つの点数で、すべての主張を代用しない

自然さ	会話や物語としてもっともらしい
分布・個人	割合、ばらつき、同じ人の回答を再現する
構造・効果	回答の関係、条件を変えた差を再現する
意思決定	同じ予算で、よりよい選択をする
現実の結果	実際の利益・生活・負担・害を測る

[R01] [R02] [R04] [R05]

ベンチマークは、データセットだけではない

問いと採点条件を固定する「試験の設計書」

課題

何を予測・選択する?

参照データ

何を正解の根拠にする?

分割

何を未知として残す?

入力・実行

情報、ツール、回数、予算

比較対象

単純模型と強い既存法

指標・集計

単位、重み、欠測、失敗

不確実性

人・研究単位での変動

再現条件

版、コード、出典、費用

[R05] [R16]

一問ずつは完全一致。しかし、組み合わせは逆

教育用：質問 A と B 、各 100 人。 1= はい／ 0= いいえ。

参照集団

	B=0	B=1
A=0	50 人	0 人
A=1	0 人	50 人

人工集団

	B=0	B=1
A=0	0 人	50 人
A=1	50 人	0 人

各質問の周辺 TVD は 0 。同時分布の TVD は 1 。割合だけでは「誰が何を答えたか」が消える。

[D01] [R05]

正しい方向でも、効果量を外す

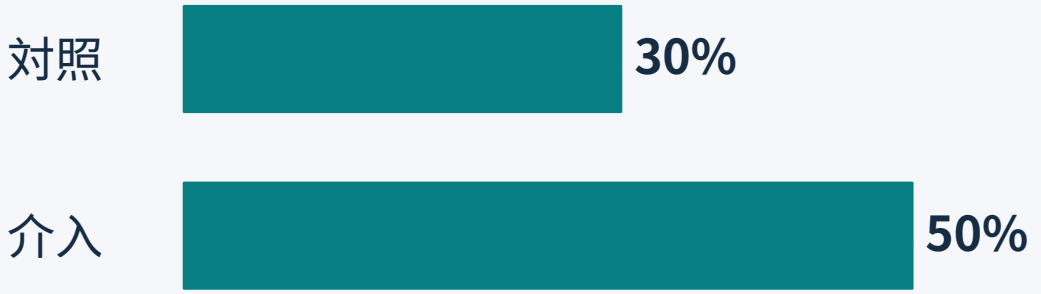
架空例：対照から介入後への結果の変化

参照



差： +8 ポイント

模型



差： +20 ポイント

参照： +8 ポイント。模型： +20 ポイント。効果の絶対誤差は 12 ポイント。

[D01] [R04]

AS Benchmark： 11 の検査で用途を確かめる

Chidichimo et al., 2026 preprint ｜ 20 人間データソース、 9 つの汎用 LLM

回答過程（ IV ）

IV-1 同じ質問の繰り返し

IV-2 関連項目の論理

IV-3 言い換え

IV-4 順番・形式の変更

測定構造（ CV ）

CV-1 項目間の共分散

CV-2 外部基準との関係

CV-3 異なる特性の区別

人口・実験（ EV ）

EV-1 回答分布

EV-2 個人・部分集団

EV-3 実験効果

EV-4 因子・測定構造

※ IV は本論文の回答忠実性の診断分類。因果識別そのものを保証する用語ではない。

[R05] [R06]

何を未知として残したのか?

同じテスト点でも、一般化の主張は変わる

人物

未見の人を予測

時間

既知の人の未来を予測

研究

新しい実験を予測

領域

別の製品や文化へ移植

入力時点

未来情報・答えの混入を排除

生成器

別の模擬ユーザーでも試す

採点器

自己採点の癖から分離

欠測・失敗

無効出力と未回答も報告

[R16] [R17] [R05]

共通ベンチマークは、すでに存在する

ただし 1 枚のランキングで、分布・個人・介入・長期行動を同時に採点できない

SimBench

20 datasets

集団の回答分布

Artificial Societies

11 validity tests

個人差・関係・効果

Human Behavior Bench

1,199 tasks

US 調査・非公開 960 課題

SSDataBench

5 statistical patterns

相関・系列・統計的現実性

Social Simulation Arena

Locked before outcome

未来の観測で採点

SocSci210 / Socrates

210 experiments

未知研究・条件の予測

[B01] [B02] [B03] [B04] [B05] [B06]

公平な比較のための「試験の契約」

同じ問題・人間の正解・入力情報・費用・採点・無効回答を揃える

01

固定した問題

誰のどの回答?

02

未見の参照

人・研究・時期を保留

03

モデル予測

p(A), p(B), p(C)

04

共通採点

TVD ・ Brier ・有効率

05

限界と再現

費用・モデル版・失敗

例：人間 (50,30,20)% vs AI (40,40,20)% → TVD = 0.10

[B01] [B03] [B05]

行動の「予測」と「変える効果」は違う

交絡があると観察データからの結論は、真の介入効果と逆になる

通知を受けた人 vs 受けなかった人

+26 pt

見かけ上「効果がありそう」

同じ対象へ通知する・しないを比較

−10 pt

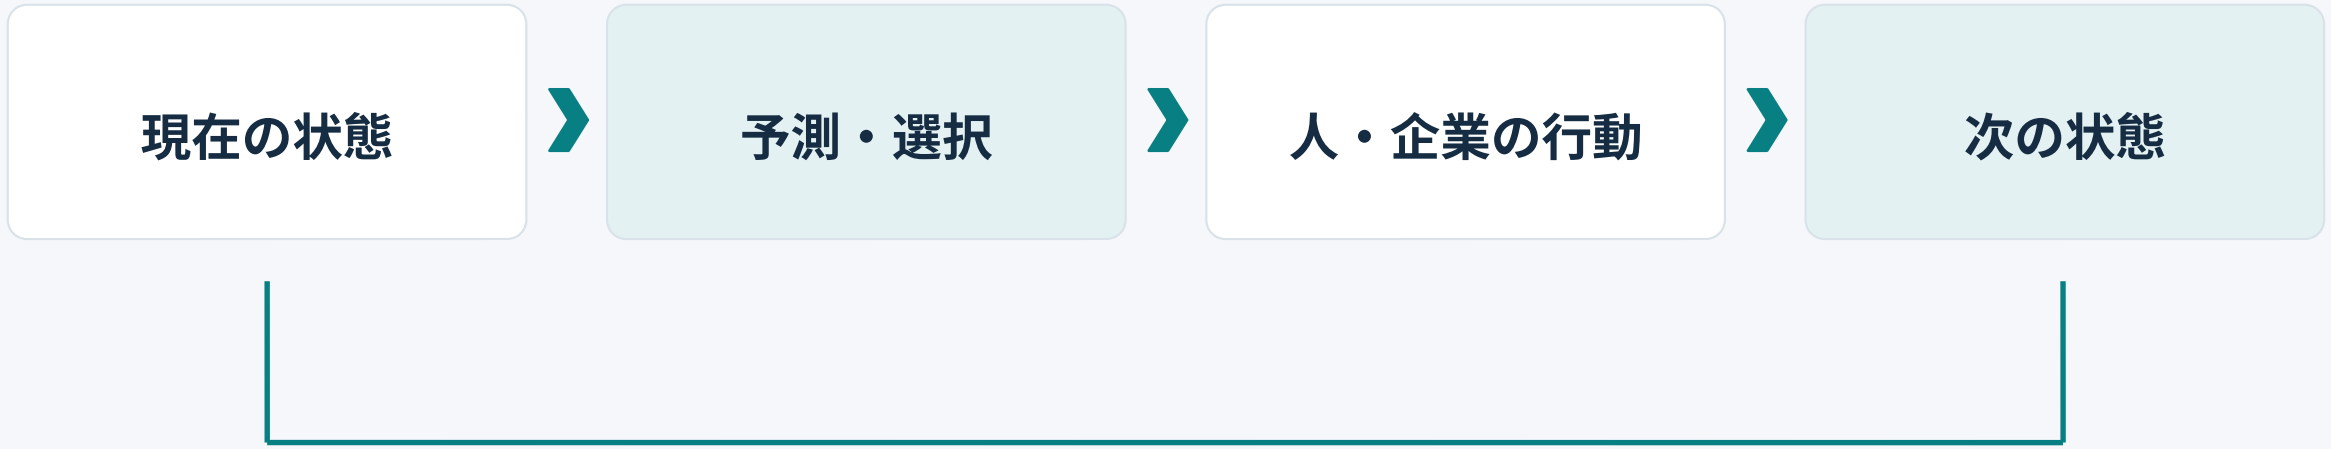
本当に通知すると悪化（架空例）

原因：もともとの関心 U が「通知」と「完了」の両方に影響していた

[C01] [C02] 教材用の完全架空数値

予測が使われると、予測対象も変わる

反応の反応まで、動的な模型の研究対象にする



行動によって、次のデータ分布そのものが変わる

「人の反応は変わる」を模型に入れる。ただし、完全予知とは主張しない。

[R20]

研究を読むときの、三つの持ち帰り

ここまでが分野と評価の整理

01

問いが違えば、証拠も違う

自然さ、個人の回答、分布、効果、実世界の便益。

02

点数より、条件を読む

誰を残し、何を入力し、何と比べ、何を数えたか。

03

一般化を実際に試す

同じ模型を、別の人・時期・研究・領域で評価する。

[R02] [R03] [R05]

最後に： Manager の研究構想

汎用的な反応モデルと、許可された実行・独立評価を一つに接続する

01 観察 › 02 反応を予測 › 03 候補を比較 › 04 許可して実行 › 05 独立に評価

参照データと照合し、適用範囲を更新する

構想と現在の証拠を分ける。モデル・行動・費用・結果を追跡する。

[E01]

Manager 1.0 で、何を最初に示すか

既存研究を再利用し、改善の原因を切り分ける

比較段階	固定するもの	示したいこと
模型単体	情報・分割・採点	反応予測の改善
同じ実行枠	候補・ツール・予算	模型の違いの効果
限定した現実	対照・対象・期間	増分価値と害
移植	未知の人・時期・領域	一般化の範囲

重みを出したことと、現実の利益や苦しみの軽減を示したことは別。

[R03] [R06] [E01]

議論：どの証拠があれば、この模型を使うか?

結論を売り込むのではなく、検証可能な問いを残す

模型の妥当性

どの診断が必要?

用途と参照データから決める

判断の価値

何と比較する?

同条件・同予算の強い基準

人への利益

何を守る?

本人の意思・害・長期の結果

Discussion / ここから約 15 分