JOURNAL CLUB · 2026.11.05 13:00–14:00 JST

AI は人間の行動を どこまで再現できるか?

人間模型・行動介入・社会的協働・事業エージェントを「測定」から読む

人間データ | シミュレーション | 介入 | 評価

成田 大祐 ｜ 人間行動・協働・事業エージェントの方法と評価

今日の問いは、三つ

分野の整理 → 代表論文 → 評価の落とし穴 → 今後の研究

01

何をシミュレーションしている?

個人の回答／選択／相互作用／長期の変化

02

何をもって「正しい」とする?

自然さ、分布、個人差、介入効果は別

03

現実の意思決定へ使える?

比較対象・不確実性・移植・害を見る

二つの「エージェント」を混ぜない

人を演じる模型と、人のために行動する AI は別の役割

人間・世界モデル

「どう反応しそうか？」

プロフィール＋履歴＋状況 → 反応の分布

方策・実行エージェント

「何をするべきか？」

目標＋予測＋制約 → 発言・変更・待機

[R12] [R13]

人間行動シミュレーションの共通構造

人口を作るだけでは、行動モデルは完成しない

01 実人間の情報 › 02 個人・集団の表現 › 03 反応モデル › 04 相互作用・時間 › 05 集計・比較

参照データと照合し、適用範囲を更新する

観測データで検証し、模型に戻す。すべての方式が全層を持つわけではない。

[R01] [R02] [R07]

人間行動シミュレーションは、LLMより前からある

一つの直線的な発展ではなく、複数の研究伝統が合流している

1996

ABM・Sugarscape

少数の行動規則から
集団・社会の構造を生成

→

2023

Generative Agents

LLM＋記憶・計画・
振り返りで仮想社会を生成

→

2024–25

個人模型・実験回答学習

面接・調査と大規模な
実人間回答で反応を推定

→

2026

効果予測・評価の厳密化

未見研究・因果効果・
一般化と限界を検証

問い：それらしい社会を作ることと、現実の人や介入効果を予測することは同じか？

Epstein & Axtell 1996 / Park et al. UIST 2023 / Kolluri et al. EMNLP 2025

人間行動AIを『状態・観測・選択・結果』で理解する

脳科学でも、ビジネスでも、生活でも使える4つの基本的な見方

潜在状態 s

意欲・信念・疲労・記憶

直接は見えず、行動や報告から推定

観測 o

発話・選択・調査回答

モデルが再現しようとする外部データ

方策 π(a|s)

何を選ぶか・いつ介入するか

行動や介入を選択する規則

評価・介入 do(a)

予測と因果効果は異なる

モデルが現実の結果と一致するか検証

行動予測と、介入による因果効果は異なる。証拠がないときは何もしないことも選択肢。

Conceptual analogy: state-space models / decision models / causal inference

方法の違いは「何を学び、何を固定するか」

排他的な五択ではなく、組み合わせる設計要素

系統	主な表現・入力	強み／主な検証課題
統計・選択モデル	数値特徴、選択肢、効用	単純な基準／未知の文脈への移植
エージェントベース	状態・規則・ネットワーク	相互作用／規則の根拠
LLM ＋ペルソナ	属性・指示・会話	言語の柔軟性／型にはめた反応
インタビューで個人を表現	本人の自己報告・記憶	個人固有の文脈／未知の結果
行動データで追加学習	実験・調査・行動の記録	共有表現／リークと一般化

[R01] [R02] [R03] [R09]

起点① Generative Agents： 記憶から行動へ

Park et al., UIST 2023 ｜ 25 体のエージェントの仮想社会

01 観察 › 02 記憶ストリーム › 03 関連記憶を検索 › 04 振り返り・計画 › 05 行動

参照データと照合し、適用範囲を更新する

示したのは、構成要素が「もっともらしい振る舞い」に寄与すること。

[R01]

起点② 実際の人の情報で個人模型を作る

Park et al., arXiv v3 （2026-06-28） | 1,052 人の米国成人

01 本人の情報 › 02 面接／調査／両方 › 03 LLM へ文脈として入力 › 04 隠した項目を予測 › 05 本人の回答と比較

参照データと照合し、適用範囲を更新する

新しい人の予測とは限らない。「本人の未提示の結果」を何で測ったかが重要。

[R02]

起点③ Socrates： 反応を追加学習する

Kolluri et al., EMNLP 2025 | SocSci210

01
210 の公開実験

02
条件＋属性＋回答

03
事前学習済み LLM

04
SFT ／ DPO 等

05
未見の研究で評価

参照データと照合し、適用範囲を更新する

約 290 万回答・ 400,491 参加者。「行数」と「人数」と「研究数」は別。

[R03]

起点④ 条件間の差を予測する

Ashokkumar et al., Nature 2026 ｜社会科学実験の効果予測

データ

70 実験／ 469 効果

事前登録された米国調査実験。119,330 参加者。

方法

刺激を条件別に提示

模擬回答の条件間差から、介入効果を予測。

重要な限界

相関は高いが過大推定

強い相関だけで、効果の大きさが正しいとは言えない。

企業の違いを、入出力と検証から読む

ここは企業公式説明。原理の比較であり、独立した性能ランキングではない。

組織	公表している主なアプローチ	読むべき未確認点
Aaru	人口を構成し、非 LLM の中核行動モデルで応答	対象範囲・時間制約・分布と実行動
Simile	実人間データで行動モデルと信頼度を学ぶ	信頼度の検証・データ更新・移植
Rothko / Artificial Societies	事前学習モデルを変更し、意思決定を出力	非公開の構造・学習データ・独立再現

[R07] [R08] [R09]

Aaru： 2,993 問で「集団分布」を検証する

対象集団 → 人工人口 → 回答比率 → 人間調査との距離

調整前の平均 TVD

7.62 pt

2,993 問を等重みで平均

標本誤差調整後

5.98 pt

調整前と定義が異なる

信頼度上位約 51%

4.54 pt

1,525 問だけで評価

核心：誤差の小ささと「答えられる範囲」を同時に示す

Aaru の公開結果は一問ごとの回答分布が中心。同じ人の複数回答や未見介入の効果まで保証しない。

Simile： 人の「行動」と「理由」を同時に使う

購買ログだけ、インタビューだけ、では答えられない「なぜ変わったか」

WHAT ｜実行動
購入、閲覧、取引など

WHY ｜自己報告
インタビュー、調査

CHANGE ｜実験
条件変更後の反応

Human Behavior Foundation Model

内部評価
10,000+
人間の参照があるシナリオ

信頼度評価
約 8,600 問
5 分割交差検証の報告

Simile research https://www.simile.com/blog/evals /blog/what-if-machine /blog/confidence?v=2

Rothko ／ AS： 人間らしさは「平均」だけではない

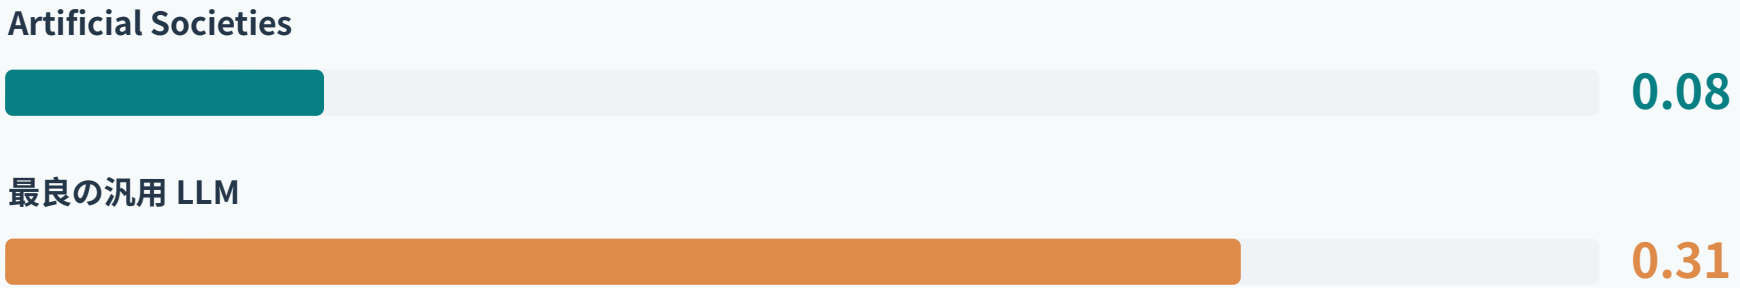
11 の検査で、回答・項目間の関係・条件変化を別々に採点

① 回答過程
再回答、順序、言い換え、情報提示

② 測定構造
同じ特性を測る質問同士の関係

③ 外的な一致
集団・個人差・実験効果

企業による 7 ソースの分布 TVD 比較（低いほどよい）



同一の公開共通ベンチマークでの他社全比較ではない

AS Benchmark arxiv.org/abs/2609.30030 / Vendor comparison societies.ai/as-benchmark

Listen Twins： 本人の言葉を、本人の「未見回答」で測る

Twins の個人内評価と、 StyleFits の実売上を混同しない

本人と面接	回答の一部を保留	Twin に予測させる	本人の答えと比較
1 : 1	holdout	predict	score

別の実行実験： StyleFits （ Listen Labs の自己報告）

2,000	100	$1,293	$2,000
インタビュー	製品案	収入	広告費

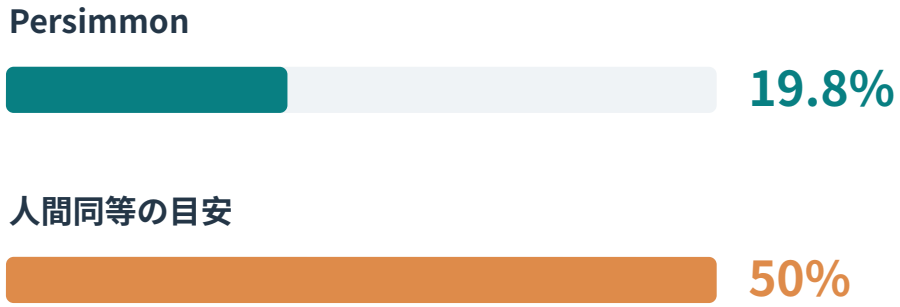
広告費だけを引いて − $707 。本人 Twin の精度試験とは別の証拠。

Listen Twins: https://listenlabs.com/twins / Listen closed-loop: https://listenlabs.com/blog/closed-loop

Persimmon： 人の会話を模し、長い文脈に耐える

「人間と見分けにくい」は、購買行動の正答率ではない

人間らしい会話の識別試験



どう学習する?

① 既存の大規模モデル
② 実際の人々の会話
③ 自己生成に対する強化学習
④ 80 ターンなど長期整合性の検査

Turing Test の成功率 ≠ 個人の未来行動の正答率

Persimmon research: https://persimmon.humansand.ai/blog/persimmon.html

Ampersand： 模擬ユーザーから協働の「方策」を学ぶ

Persimmon がユーザー役、 Ampersand が発言・質問・待機を選ぶ

Persimmon
模擬ユーザーの次の反応

→

長い会話・社会環境
相手の目的、反発、変化

→

Ampersand
返す・尋ねる・待つ・行動

長期協働・内部シミュレーションの得点（高いほどよい）

12.94
Ampersand

vs

9.89
基盤 GLM 5.3

内部シミュレーション ≠ 実際の人への介入の因果効果

Ampersand model card: https://ampersand.humansand.ai/blog/model-card.html

独立研究が突きつける、まだ解けていない問題

「人間らしく見える」模型でも、個人の未知行動を外す

独立したツイン評価
19 研究
164 の事前登録結果

個人回答との平均相関
≈0.20
独立研究の報告

SimBench
20 データ
最良 LLM 40.80/100

モデルへの入力が多い ≠ 未来の個人行動を正しく再現できる

五つの典型的な歪み：個人差の圧縮／ステレオタイプ／代表性／思想的偏り／過度の合理化

Critical study: pmc.ncbi.nlm.nih.gov/articles/PMC13537255 / SimBench: ICLR 2026

「人間らしい」から「役立つ」まで、証拠は飛べない

一つの点数で、すべての主張を代用しない

自然さ	会話や物語としてもっともらしい
分布・個人	割合、ばらつき、同じ人の回答を再現する
構造・効果	回答の関係、条件を変えた差を再現する
意思決定	同じ予算で、よりよい選択をする
現実の結果	実際の利益・生活・負担・害を測る

[R01] [R02] [R04] [R05]

ベンチマークは、データセットだけではない

問いと採点条件を固定する「試験の設計書」

課題

何を予測・選択する?

参照データ

何を正解の根拠にする?

分割

何を未知として残す?

入力・実行

情報、ツール、回数、予算

比較対象

単純模型と強い既存法

指標・集計

単位、重み、欠測、失敗

不確実性

人・研究単位での変動

再現条件

版、コード、出典、費用

[R05] [R16]

一問ずつは完全一致。しかし、組み合わせは逆

教育用：質問 A と B 、各 100 人。 1= はい／ 0= いいえ。

参照集団

	B=0	B=1
A=0	50 人	0 人
A=1	0 人	50 人

人工集団

	B=0	B=1
A=0	0 人	50 人
A=1	50 人	0 人

各質問の周辺 TVD は 0 。同時分布の TVD は 1 。割合だけでは「誰が何を答えたか」が消える。

[D01] [R05]

正しい方向でも、効果量を外す

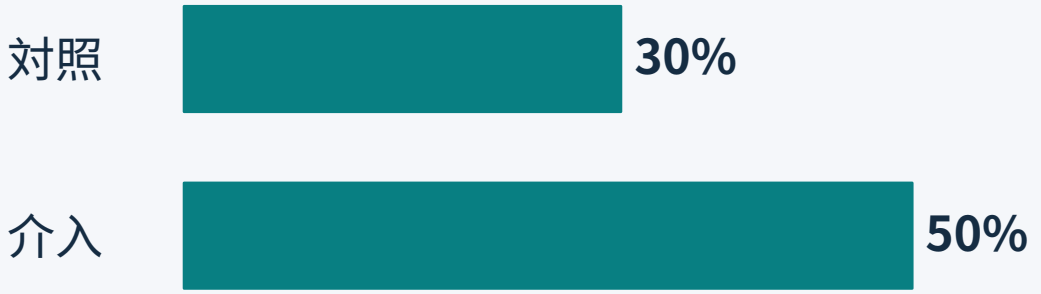
架空例：対照から介入後への結果の変化

参照



差： +8 ポイント

模型



差： +20 ポイント

参照： +8 ポイント。模型： +20 ポイント。効果の絶対誤差は 12 ポイント。

[D01] [R04]

AS Benchmark： 11 の検査で用途を確かめる

Chidichimo et al., 2026 preprint ｜ 20 人間データソース、 9 つの汎用 LLM

回答過程（ IV ）

IV-1 同じ質問の繰り返し

IV-2 関連項目の論理

IV-3 言い換え

IV-4 順番・形式の変更

測定構造（ CV ）

CV-1 項目間の共分散

CV-2 外部基準との関係

CV-3 異なる特性の区別

人口・実験（ EV ）

EV-1 回答分布

EV-2 個人・部分集団

EV-3 実験効果

EV-4 因子・測定構造

※ IV は本論文の回答忠実性の診断分類。因果識別そのものを保証する用語ではない。

[R05] [R06]

何を未知として残したのか?

同じテスト点でも、一般化の主張は変わる

人物

未見の人を予測

時間

既知の人の未来を予測

研究

新しい実験を予測

領域

別の製品や文化へ移植

入力時点

未来情報・答えの混入を排除

生成器

別の模擬ユーザーでも試す

採点器

自己採点の癖から分離

欠測・失敗

無効出力と未回答も報告

[R16] [R17] [R05]

共通ベンチマークは、すでに存在する

ただし1枚のランキングで、分布・個人・介入・長期行動を同時に採点できない

SimBench

20 datasets

集団の回答分布

Artificial Societies

11 validity tests

個人差・関係・効果

Human Behavior Bench

1,199 tasks

US調査・非公開960課題

BehaviorBench

20 scenarios

個別・分布／Be.FM 1.5

Social Simulation Arena

Locked before outcome

未来の観測で採点

SocSci210 / Socrates

210 experiments

未知研究・条件の予測

[B01] [B02] [B03] [B07] [B05] [B06]

公平な比較のための「試験の契約」

同じ問題・人間の正解・入力情報・費用・採点・無効回答を揃える

01

固定した問題

誰のどの回答?

02

未見の参照

人・研究・時期を保留

03

モデル予測

p(A), p(B), p(C)

04

共通採点

TVD ・ Brier ・有効率

05

限界と再現

費用・モデル版・失敗

例：人間 (50,30,20)% vs AI (40,40,20)% → TVD = 0.10

[B01] [B03] [B05]

行動の「予測」と「変える効果」は違う

実際に観測された申込結果があっても、勧誘の因果効果は別の問題

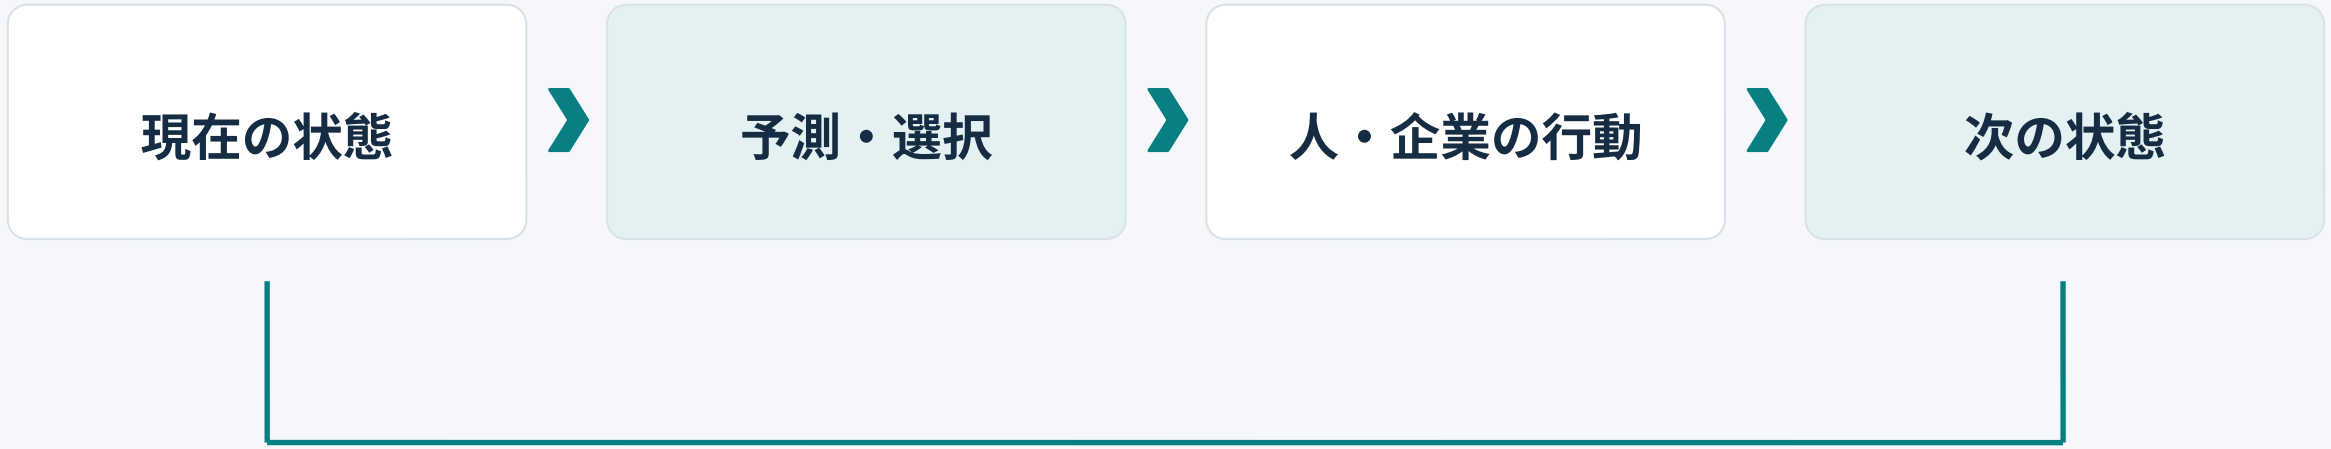
銀行の電話勧誘を受けた人の申込記録	電話しなかった対照群が存在しない
41,188件	不明
申込の有無を予測する実データ	勧誘の因果効果は求められない

介入の効果を知るにはRCT等の識別が必要。分類性能≠因果効果。

[C01] UCI Bank Marketing（実観測41,188件）

予測が使われると、予測対象も変わる

反応の反応まで、動的な模型の研究対象にする



行動によって、次のデータ分布そのものが変わる

「人の反応は変わる」を模型に入れる。ただし、完全予知とは主張しない。

[R20]

研究を読むときの、三つの持ち帰り

ここまでが分野と評価の整理

01

問いが違えば、証拠も違う

自然さ、個人の回答、分布、効果、実世界の便益。

02

点数より、条件を読む

誰を残し、何を入力し、何と比べ、何を数えたか。

03

一般化を実際に試す

同じ模型を、別の人・時期・研究・領域で評価する。

[R02] [R03] [R05]

Manager：What-if Machine × Executor

行動を『予測する』から、『介入・実行・検証する』へ

① Behavior

人と状況の状態
反応を予測

→

② What-if

候補施策の因果効果
不確実性を比較

→

③ Executor

同意・権限の範囲で
実際に行動

→

④ Evidence

結果・害・費用を
独立に測定

大きな可能性は研究仮説。どの意思決定が本当に改善したか、実験で反証可能にする。

実証するのは、製品・流通・人への便益

最初にManagerを直接売るのではなく、Managerが生んだ成果を示す

製品が求められる

実際の課題解決
継続率・返金率
貢献利益

必要な人へ届く

増分の顧客獲得
獲得費用・LTV
配信後の純利益

苦しみが軽減する

反すう/PTQ
マインドフルネス/FFMQ
生活機能・害・同意

フォロワー数・視聴回数・売上だけでは不十分。費用を差し引いた利益と本人の実測便益で判断する。

Managerはいつ動く？ 製品・モデル・人への効果の3本線

独自のモデルの重みを待たず、今あるAIと安全な実行基盤で成果を検証する

会社のEngine

最初はShadow
→ 1つの可逆な実務操作

モデルの重み

権利とHoldout評価
→ 実LoRA → Open weight

人への効果

本人の希望と同意
→ 行動・反すうの比較測定

公開の実人間53,518件で予測比較。本当の増分利益・心理改善は未証明。

『結果で語る』——まだ未検証のことも示す

実人間の購買・申込記録でモデルを比較。介入の効果は今後検証。

いま確認できていること

UCI実観測53,518件を検証
4種類のモデルを同条件比較
未見データの予測性能を測定

これから証明すること

実在研究の未見予測
製品・流通の増分成果
本人の心理・生活の改善

可能な範囲でコード／重みを公開し、第三者に検証してもらう。
問い：最初にどの実験で、この仮説を厳しく試すべきか？