JOURNAL CLUB · 2026.11.05 13:00–14:00 JST

AI は人間の行動を どこまで再現できるか?

人間模型・行動介入・社会的協働・事業エージェントを「測定」から読む

人間データ | シミュレーション | 介入 | 評価

成田 大祐 | 人間行動・協働・事業エージェントの方法と評価

今日の問いは、三つ

分野の整理 → 代表論文 → 評価の落とし穴 → 今後の研究

01

何をシミュレーションしている?

個人の回答／選択／相互作用／長期の変化

02

何をもって「正しい」とする?

自然さ、分布、個人差、介入効果は別

03

現実の意思決定へ使える?

比較対象・不確実性・移植・害を見る

二つの「エージェント」を混ぜない

人を演じる模型と、人のために行動する AI は別の役割

人間・世界モデル

「どう反応しそうか?」

プロフィール＋履歴＋状況 → 反応の分布

方策・実行エージェント

「何をするべきか?」

目標＋予測＋制約 → 発言・変更・待機

[R12] [R13]

人間行動シミュレーションの共通構造

人口を作るだけでは、行動モデルは完成しない

01 実人間の情報 › 02 個人・集団の表現 › 03 反応モデル › 04 相互作用・時間 › 05 集計・比較

参照データと照合し、適用範囲を更新する

観測データで検証し、模型に戻す。すべての方式が全層を持つわけではない。

[R01] [R02] [R07]

方法の違いは「何を学び、何を固定するか」

排他的な五択ではなく、組み合わせる設計要素

系統	主な表現・入力	強み／主な検証課題
統計・選択モデル	数値特徴、選択肢、効用	単純な基準／未知の文脈への移植
エージェントベース	状態・規則・ネットワーク	相互作用／規則の根拠
LLM ＋ペルソナ	属性・指示・会話	言語の柔軟性／型にはめた反応
インタビューで個人を表現	本人の自己報告・記憶	個人固有の文脈／未知の結果
行動データで追加学習	実験・調査・行動の記録	共有表現／リークと一般化

[R01] [R02] [R03] [R09]

「よいアシスタント」と「忠実な人間模型」は同じではない

もっともらしい説明 ≠ 実際の選択を生む原因

使える力

知識・言語・文脈を広く扱える

未知の質問を、自然言語で与えられる

ずれ得る目的

迎合や一貫性が、人の反応を歪める可能性

個人差や揺らぎを平均化する可能性

[R05] [R09]

起点① Generative Agents： 記憶から行動へ

Park et al., UIST 2023 ｜ 25 体のエージェントの仮想社会

01 観察 › 02 記憶ストリーム › 03 関連記憶を検索 › 04 振り返り・計画 › 05 行動

参照データと照合し、適用範囲を更新する

示したのは、構成要素が「もっともらしい振る舞い」に寄与すること。

[R01]

起点② 実際の人の情報で個人模型を作る

Park et al., arXiv v3 （2026-06-28） | 1,052 人の米国成人

01 本人の情報 › 02 面接／調査／両方 › 03 LLM へ文脈として入力 › 04 隠した項目を予測 › 05 本人の回答と比較

参照データと照合し、適用範囲を更新する

新しい人の予測とは限らない。「本人の未提示の結果」を何で測ったかが重要。

[R02]

「86%」は、生の正答率ではない

本人の 2 週間後の再回答一致率に対する正規化値｜ GSS の未提示項目



分母・正規化・対象項目・論文の版を読む。 1.00 はこの評価の本人再回答基準。

[R02]

起点③ Socrates： 反応を追加学習する

Kolluri et al., EMNLP 2025 | SocSci210

01
210 の公開実験

02
条件＋属性＋回答

03
事前学習済み LLM

04
SFT ／ DPO 等

05
未見の研究で評価

参照データと照合し、適用範囲を更新する

約 290 万回答・ 400,491 参加者。「行数」と「人数」と「研究数」は別。

[R03]

追加学習の効果は、指標ごとに読む

Socrates ・ PDF Table 2 ｜未見研究の正規化 1-Wasserstein 距離（低いほどよい）



0.205 → 0.151： 距離が約 26.3% 減少。正答率が 26.3 ポイント上がったのではない。

[R03]

起点④ 条件間の差を予測する

Ashokkumar et al., Nature 2026 ｜社会科学実験の効果予測

データ

70 実験／ 469 効果

事前登録された米国調査実験。119,330 参加者。

方法

刺激を条件別に提示

模擬回答の条件間差から、介入効果を予測。

重要な限界

相関は高いが過大推定

強い相関だけで、効果の大きさが正しいとは言えない。

[R04]

企業の違いを、入出力と検証から読む

ここは企業公式説明。原理の比較であり、独立した性能ランキングではない。

組織	公表している主なアプローチ	読むべき未確認点
Aaru	人口を構成し、非 LLM の中核行動モデルで応答	対象範囲・時間制約・分布と実行動
Simile	実人間データで行動モデルと信頼度を学ぶ	信頼度の検証・データ更新・移植
Rothko / Artificial Societies	事前学習モデルを変更し、意思決定を出力	非公開の構造・学習データ・独立再現

[R07] [R08] [R09]

Listen Labs： 速い模型と、現実のフィードバック

Twins と StyleFits の報告は、別の証拠として扱う

Listen Twins

実人間に対応する模型

インタビューを入力し、隠した回答と比較。出典・信頼度を提示。

StyleFits 実験

調査 → 開発 → 実ユーザー → 修正

約 2,000 インタビュー。売上 $1,293 、広告 $2,000 。人の介助あり。

[R10] [R11]

humans&：人間模型で支援モデルを訓練する

模擬ユーザーと方策を分ける、具体例

Persimmon

人間側の反応を生成

履歴・プロフィール・状況 → 会話の続きを生成

Ampersand

支援の行動を学ぶ

長期の模擬社会シナリオで RL 。発言する／待つ。

[R12] [R13]

Persimmon： 人間らしさを五つに分ける

評価名だけでなく、何を人間の参照にしているかを見る

試験	主に観察するもの	主張の限界
Multi-User Turing	本物／生成の会話群の識別	個人の未来正答率ではない
Profile Turing	プロフィールと会話の対応	内心の読取ではない
User-Sim Index	文体・質問・情報・誤りへの反応	パターン依存
Trickle Test	情報の段階的な開示	生成情報の真実性とは別
Long Context	長い会話の整合性	人への長期利益とは別

会話の自然さ・整合性・実行動の予測は、別の評価対象。

[R13] [R23]

Ampersand： 支援の結果を、長い時間で測る

訓練環境のユーザーモデルと採点者への依存を検査する

訓練

長い社会的やり取り

Persimmon の反応から学ぶ

行動

発言・ツール・待つ

多く動く＝よい支援ではない

外部検証

未知の相手と状況

模型・ grader への適合を点検

模型内の協働得点から、実人間の便益へは別の証拠が必要。

[R12]

「人間らしい」から「役立つ」まで、証拠は飛べない

一つの点数で、すべての主張を代用しない

自然さ	会話や物語としてもっともらしい
分布・個人	割合、ばらつき、同じ人の回答を再現する
構造・効果	回答の関係、条件を変えた差を再現する
意思決定	同じ予算で、よりよい選択をする
現実の結果	実際の利益・生活・負担・害を測る

[R01] [R02] [R04] [R05]

ベンチマークは、データセットだけではない

問いと採点条件を固定する「試験の設計書」

課題

何を予測・選択する?

参照データ

何を正解の根拠にする?

分割

何を未知として残す?

入力・実行

情報、ツール、回数、予算

比較対象

単純模型と強い既存法

指標・集計

単位、重み、欠測、失敗

不確実性

人・研究単位での変動

再現条件

版、コード、出典、費用

[R05] [R16]

一問ずつは完全一致。しかし、組み合わせは逆

教育用：質問 A と B 、各 100 人。 1= はい／ 0= いいえ。

参照集団

	B=0	B=1
A=0	50 人	0 人
A=1	0 人	50 人

人工集団

	B=0	B=1
A=0	0 人	50 人
A=1	50 人	0 人

各質問の周辺 TVD は 0 。同時分布の TVD は 1 。割合だけでは「誰が何を答えたか」が消える。

[D01] [R05]

正しい方向でも、効果量を外す

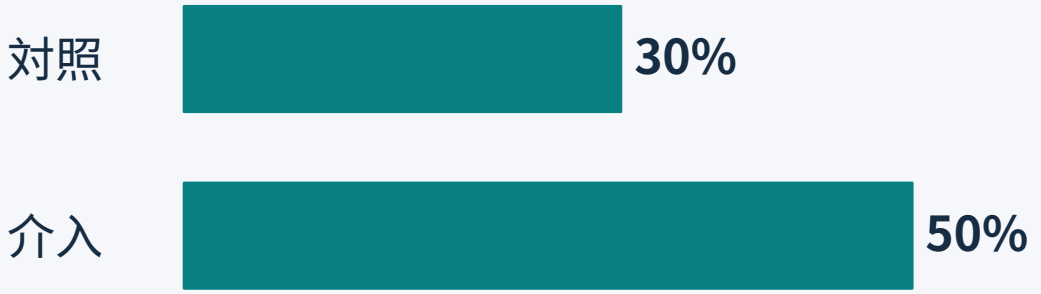
架空例：対照から介入後への結果の変化

参照



差： +8 ポイント

模型



差： +20 ポイント

参照： +8 ポイント。模型： +20 ポイント。効果の絶対誤差は 12 ポイント。

[D01] [R04]

AS Benchmark： 11 の検査で用途を確かめる

Chidichimo et al., 2026 preprint ｜ 20 人間データソース、 9 つの汎用 LLM

回答過程（ IV ）

IV-1 同じ質問の繰り返し

IV-2 関連項目の論理

IV-3 言い換え

IV-4 順番・形式の変更

測定構造（ CV ）

CV-1 項目間の共分散

CV-2 外部基準との関係

CV-3 異なる特性の区別

人口・実験（ EV ）

EV-1 回答分布

EV-2 個人・部分集団

EV-3 実験効果

EV-4 因子・測定構造

※ IV は本論文の回答忠実性の診断分類。因果識別そのものを保証する用語ではない。

[R05] [R06]

公開コードを、入出力の流れとして読む

データの意味は、提示・解析・欠測処理の実装にも宿る

01 課題・人物 › 02 提示・収集 › 03 解析・欠測 › 04 指標と比較 › 05 スコアカード

参照データと照合し、適用範囲を更新する

正常に終了したことと、人間を正しく予測したことは別。

[R06]

AS 再現：公開された計算経路を確認する

本日作成済みの Mac 実行ログ・ XML ・出力レシートを今回照合

検査	確認した記録	言える範囲
環境・全テスト	68 成功／ 7 スキップ	元個票が必要な 7 件は残る
スコアカード	7,128 セルの行内容一致	保存済み集計からの再構築
図	10 図 × PNG/PDF	PDF デバイスを移植
新規模型推論	0 回	模型の性能比較は未実施

既存実行の照合。今回、全推論を新しく実行したという報告ではない。

[R06] [E01]

「再現できる範囲」を正確に切り分ける

専有モデルへの認証と、公開コードの実行は別の問題

対象	確認した範囲	別に必要なもの
AS Benchmark	固定環境・全テスト起動・再集計	元調査データ／新規回答
Ampersand	公式 SDK 準備、API401	許可されたアカウントのキー
Persimmon	公開方法・評価・制限	利用承認と再現用の資料
内部ベンチ全体	公開説明を検討	シナリオ・ grader ・原出力

未知の部分を埋めたふりをしないことも、再現研究の成果。

[R19] [R06] [E01]

naïve： 二つのベンチマーク群

同じモデルで実行基盤を替えるか、同じ基盤でモデルを替えるか

モデル比較

同じ環境・違う模型

Clipping ／ Short Form

実行基盤比較

同じ模型・違う実行系

業務・コード・会社運営

共通の問い

何を完成と呼ぶか

成功・費用・失敗の単位

企業名やモデル名だけの順位表では、改善の原因は分からない。

[N00]

Clipping Bench： 模擬メディア事業の一か月

単発の投稿ではなく、権利・時間・疲労・遅れた入金を扱う

01 素材・案件 › 02 編集・選択 › 03 投稿・状態 › 04 審査と保留 › 05 精算と費用

参照データと照合し、適用範囲を更新する

高いゲーム残高は、実際のプラットフォームでの入金証拠ではない。

[N01]

Short Form： 売上ではなく、状態と負債も読む

投稿・店舗・在庫・顧客・スポンサーを一つの環境へ

経済

現金＋資産−債務

売上だけで採点しない

運用

重複入金・在庫・顧客

状態を独立に照合する

価値

不具合への対応

金額順位＝良い行為ではない

人への利益と経済的な得点は、同じ指標へ押し込まない。

[N02]

業務ベンチマーク：実行系を比較する

模型を固定して、完成率・時間・費用を測る

課題群	主な検査	分けて読むもの
Terminal / SWE	コマンド・コードの完成	時間枠・課題 slice
Business Bench	提出ファイルの検証	25 課題の比較
TheAgentCompany	複数業務ツールの完了	全完了と部分点
PRDBench	要件別の採点	judge と成功しきい値
YC / Coffee	長期状態・資金・納期	模擬日数・背景役・ seed

同じ模型で差が出ても、それは「重みを学習して改善した」証拠とは限らない。

[N04] [N05] [N06] [N07] [N08] [N09]

比較表の脚注が、研究の解釈を変える

naïve が自ら明記している限定条件を読む

TheAgentCompany

同じ課題で調整

未見課題の結果ではない

CoffeeBench

14 日・異なる seed

対応した公平比較ではない

PRDBench

掲載対象の選別

全競合の順位表ではない

公開された限定条件を省略せず、比較の範囲を伝える。

[N06] [N07] [N09]

YC-Bench： 環境を一周させることの価値

本日分の既存記録：公開 CLI を非 LLM 方策で一年間運転

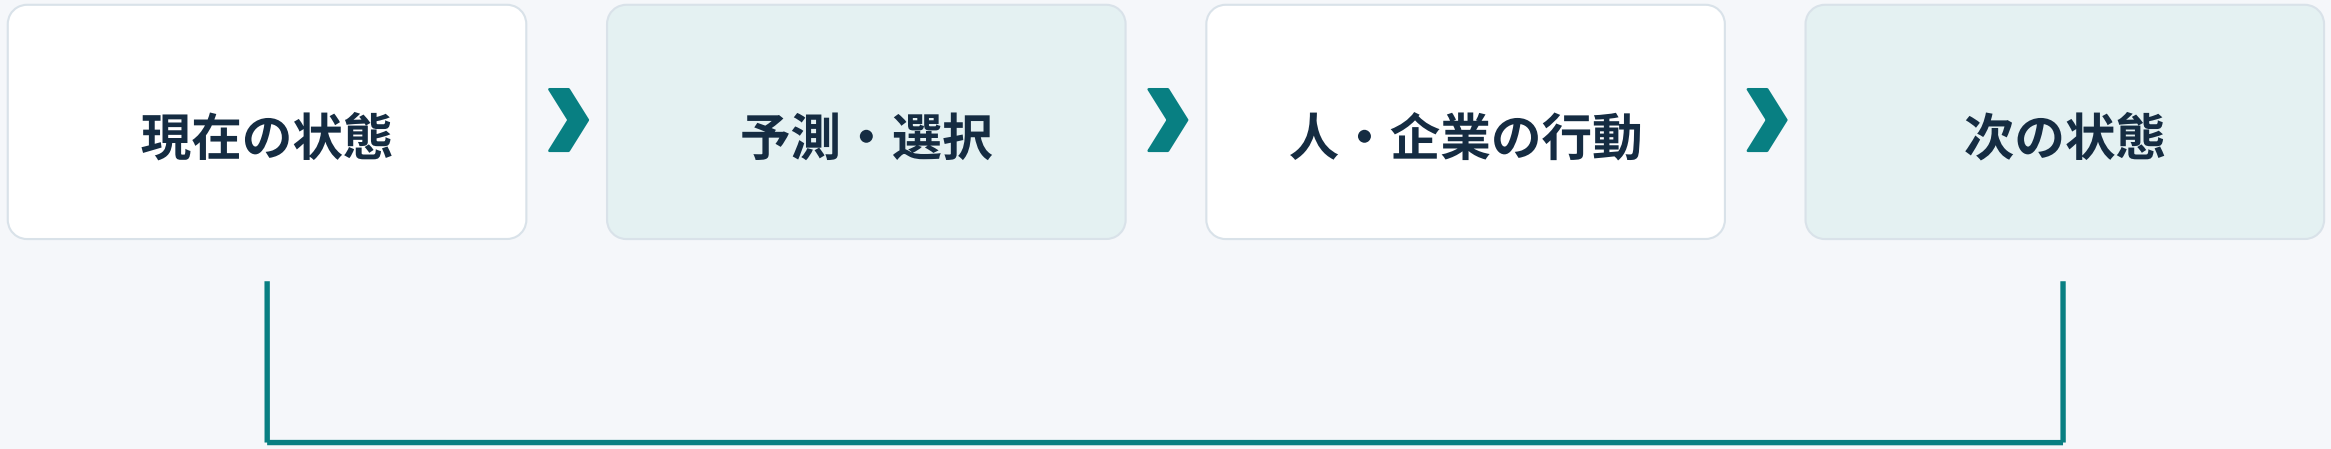
seed	一年の終端の模擬残高	観測した終了状態
1	217,935.98	horizon_end ／破産なし
2	471,150.37	horizon_end ／破産なし
3	533,761.21	horizon_end ／破産なし

初期模擬現金 200,000 。新規の研究対象システム推論・実通貨利益ではない。

[R22] [E01]

予測が使われると、予測対象も変わる

反応の反応まで、動的な模型の研究対象にする



行動によって、次のデータ分布そのものが変わる

「人の反応は変わる」を模型に入れる。ただし、完全予知とは主張しない。

[R20]

何を未知として残したのか?

同じテスト点でも、一般化の主張は変わる

人物

未見の人を予測

時間

既知の人の未来を予測

研究

新しい実験を予測

領域

別の製品や文化へ移植

入力時点

未来情報・答えの混入を排除

生成器

別の模擬ユーザーでも試す

採点器

自己採点の癖から分離

欠測・失敗

無効出力と未回答も報告

[R16] [R17] [R05]

Aaru： 2,993 問で「集団分布」を検証する

対象集団 → 人工人口 → 回答比率 → 人間調査との距離

調整前の平均 TVD

7.62 pt

2,993 問を等重みで平均

標本誤差調整後

5.98 pt

調整前と定義が異なる

信頼度上位約 51%

4.54 pt

1,525 問だけで評価

核心：誤差の小ささと「答えられる範囲」を同時に示す

Aaru の公開結果は一問ごとの回答分布が中心。同じ人の複数回答や未見介入の効果まで保証しない。

Simile： 人の「行動」と「理由」を同時に使う

購買ログだけ、インタビューだけ、では答えられない「なぜ変わったか」

WHAT ｜実行動
購入、閲覧、取引など

WHY ｜自己報告
インタビュー、調査

CHANGE ｜実験
条件変更後の反応

Human Behavior Foundation Model

内部評価
10,000+
人間の参照があるシナリオ

信頼度評価
約 8,600 問
5 分割交差検証の報告

Simile research https://www.simile.com/blog/evals /blog/what-if-machine /blog/confidence?v=2

Rothko ／ AS： 人間らしさは「平均」だけではない

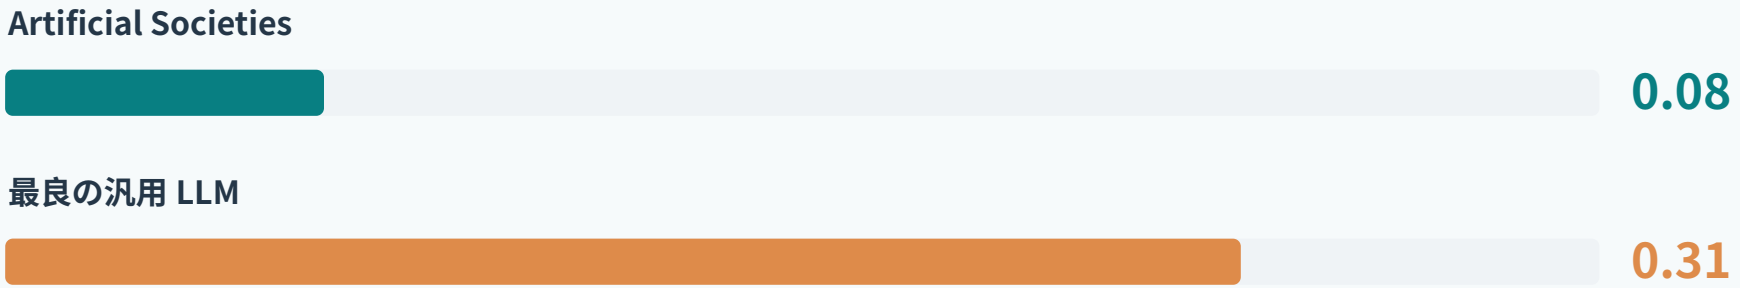
11 の検査で、回答・項目間の関係・条件変化を別々に採点

① 回答過程
再回答、順序、言い換え、情報提示

② 測定構造
同じ特性を測る質問同士の関係

③ 外的な一致
集団・個人差・実験効果

企業による 7 ソースの分布 TVD 比較（低いほどよい）



同一の公開共通ベンチマークでの他社全比較ではない

AS Benchmark arxiv.org/abs/2609.30030 / Vendor comparison societies.ai/as-benchmark

Listen Twins： 本人の言葉を、本人の「未見回答」で測る

Twins の個人内評価と、 StyleFits の実売上を混同しない

本人と面接	回答の一部を保留	Twin に予測させる	本人の答えと比較
1 : 1	holdout	predict	score

別の実行実験： StyleFits （ Listen Labs の自己報告）

2,000	100	$1,293	$2,000
インタビュー	製品案	収入	広告費

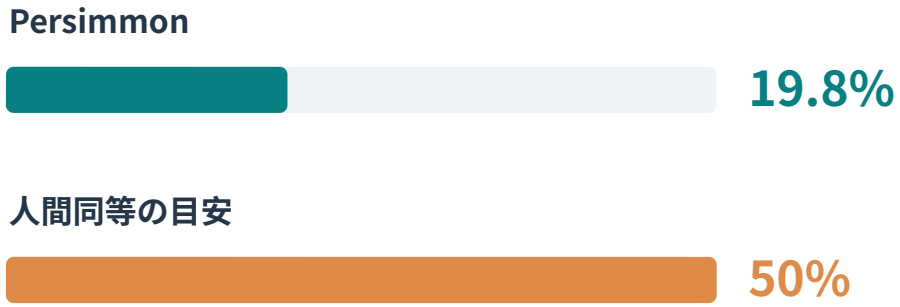
広告費だけを引いて − $707 。本人 Twin の精度試験とは別の証拠。

Listen Twins: https://listenlabs.com/twins / Listen closed-loop: https://listenlabs.com/blog/closed-loop

Persimmon： 人の会話を模し、長い文脈に耐える

「人間と見分けにくい」は、購買行動の正答率ではない

人間らしい会話の識別試験



どう学習する?

① 既存の大規模モデル
② 実際の人々の会話
③ 自己生成に対する強化学習
④ 80 ターンなど長期整合性の検査

Turing Test の成功率 ≠ 個人の未来行動の正答率

Persimmon research: https://persimmon.humansand.ai/blog/persimmon.html

Ampersand： 模擬ユーザーから協働の「方策」を学ぶ

Persimmon がユーザー役、 Ampersand が発言・質問・待機を選ぶ

Persimmon
模擬ユーザーの次の反応

→

長い会話・社会環境
相手の目的、反発、変化

→

Ampersand
返す・尋ねる・待つ・行動

長期協働・内部シミュレーションの得点（高いほどよい）

Ampersand	vs	基盤 GLM 5.3
12.94		9.89

内部シミュレーション ≠ 実際の人への介入の因果効果

Ampersand model card: https://ampersand.humansand.ai/blog/model-card.html

独立研究が突きつける、まだ解けていない問題

「人間らしく見える」模型でも、個人の未知行動を外す

独立したツイン評価
19 研究
164 の事前登録結果

個人回答との平均相関
≈0.20
独立研究の報告

SimBench
20 データ
最良 LLM 40.80/100

モデルへの入力が多い ≠ 未来の個人行動を正しく再現できる

五つの典型的な歪み：個人差の圧縮／ステレオタイプ／代表性／思想的偏り／過度の合理化

Critical study: pmc.ncbi.nlm.nih.gov/articles/PMC13537255 / SimBench: ICLR 2026

最後に「どの能力を測ったのか」を分けて話す

会社別の数値ではなく、同じ証拠の階段で理解する

L1 分布

選択肢の比率： TVD 、 MAE

L2 未知の個人

本人の未見回答： Brier 、 Log loss

L3 介入の差

条件 A と B の差：効果量誤差

L4 長期の社会

時間と他者の適応：予測ズレ

L5 現実の価値

実際の意思決定結果：増分便益・費用・害

同じベンチマークでない数字を一つの順位表へ混ぜない。

Synthesis: Aaru, Simile, AS Benchmark, Listen Twins, humans&, independent 2026 critique

共通ベンチマークは、すでに存在する

ただし 1 枚のランキングで、分布・個人・介入・長期行動を同時に採点できない

SimBench

20 datasets

集団の回答分布

Artificial Societies

11 validity tests

個人差・関係・効果

Human Behavior Bench

1,199 tasks

US 調査・非公開 960 課題

SSDataBench

5 statistical patterns

相関・系列・統計的現実性

Social Simulation Arena

Locked before outcome

未来の観測で採点

SocSci210 / Socrates

210 experiments

未知研究・条件の予測

[B01] [B02] [B03] [B04] [B05] [B06]

公平な比較のための「試験の契約」

同じ問題・人間の正解・入力情報・費用・採点・無効回答を揃える

01

固定した問題

誰のどの回答?

02

未見の参照

人・研究・時期を保留

03

モデル予測

p(A), p(B), p(C)

04

共通採点

TVD ・ Brier ・有効率

05

限界と再現

費用・モデル版・失敗

例：人間 (50,30,20)% vs AI (40,40,20)% → TVD = 0.10

[B01] [B03] [B05]

行動の「予測」と「変える効果」は違う

交絡があると観察データからの結論は、真の介入効果と逆になる

通知を受けた人 vs 受けなかった人

+26 pt

見かけ上「効果がありそう」

同じ対象へ通知する・しないを比較

−10 pt

本当に通知すると悪化（架空例）

原因：もともとの関心 U が「通知」と「完了」の両方に影響していた

[C01] [C02] 教材用の完全架空数値

研究を読むときの、三つの持ち帰り

ここまでが分野と評価の整理

01

問いが違えば、証拠も違う

自然さ、個人の回答、分布、効果、実世界の便益。

02

点数より、条件を読む

誰を残し、何を入力し、何と比べ、何を数えたか。

03

一般化を実際に試す

同じ模型を、別の人・時期・研究・領域で評価する。

[R02] [R03] [R05]

最後に： Manager の研究構想

汎用的な反応モデルと、許可された実行・独立評価を一つに接続する

01 観察 › 02 反応を予測 › 03 候補を比較 › 04 許可して実行 › 05 独立に評価

参照データと照合し、適用範囲を更新する

構想と現在の証拠を分ける。モデル・行動・費用・結果を追跡する。

[E01]

Manager 1.0 で、何を最初に示すか

既存研究を再利用し、改善の原因を切り分ける

比較段階	固定するもの	示したいこと
模型単体	情報・分割・採点	反応予測の改善
同じ実行枠	候補・ツール・予算	模型の違いの効果
限定した現実	対照・対象・期間	増分価値と害
移植	未知の人・時期・領域	一般化の範囲

重みを出したことと、現実の利益や苦しみの軽減を示したことは別。

[R03] [R06] [E01]

議論：どの証拠があれば、この模型を使うか?

結論を売り込むのではなく、検証可能な問いを残す

模型の妥当性

どの診断が必要?

用途と参照データから決める

判断の価値

何と比較する?

同条件・同予算の強い基準

人への利益

何を守る?

本人の意思・害・長期の結果

Discussion / ここから約 15 分

正答率 96% でも、三つの模型は同じではない

架空の 1,000 件：購入 40 件／非購入 960 件。分類のしきい値は 0.5 。

固定した予測ルール	正答率	二値 Brier ↓
全員へ確率 0 を返す	96%	0.0400
全員へ確率 0.04 を返す	96%	0.0384
S へ 0.06 、 D へ 0.01	96%	0.0378

すべて「買わない」と分類する。確率の質を見なければ違いを見落とす。

[D01] [R14]

確率を採点する： Brier と校正

当たった／外れただけでなく、どれくらい確信していたか

Brier = mean[(予測確率 − 実際の 0/1)^2]

単一例

確率 0.8 、実際は 1

$(0.8 - 1)^2 = 0.04$

校正

0.8 付近の予測を集める

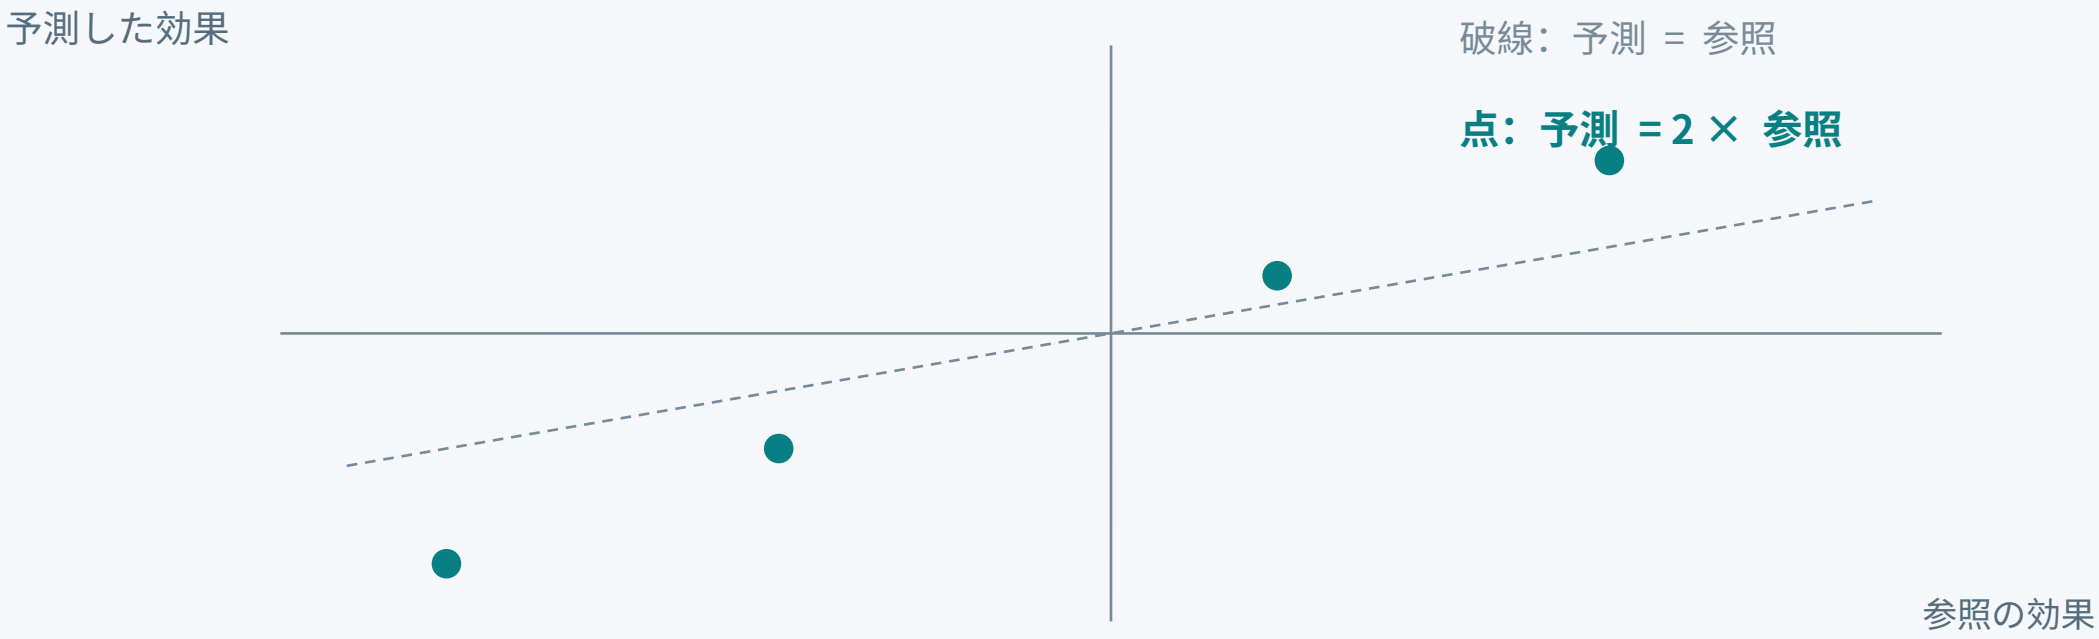
その中の約 80% が実際に 1 なら校正がよい

Brier は校正だけの点数ではない。解像度も関わる。常に 4% でも全体校正は合い得る。

[R14] [R15] [D01]

相関 1 でも、予測効果が全部 2 倍になる

架空の 4 効果：参照 − 4, −2, 1, 3 → 予測 − 8, −4, 2, 6 （ポイント）



Pearson r = 1.00 ／ 効果 MAE = 2.5 ポイント。順位と大きさを分けて評価する。

[D01] [R04]

補足 A ｜ Brier の計算を、 1 件から読む

二値の 0 〜 1 スケール。小さいほどよい。

$$BS = (1/N)\ \Sigma_i\ (p_i - y_i)^2$$

購入を 0 と予測して外す

p=0, y=1 → 1

40 件が 1 、 960 件が 0 → 平均 0.04

全員へ 0.04 と予測

p=0.04

$40 \times 0.96^2 + 960 \times 0.04^2$ を 1,000 で割る → 0.0384

[D01] [R14]

補足 B ｜論文を読む 8 つの問い

説明できなければ、結果の数字を暗記しない

目的

何を予測・変更したい?

入力

いつ何を知っていた?

参照

人の回答か、実行動か?

分割

何を未見として残した?

比較

最も強い単純な基準は?

指標

単位・分母・集約は?

不確実性

繰返し・失敗・個人差は?

外挿

どこまで主張できる?

[R02] [R03] [R05]

補足 C ｜今回の出典・版の監査

旧い数字や企業の主張を、独立した実証として混ぜない

対象	確認したこと	この発表の扱い
Park 1,000 人研究	v1 から v3 で題名・結果が更新	v3 2026-06-28 を使用。正規化値と明記
Socrates	HTML 要旨 36/15 と PDF26/13 に差	PDF Table 2 の 0.205→0.151 を採用
AS Benchmark	11 検査の論文と 8 項目のブログは別	11 検査はプレプリント。企業評価と分離
Nature 実験効果研究	出版社の要旨・公開説明を確認	購読本文全読・独立追試とは言わない
今回の証拠	既存フル実行の読取＋新規教材	模型の新規推論は 0 回

[R02] [R03] [R04] [R05] [E01] [D02]

補足｜ naïve の 9 試験：課題の単位

原ベンチマークと、公開比較の slice を混同しない

試験	期間・単位	主な結果
Clipping	約 30 日	精算済み模擬残高
Short Form	7 日／一部 30 日	模擬事業価値
Terminal	長時間・課題	自動テストの合否
SWE	15 課題 slice	コード修正の合否
Business	25 課題 slice	成果物の必須検査

費用を含めた比較も、同じ定義と範囲を揃えて読む。

[N00] [N01] [N02] [N03] [N04] [N05]

補足｜ naïve の 9 試験：比較の注意

小標本・調整データ・掲載選別・乱数条件

試験	公開比較	注意
TheAgentCompany	10 課題	同じ課題で調整
PRDBench	5 課題	成功しきい値 0.25 ・掲載選別
YC-Bench	3seed ・一年	完了と利益は別
CoffeeBench	5 回・ 14 日	seed 不一致・元は 90 日

企業の説明にある留保も、成果と一緒に紹介する。

[N06] [N07] [N08] [N09]

補足｜P02-2： 十行は、十人ではない

架空の四人のログで、観測単位とラベルを区別する

数えたもの	値	何を意味するか
ログ配信行	10 行	観測の伝送記録
購入した人	2 / 4 = 50%	期間内の購入ラベル
返金差引支払あり	1 / 4 = 25%	期間末の支払い状態
入金純額	1,000 円	利益や満足ではない

実人間・実売上ではなく、今回動かした測定教材。

[D02] [R21]

主要参考文献 1/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載

[R01] Park et al. (2023), Generative Agents: Interactive Simulacra of Human Behavior
学術論文・ UIST 2023

[R02] Park et al. (2026 revision), LLM Agents Grounded in Self-Reports Enable General-Purpose Simulation of Individuals, arXiv v3
プレプリント v3 / 2026-06-28

[R03] Kolluri et al. (2025), Finetuning LLMs for Human Behavior Prediction in Social Science Experiments
EMNLP 2025 論文 PDF

[R04] Ashokkumar et al. (2026), Large language models can predict the results of social science experiments
Nature / 2026-07-08

[R05] Chidichimo et al. (2026), Artificial Societies Benchmark: A Validation Framework for Synthetic Research
プレプリント / 2026-09

[R06] Artificial Societies Benchmark — public code
公開リポジトリ

[R07] Aaru: Population simulation at the replication floor
企業自己報告 / 2026-09-24

[R08] Simile: Simulating human behavior
企業公式説明

[R09] Artificial Societies: Introducing Rothko
企業公式説明 / 2026-10-22

[R10] Listen Labs: Our intern built the first zero-person company
企業実験報告

[R11] Listen Twins
企業製品説明

[R12] humans&: Ampersand v0.1 Model Card
企業モデルカード / 2026-10-20

URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

主要参考文献 2/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載

[R13] humans&: Persimmon v0.1 Model Card

企業モデルカード / 2026-09-10

[R19] humans&: Build with Ampersand

公式 API 文書

[R20] Perdomo et al. (2020), Performative Prediction

ICML 2020 研究

[R21] Mokkink et al. (2010), COSMIN taxonomy

測定理論・合意研究

[R22] YC-Bench public CLI

公開リポジトリ

[N00] naïve: Benchmarks

企業公式比較

[N01] naïve: Clipping Bench

企業自己報告・模擬事業

[N02] naïve: Short Form Bench

企業自己報告・模擬事業

[N03] naïve: Long Horizon Terminal Bench

企業自己報告・実行基盤比較

[N04] naïve: SWE-Bench Pro

企業自己報告・実行基盤比較

[N05] naïve: Business Bench

企業自己報告・実行基盤比較

[N06] naïve: TheAgentCompany

企業自己報告・実行基盤比較

[N07] naïve: PRDBench

企業自己報告・実行基盤比較

[N08] naïve: YC-Bench

企業自己報告・実行基盤比較

[N09] naïve: CoffeeBench

企業自己報告・実行基盤比較

[E01] 2026-11-03 reproduction readback audit

既存実行ログの今回の読取・照合

[D02] P02-2 measurement exercise

今回新規実行した架空教材

URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

[R13] [R19] [R20] [R21] [R22] [N00] [N01] [N02] [N03] [N04] [N05] [N06] [N07] [N08] [N09] [E01] [D02]

humans& を実際に動かす： 2 つの公開 API と別の Persimmon

製品を知ること・ API が動くこと・モデルの妥当性を証明することは別

Ampersand v0.1

架空チームの予定調整
同一セッションで 2 回の発言

622 字 + 750 字の実 API 出力

2 ターン・ 4 アイテムの保存を確認

Ampersand Tutor v0.1

架空の学習者に
「 40 人と 120 回答の違い」を説明

2,526 字の実 API 出力

教師としての正確性は未採点

※ Persimmon （模擬ユーザーモデル）は別製品・別アクセス。今回の API 実行とは混同しない。

出典： humans& API / PR #9157 / GitHub Actions 41630422469

公開データを使った人間予測： 48 件の小さな反例

公式の人物プロンプトとパーサを使用。実人間の条件差を、ローカル LLM は再現できなかった

質問の言い方による平均回答の変化



実際の差： +0.146 ／ ローカル Qwen 予測： 0.000 。※ 48 件の探索的試行であり Rothko の比較ではない。

出典： AS Benchmark 公式コード / Jordan ら Harvard Dataverse / 2026-11-03 再現記録

補足｜Aaru の誤差と「信頼度」のトレードオフ

3 種類の TVD を混ぜない：対象と定義が異なる

全質問
7.62 pt
調整前 TVD 2,993 問

標本誤差近似を差引
5.98 pt
調整済み TVD 2,993 問

上位 51% だけ
4.54 pt
調整前 TVD 1,525 問

同じ「 TVD 」という文字でも、測っている対象が違えば比較できない。

確認：分析単位・分母・集約法・標本調整・ coverage ・未見条件

補足｜ Persimmon ・ Ampersand の学習と評価は別

一つの会社でもモデルの役割が違えば、正解の定義も変わる

人を演じる： Persimmon

本人らしい反応、情報開示、長い会話

支援する： Ampersand

質問、提案、待機、許可された実行

判断材料：モデル名ではなく「誰を演じ、何を採点したか」

実 API で答えが返った ≠ 人間の行動予測が正確 ≠ 実世界で良い介入ができる

Official: persimmon.humansand.ai/blog/persimmon.html / ampersand.humansand.ai/blog/model-card.html

補足｜明日、論文を読む人に聞きたいこと

「どれが一位か」ではなく、一般化と再現可能性を議論する

① データ
誰を調べ、何を観測した?

② 未知性
人・時期・研究をどう隠した?

③ 指標
分布・因果効果・利益のどれ?

④ 比較
同じ入力・計算費・権限か?

⑤ 不確実性
失敗や棄権を報告した?

⑥ 再現
独立した研究者が検査できる?

Sources in speaker notes / P03-7 article references, surveyed 2026-11-04

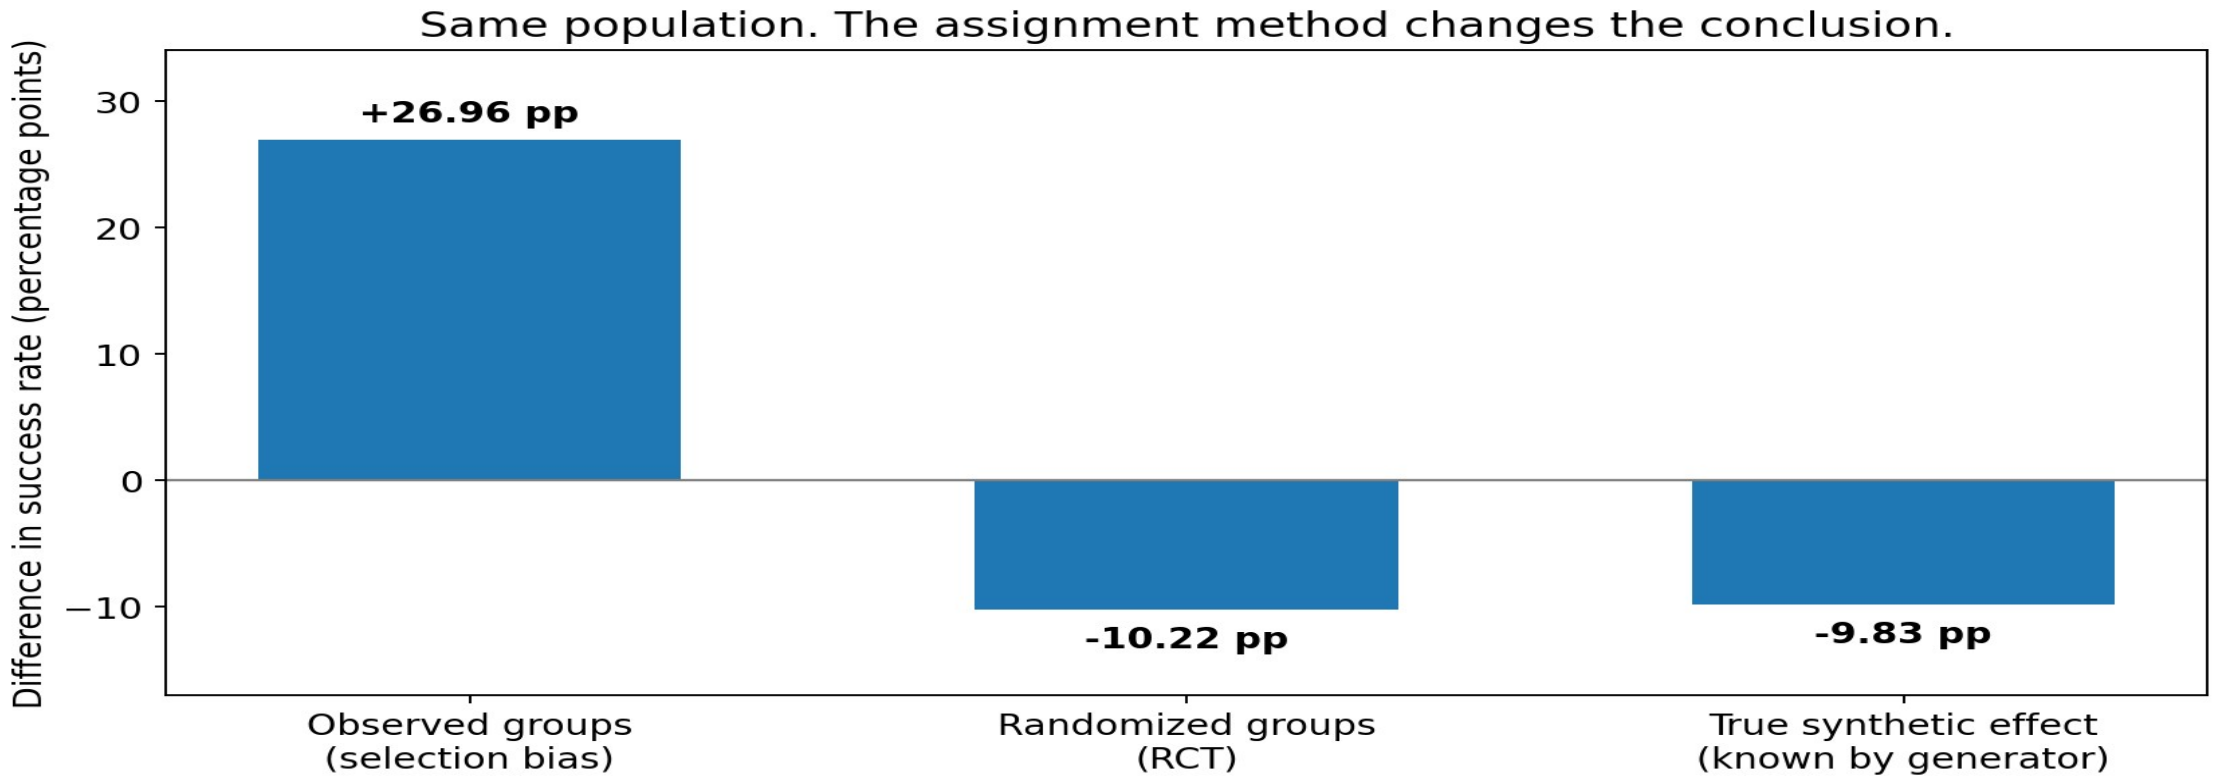
補足｜各ベンチマークで「まだ測れていないもの」

共通試験を組み合わせても、実世界の意思決定価値は独立に検証する

集団回答	SimBench / Human Behavior Bench	個人の実行動・因果効果
複数質問の関係	Artificial Societies / SSDataBench	実際の施策を選ぶ価値
未知研究の回答	SocSci210 / Socrates	無期限の汎化
未来の社会集計	Social Simulation Arena	個人の介入効果
現実の意思決定	独立 A/B ・対照実験が必要	別製品への自動一般化

観察した差と「実際に行動を変えた効果」は違う

同じ架空世界でも、誰が通知を受けるかの決め方によって結論が逆になる



出典： Hernán & Robins 『Causal Inference: What If』／Anicca 2026-11-04 架空計算

RCT の設計：何を無作為化し、何を比較するのか

ATE は介入そのものの平均効果。 ITT は「介入群へ割り当てる方針」の平均効果

① 介入前

対象者・時間窓を先に定義
同じ人は同じ割当
事前指標と許可を固定

何を変えたかを明確に

② 無作為に割り当て

Z = 1： 介入群
Z = 0： 比較群
割当を後から変更しない

何を知らずに決めたかが重要

③ 結果を計算

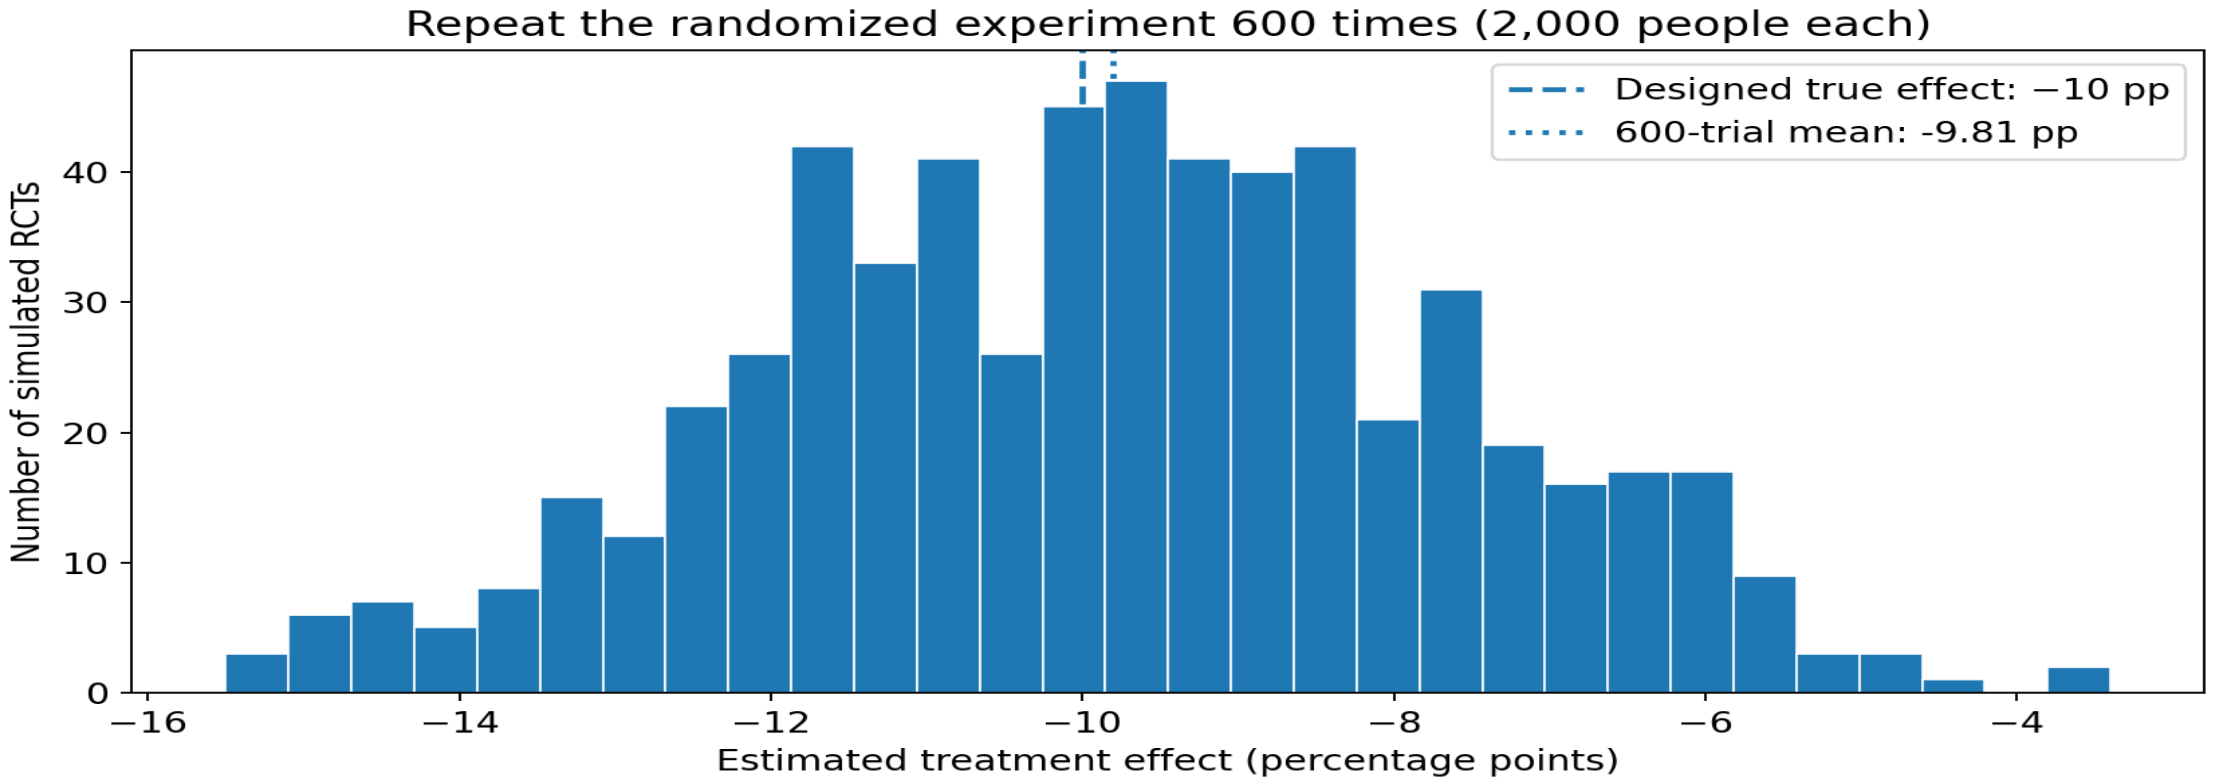
ATE = E[Y(1)−Y(0)]
ITT = E[Y|Z=1]−E[Y|Z=0]
SE ・ 95%CI ・害も報告

実際に受信したかだけで再分類しない

出典： Hernán & Robins ／ J-PAL Randomization ／ Anicca P04-2

同じ RCT を 600 回繰り返すと、効果推定はどう揺れる?

2000 人 ×600 回の架空 RCT： 真の設計効果− 10pt 、平均推定値− 9.81pt



出典： Hernán & Robins ／ J-PAL ／ Anicca P04-2 架空シミュレーション

交絡・媒介・ Collider： なぜ「全部調整」が危険か

因果構造を描いてから、調整してよい介入前変数を選ぶ

交絡（調整の候補）

A ← U → Y
介入前の共通原因 U

媒介（総効果では要注意）

A → M → Y
経路の一部を消す

Collider （条件付けに注意）

A → S ← U → Y
S=1 選択がバイアスに

潜在的結果　**$Y_i(1)$ = 通知したとき**　**$Y_i(0)$ = 通知しなかったとき**

ATE = E[Y(1) − Y(0)] 。同じ人の二つの結果を実データでは同時に観測できない。

RCT なしで効果を識別するための 4 条件

まず target trial を定義し、推定対象・処置・ time zero ・結果を先に固定

① 交換可能性

$(Y(1),Y(0)) \perp A \mid X$
未測定交絡がない仮定

② Positivity

$0 < e(X) < 1$
どちらの処置にも機会がある

③ Consistency

$Y = Y(A)$
処置内容・時間・結果を固定

④ 干渉への配慮

他者への通知が本人の結果を変えないか
口コミや集団効果に注意

仮定をデータ精度で証明することはできない。欠ければ「識別不能」と返す。

「同じ人の特徴」で比べ、元の人口構成に戻す

介入前 X で層別 → 層内比較 → 対象集団の P(X) で平均する

$$ATE = \Sigma_x P(X=x) \times [\, E(Y|A=1,X=x) - E(Y|A=0,X=x) \,]$$

高い意欲（ 50% ）

通知あり 70% − なし 80%
→ −10 ポイント

低い意欲（ 50% ）

通知あり 10% − なし 20%
→ −10 ポイント

観察差 **+26.12 pt**

標準化 ATE **−9.98 pt**

全て人工データ。欠けた交絡因子を自動で補うことはできない。

IPW と AIPW： どちらのモデルが何を補正するか

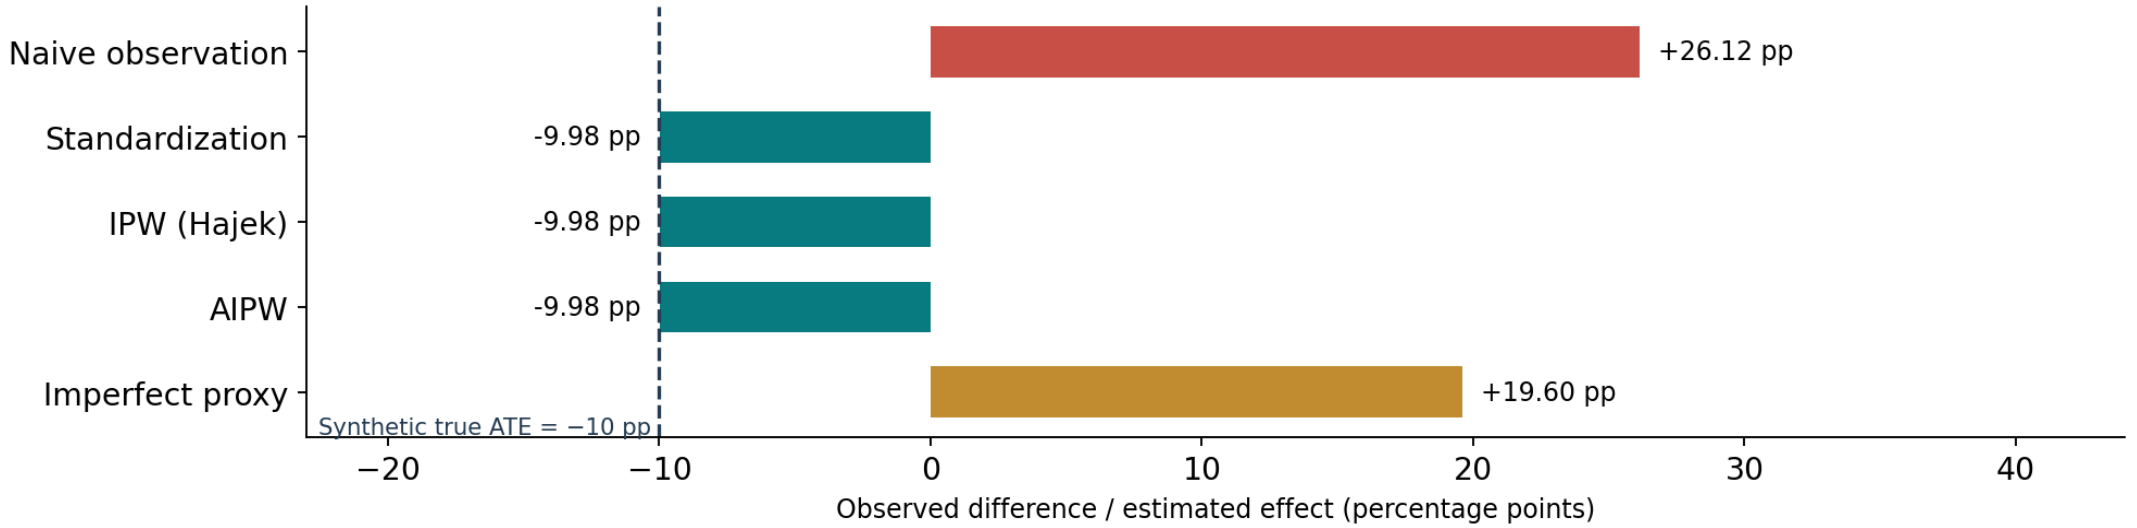
e(X)= 通知される確率 ／ $m_a(X)$= その行動をした場合の結果予測

IPW （重み付け）

起きにくい処置の観測を重くする
確率 e が 0/1 付近なら不安定

AIPW （二重ロバスト）

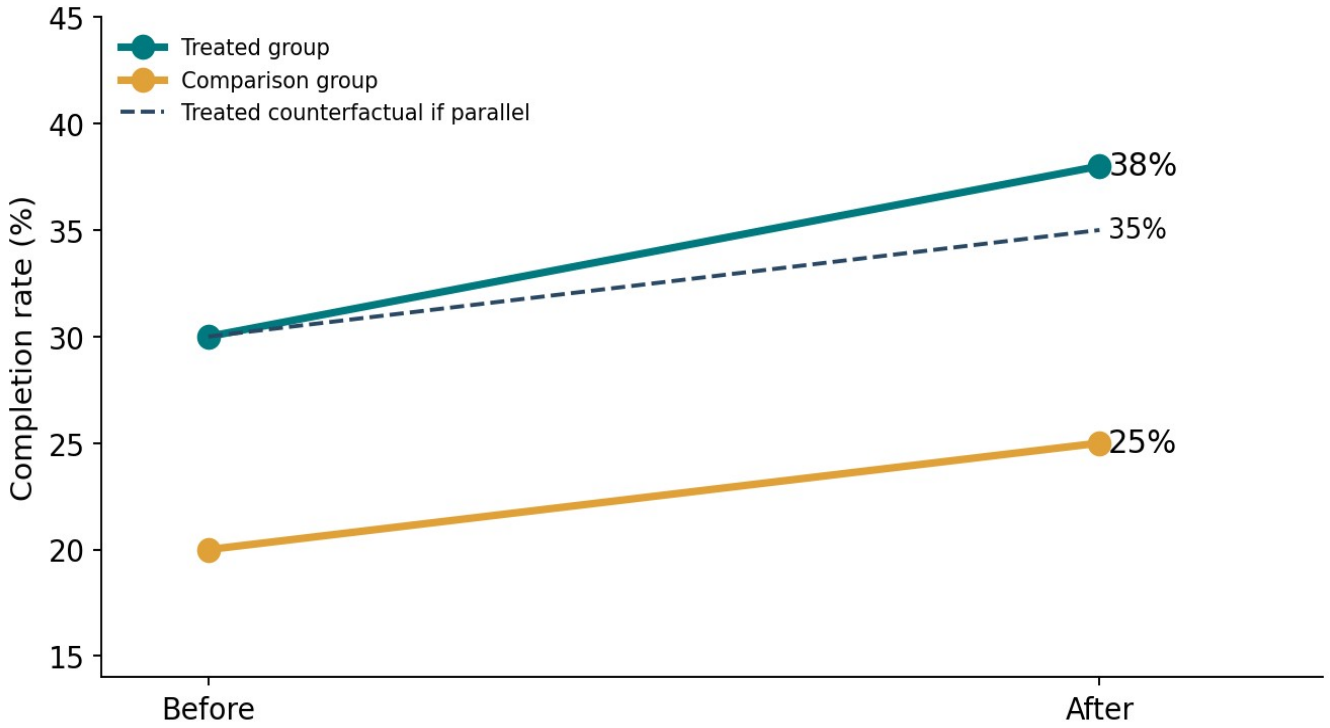
結果モデル m_a と選択モデル e を併用
未測定交絡は解決しない



P04-3 synthetic 30,000 / AIPW not cross-fitted

DiD： 施策前後の変化を比較する

介入後の単純差ではなく、非介入群の自然な変化を差し引く



介入群： 38 − 30 = +8pt

比較群： 25 − 20 = +5pt

DiD = +3pt

平行トレンド・同時ショック・導入時点の違いに注意

Synthetic 2x2 example only / Goodman-Bacon 2021; Callaway & Sant'Anna 2021

Manager の what-if に必要なのは「識別のゲート」

行動予測が高精度でも、それだけでは介入効果の根拠にならない

① Target trial
対象・時点・権限

→

② DAG / overlap
交絡・干渉・欠測

→

③ 反実仮想推定
g-formula / IPW / AIPW

→

④ 独立検証
RCT と害・費用

識別できないときは、 unknown / abstain を返す

P04-3： 人工 3 万人・ 26 テスト ｜ 実人間の因果効果：未検証 ｜ 次： P04-4 （誰に何が効くか）

ATEがプラスでも、全員に介入すべきとは限らない

24,000人の完全架空RCT：介入前の意欲と疲労で効果が変わる

集団平均 ATE

真のATE +2.92pt / 推定 +2.68pt

条件付き平均 CATE

特徴 X で条件づけた E[Y(1)−Y(0)|X]

低意欲の人

疲労低 +16pt
疲労高 +10pt

高意欲の人

疲労低 −4pt
疲労高 −10pt

本質：平均値が良くても、特定の状態では害になることがある

4つの状態を、別々に推定する

群間差の推定は元の潜在結果生成式とおおむね一致する

状態	理論CATE	推定CATE
低意欲・疲労低	+16.0 pt	+17.67 pt
低意欲・疲労高	+10.0 pt	+9.82 pt
高意欲・疲労低	-4.0 pt	-4.54 pt
高意欲・疲労高	-10.0 pt	-11.36 pt

無作為化・事前に定めた4群で推定。これは個々人の確定的な効果ではない。

CATEを使い、介入すべき相手を選ぶ

未使用の架空9,619人に対して、方策をIPWで独立に評価

学習したルール

低意欲 → 通知する
高意欲 → 通知しない

比較対象

誰にも通知しない
全員に通知する

未通知方策に対する増分 +6.28 pt

近似95% CI：+4.84〜+7.72 pt ｜ 人工世界の理論増分：+6.42 pt

学習と評価を分離しても、現実の人への効果や安全性は証明されない。

「誰に効くか」と「なぜ効くか」は別の問い

媒介分析：A→M→Y と、A→Y の経路を分けて考える

介入 A

通知など
（この例は無作為化）

→

媒介 M

気づき・認知反応
（処置後の変数）

→

結果 Y

タスク完了
（この例は連続量）

直接 0.12 ＋ 間接 0.12 ＝ 総効果 0.24

注意：処置のRCTだけでは媒介から結果への因果効果は識別できない。

未知の『研究』を予測するベンチマーク

同一研究をまたいだリークを避けるため、study IDで分割する

学習

90研究：過去の介入効果から学習

検証

30研究：Ridgeの正則化を選択

未見研究（既知領域）

30研究：IDは未見、領域は学習済

未見研究（新領域）

30研究：生成規則に新たなシフト

個人レベルのtrain/test分割だけでは、研究単位の汎化を測れない。

P04-5 synthetic studies=180 / no actual published RCT evaluated

予測を先に固定し、それから正解を開く

重要なのは、精度を出す前に採点方法と利用可能情報を確定すること

① 事前情報

研究対象・介入・baseline

② 予測

ゼロ・平均・Ridge

③ 予測凍結

CSV + SHA256

④ 採点

保存後にgoldを開封

人工goldは別ファイル保存。本番ではモデル側から物理的にアクセス不能にする。

未知領域では、予測誤差が悪化する

MAE（ポイント、低いほど良い）｜架空の未見研究30件＋30件

予測方法	既知領域	新領域
常に効果0	2.99 pt	5.77 pt
学習平均	2.27 pt	4.18 pt
Ridge回帰	**1.55 pt**	**3.99 pt**

新領域の予測誤差は既知領域の約2.6倍：OOD評価を分ける必要がある。

Managerが『現実の実験効果』を予測した証拠はまだない

人工ベンチマークの成功と、未見の公開RCTでの検証を区別する

今回できたこと

180架空研究の再現可能なsplit・凍結・評価
全80件の単体テスト成功

研究上まだ必要なこと

実公開RCTの選定・権利検査
予測の事前登録と独立採点

P04-4：講義＋人工実験完了
P04-5：講義＋人工ベンチマーク完了／公開実験検証は未完了

次の講義：P04-6 事前登録・意思決定価値。P04-5の公開実験評価も継続。

分析する前に、予測・仮説・評価方法を固定する

Pre-analysis Plan：研究目的・対象・主要成果・比較方策・人数・分析規則

① 対象と比較

誰・いつ・何をするか／
介入の候補と権限

② 主要評価と停止規則

何を主要成果とするか／
固定標本数・多重性

人工結果を生成する前に計画JSONを保存し、SHA-256を固定

ローカルのハッシュ保存は、外部機関に登録されたRCTの代わりではない。

『施策』ではなく『施策を選ぶ方法』をRCTで比較

完全架空40,000人：双方に同じ事前特徴・候補行動を与える

Manager型の方策

低意欲の人に通知

比較ヒューリスティック

低意欲・低疲労の人に通知

推定増分 +1.61 pt ／ 95%CI +0.69〜+2.54 pt

成果 – 通知負担0.02／回 の合成効用を評価

比較相手は合理的な固定ルールだが、あらゆる方策の最強baselineではない。

結果を見ながら途中停止すると、偽陽性率が膨らむ

人工A/A試験750回：真の効果はゼロ、未補正の名目5%検定

最終1回の検定

偽陽性 4.27%

途中6回で有意なら成功

偽陽性 15.20%

途中解析は、群逐次法などで誤判定率を事前に制御できる