JOURNAL CLUB · 2026.11.05 13:00–14:00 JST

AI は人間の行動を どこまで再現できるか?

人間模型・行動介入・社会的協働・事業エージェントを「測定」から読む

人間データ | シミュレーション | 介入 | 評価

成田 大祐 | 人間行動・協働・事業エージェントの方法と評価

今日の問いは、三つ

分野の整理 → 代表論文 → 評価の落とし穴 → 今後の研究

01

何をシミュレーションしている?

個人の回答／選択／相互作用／長期の変化

02

何をもって「正しい」とする?

自然さ、分布、個人差、介入効果は別

03

現実の意思決定へ使える?

比較対象・不確実性・移植・害を見る

二つの「エージェント」を混ぜない

人を演じる模型と、人のために行動する AI は別の役割

人間・世界モデル

「どう反応しそうか?」

プロフィール＋履歴＋状況 → 反応の分布

方策・実行エージェント

「何をするべきか?」

目標＋予測＋制約 → 発言・変更・待機

[R12] [R13]

人間行動シミュレーションの共通構造

人口を作るだけでは、行動モデルは完成しない

01 実人間の情報 › 02 個人・集団の表現 › 03 反応モデル › 04 相互作用・時間 › 05 集計・比較

参照データと照合し、適用範囲を更新する

観測データで検証し、模型に戻す。すべての方式が全層を持つわけではない。

[R01] [R02] [R07]

方法の違いは「何を学び、何を固定するか」

排他的な五択ではなく、組み合わせる設計要素

系統	主な表現・入力	強み／主な検証課題
統計・選択モデル	数値特徴、選択肢、効用	単純な基準／未知の文脈への移植
エージェントベース	状態・規則・ネットワーク	相互作用／規則の根拠
LLM ＋ペルソナ	属性・指示・会話	言語の柔軟性／型にはめた反応
インタビューで個人を表現	本人の自己報告・記憶	個人固有の文脈／未知の結果
行動データで追加学習	実験・調査・行動の記録	共有表現／リークと一般化

[R01] [R02] [R03] [R09]

「よいアシスタント」と「忠実な人間模型」は同じではない

もっともらしい説明 ≠ 実際の選択を生む原因

使える力

知識・言語・文脈を広く扱える

未知の質問を、自然言語で与えられる

ずれ得る目的

迎合や一貫性が、人の反応を歪める可能性

個人差や揺らぎを平均化する可能性

[R05] [R09]

起点① Generative Agents： 記憶から行動へ

Park et al., UIST 2023 ｜ 25 体のエージェントの仮想社会

01 観察 › 02 記憶ストリーム › 03 関連記憶を検索 › 04 振り返り・計画 › 05 行動

参照データと照合し、適用範囲を更新する

示したのは、構成要素が「もっともらしい振る舞い」に寄与すること。

[R01]

起点② 実際の人の情報で個人模型を作る

Park et al., arXiv v3 （2026-06-28） | 1,052 人の米国成人

01 本人の情報 › 02 面接／調査／両方 › 03 LLM へ文脈として入力 › 04 隠した項目を予測 › 05 本人の回答と比較

参照データと照合し、適用範囲を更新する

新しい人の予測とは限らない。「本人の未提示の結果」を何で測ったかが重要。

「86%」は、生の正答率ではない

本人の 2 週間後の再回答一致率に対する正規化値｜ GSS の未提示項目



分母・正規化・対象項目・論文の版を読む。 1.00 はこの評価の本人再回答基準。

起点③ Socrates： 反応を追加学習する

Kolluri et al., EMNLP 2025 | SocSci210

01
210 の公開実験

02
条件＋属性＋回答

03
事前学習済み LLM

04
SFT ／ DPO 等

05
未見の研究で評価

参照データと照合し、適用範囲を更新する

約 290 万回答・ 400,491 参加者。「行数」と「人数」と「研究数」は別。

[R03]

追加学習の効果は、指標ごとに読む

Socrates ・ PDF Table 2 ｜未見研究の正規化 1-Wasserstein 距離（低いほどよい）



0.205 → 0.151： 距離が約 26.3% 減少。正答率が 26.3 ポイント上がったのではない。

起点④ 条件間の差を予測する

Ashokkumar et al., Nature 2026 ｜社会科学実験の効果予測

データ

70 実験／ 469 効果

事前登録された米国調査実験。119,330 参加者。

方法

刺激を条件別に提示

模擬回答の条件間差から、介入効果を予測。

重要な限界

相関は高いが過大推定

強い相関だけで、効果の大きさが正しいとは言えない。

企業の違いを、入出力と検証から読む

ここは企業公式説明。原理の比較であり、独立した性能ランキングではない。

組織	公表している主なアプローチ	読むべき未確認点
Aaru	人口を構成し、非 LLM の中核行動モデルで応答	対象範囲・時間制約・分布と実行動
Simile	実人間データで行動モデルと信頼度を学ぶ	信頼度の検証・データ更新・移植
Rothko / Artificial Societies	事前学習モデルを変更し、意思決定を出力	非公開の構造・学習データ・独立再現

[R07] [R08] [R09]

Listen Labs： 速い模型と、現実のフィードバック

Twins と StyleFits の報告は、別の証拠として扱う

Listen Twins

実人間に対応する模型

インタビューを入力し、隠した回答と比較。出典・信頼度を提示。

StyleFits 実験

調査 → 開発 → 実ユーザー → 修正

約 2,000 インタビュー。売上 $1,293 、広告 $2,000 。人の介助あり。

[R10] [R11]

humans&：人間模型で支援モデルを訓練する

模擬ユーザーと方策を分ける、具体例

Persimmon

人間側の反応を生成

履歴・プロフィール・状況 → 会話の続きを生成

Ampersand

支援の行動を学ぶ

長期の模擬社会シナリオで RL 。発言する／待つ。

[R12] [R13]

Persimmon： 人間らしさを五つに分ける

評価名だけでなく、何を人間の参照にしているかを見る

試験	主に観察するもの	主張の限界
Multi-User Turing	本物／生成の会話群の識別	個人の未来正答率ではない
Profile Turing	プロフィールと会話の対応	内心の読取ではない
User-Sim Index	文体・質問・情報・誤りへの反応	パターン依存
Trickle Test	情報の段階的な開示	生成情報の真実性とは別
Long Context	長い会話の整合性	人への長期利益とは別

会話の自然さ・整合性・実行動の予測は、別の評価対象。

[R13] [R23]

Ampersand： 支援の結果を、長い時間で測る

訓練環境のユーザーモデルと採点者への依存を検査する

訓練

長い社会的やり取り

Persimmon の反応から学ぶ

行動

発言・ツール・待つ

多く動く＝よい支援ではない

外部検証

未知の相手と状況

模型・ grader への適合を点検

模型内の協働得点から、実人間の便益へは別の証拠が必要。

[R12]

「人間らしい」から「役立つ」まで、証拠は飛べない

一つの点数で、すべての主張を代用しない

自然さ	会話や物語としてもっともらしい
分布・個人	割合、ばらつき、同じ人の回答を再現する
構造・効果	回答の関係、条件を変えた差を再現する
意思決定	同じ予算で、よりよい選択をする
現実の結果	実際の利益・生活・負担・害を測る

[R01] [R02] [R04] [R05]

ベンチマークは、データセットだけではない

問いと採点条件を固定する「試験の設計書」

課題

何を予測・選択する?

参照データ

何を正解の根拠にする?

分割

何を未知として残す?

入力・実行

情報、ツール、回数、予算

比較対象

単純模型と強い既存法

指標・集計

単位、重み、欠測、失敗

不確実性

人・研究単位での変動

再現条件

版、コード、出典、費用

[R05] [R16]

一問ずつは完全一致。しかし、組み合わせは逆

教育用：質問 A と B 、各 100 人。 1= はい／ 0= いいえ。

参照集団

	B=0	B=1
A=0	50 人	0 人
A=1	0 人	50 人

人工集団

	B=0	B=1
A=0	0 人	50 人
A=1	50 人	0 人

各質問の周辺 TVD は 0 。同時分布の TVD は 1 。割合だけでは「誰が何を答えたか」が消える。

[D01] [R05]

正しい方向でも、効果量を外す

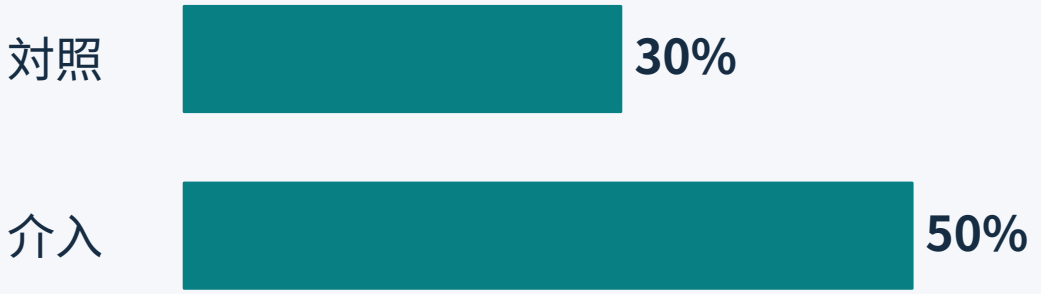
架空例：対照から介入後への結果の変化

参照



差： +8 ポイント

模型



差： +20 ポイント

参照： +8 ポイント。模型： +20 ポイント。効果の絶対誤差は 12 ポイント。

[D01] [R04]

AS Benchmark： 11 の検査で用途を確かめる

Chidichimo et al., 2026 preprint ｜ 20 人間データソース、 9 つの汎用 LLM

回答過程（ IV ）

IV-1 同じ質問の繰り返し

IV-2 関連項目の論理

IV-3 言い換え

IV-4 順番・形式の変更

測定構造（ CV ）

CV-1 項目間の共分散

CV-2 外部基準との関係

CV-3 異なる特性の区別

人口・実験（ EV ）

EV-1 回答分布

EV-2 個人・部分集団

EV-3 実験効果

EV-4 因子・測定構造

※ IV は本論文の回答忠実性の診断分類。因果識別そのものを保証する用語ではない。

[R05] [R06]

公開コードを、入出力の流れとして読む

データの意味は、提示・解析・欠測処理の実装にも宿る

01 課題・人物 › 02 提示・収集 › 03 解析・欠測 › 04 指標と比較 › 05 スコアカード

参照データと照合し、適用範囲を更新する

正常に終了したことと、人間を正しく予測したことは別。

AS 再現：公開された計算経路を確認する

本日作成済みの Mac 実行ログ・ XML ・出力レシートを今回照合

検査	確認した記録	言える範囲
環境・全テスト	68 成功／ 7 スキップ	元個票が必要な 7 件は残る
スコアカード	7,128 セルの行内容一致	保存済み集計からの再構築
図	10 図 × PNG/PDF	PDF デバイスを移植
新規模型推論	0 回	模型の性能比較は未実施

既存実行の照合。今回、全推論を新しく実行したという報告ではない。

[R06] [E01]

「再現できる範囲」を正確に切り分ける

専有モデルへの認証と、公開コードの実行は別の問題

対象	確認した範囲	別に必要なもの
AS Benchmark	固定環境・全テスト起動・再集計	元調査データ／新規回答
Ampersand	公式 SDK 準備、 API401	許可されたアカウントのキー
Persimmon	公開方法・評価・制限	利用承認と再現用の資料
内部ベンチ全体	公開説明を検討	シナリオ・ grader ・原出力

未知の部分を埋めたふりをしないことも、再現研究の成果。

[R19] [R06] [E01]

naïve： 二つのベンチマーク群

同じモデルで実行基盤を替えるか、同じ基盤でモデルを替えるか

モデル比較

同じ環境・違う模型

Clipping ／ Short Form

実行基盤比較

同じ模型・違う実行系

業務・コード・会社運営

共通の問い

何を完成と呼ぶか

成功・費用・失敗の単位

企業名やモデル名だけの順位表では、改善の原因は分からない。

Clipping Bench： 模擬メディア事業の一か月

単発の投稿ではなく、権利・時間・疲労・遅れた入金を扱う

01 素材・案件 › 02 編集・選択 › 03 投稿・状態 › 04 審査と保留 › 05 精算と費用

参照データと照合し、適用範囲を更新する

高いゲーム残高は、実際のプラットフォームでの入金証拠ではない。

[N01]

Short Form： 売上ではなく、状態と負債も読む

投稿・店舗・在庫・顧客・スポンサーを一つの環境へ

経済

現金＋資産−債務

売上だけで採点しない

運用

重複入金・在庫・顧客

状態を独立に照合する

価値

不具合への対応

金額順位＝良い行為ではない

人への利益と経済的な得点は、同じ指標へ押し込まない。

[N02]

業務ベンチマーク：実行系を比較する

模型を固定して、完成率・時間・費用を測る

課題群	主な検査	分けて読むもの
Terminal / SWE	コマンド・コードの完成	時間枠・課題 slice
Business Bench	提出ファイルの検証	25 課題の比較
TheAgentCompany	複数業務ツールの完了	全完了と部分点
PRDBench	要件別の採点	judge と成功しきい値
YC / Coffee	長期状態・資金・納期	模擬日数・背景役・ seed

同じ模型で差が出ても、それは「重みを学習して改善した」証拠とは限らない。

[N04] [N05] [N06] [N07] [N08] [N09]

比較表の脚注が、研究の解釈を変える

naïve が自ら明記している限定条件を読む

TheAgentCompany

同じ課題で調整

未見課題の結果ではない

CoffeeBench

14 日・異なる seed

対応した公平比較ではない

PRDBench

掲載対象の選別

全競合の順位表ではない

公開された限定条件を省略せず、比較の範囲を伝える。

[N06] [N07] [N09]

YC-Bench： 環境を一周させることの価値

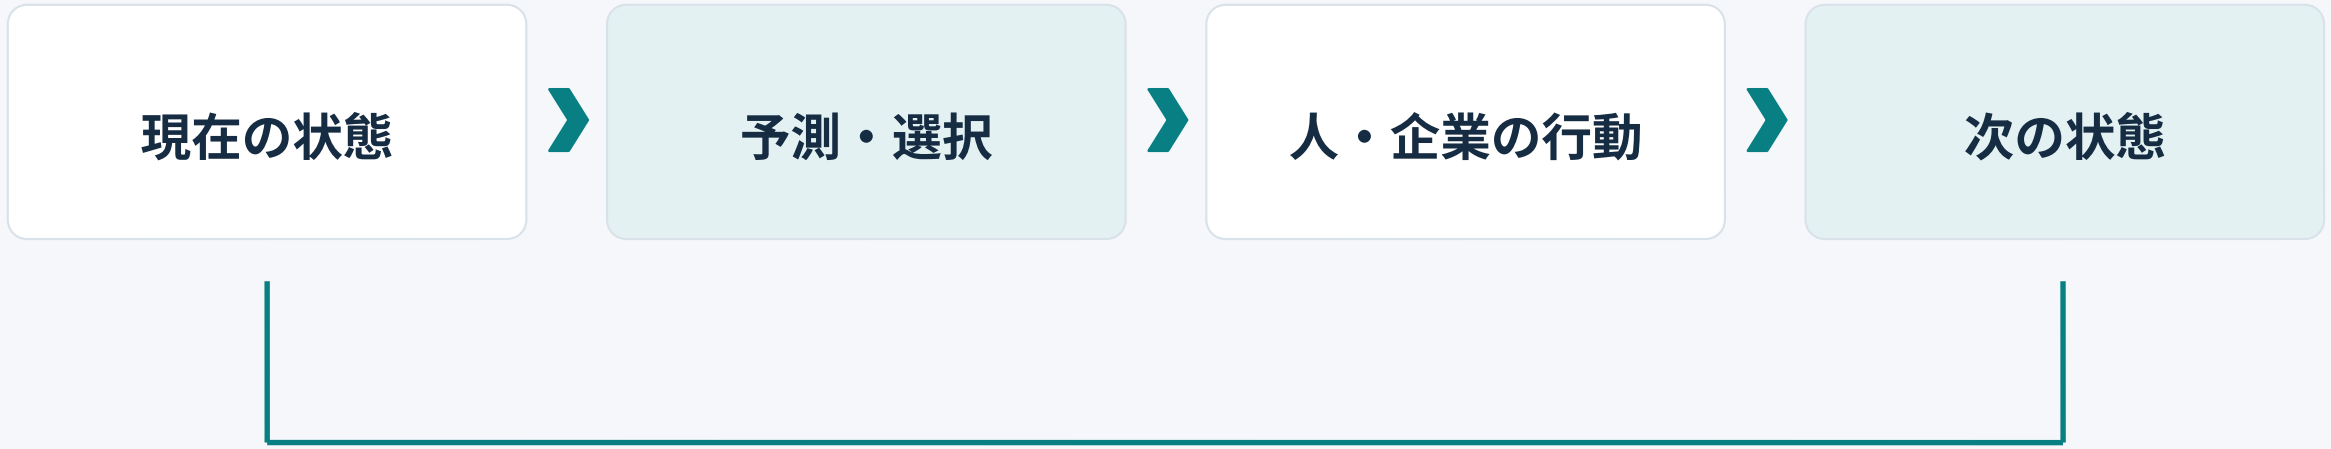
本日分の既存記録：公開 CLI を非 LLM 方策で一年間運転

seed	一年の終端の模擬残高	観測した終了状態
1	217,935.98	horizon_end ／破産なし
2	471,150.37	horizon_end ／破産なし
3	533,761.21	horizon_end ／破産なし

初期模擬現金 200,000 。新規の研究対象システム推論・実通貨利益ではない。

予測が使われると、予測対象も変わる

反応の反応まで、動的な模型の研究対象にする



行動によって、次のデータ分布そのものが変わる

「人の反応は変わる」を模型に入れる。ただし、完全予知とは主張しない。

[R20]

何を未知として残したのか?

同じテスト点でも、一般化の主張は変わる

人物

未見の人を予測

時間

既知の人の未来を予測

研究

新しい実験を予測

領域

別の製品や文化へ移植

入力時点

未来情報・答えの混入を排除

生成器

別の模擬ユーザーでも試す

採点器

自己採点の癖から分離

欠測・失敗

無効出力と未回答も報告

[R16] [R17] [R05]

Aaru： 2,993 問で「集団分布」を検証する

対象集団 → 人工人口 → 回答比率 → 人間調査との距離

調整前の平均 TVD

7.62 pt

2,993 問を等重みで平均

標本誤差調整後

5.98 pt

調整前と定義が異なる

信頼度上位約 51%

4.54 pt

1,525 問だけで評価

核心：誤差の小ささと「答えられる範囲」を同時に示す

Aaru の公開結果は一問ごとの回答分布が中心。同じ人の複数回答や未見介入の効果まで保証しない。

Simile： 人の「行動」と「理由」を同時に使う

購買ログだけ、インタビューだけ、では答えられない「なぜ変わったか」

WHAT ｜実行動
購入、閲覧、取引など

WHY ｜自己報告
インタビュー、調査

CHANGE ｜実験
条件変更後の反応

Human Behavior Foundation Model

内部評価
10,000+
人間の参照があるシナリオ

信頼度評価
約 8,600 問
5 分割交差検証の報告

Simile research https://www.simile.com/blog/evals /blog/what-if-machine /blog/confidence?v=2

Rothko ／ AS： 人間らしさは「平均」だけではない

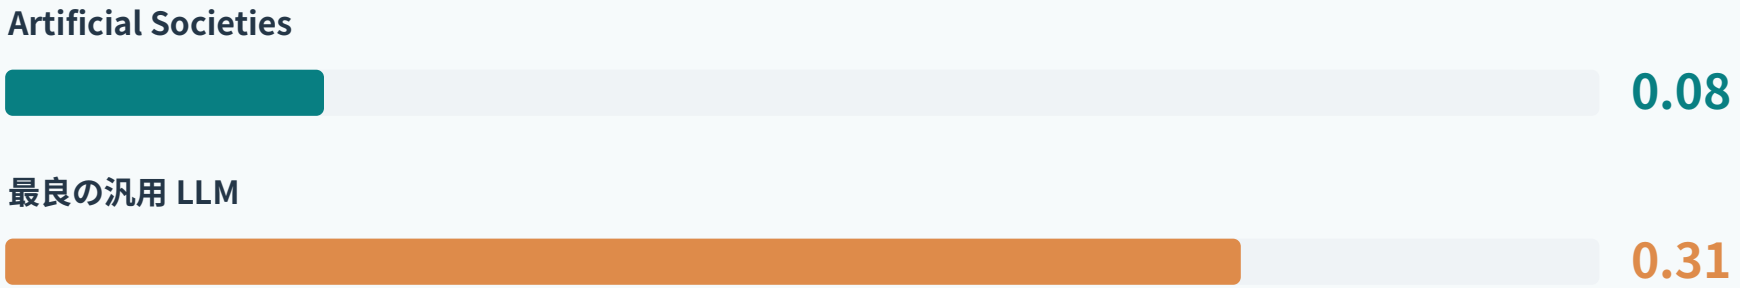
11 の検査で、回答・項目間の関係・条件変化を別々に採点

① 回答過程
再回答、順序、言い換え、情報提示

② 測定構造
同じ特性を測る質問同士の関係

③ 外的な一致
集団・個人差・実験効果

企業による 7 ソースの分布 TVD 比較（低いほどよい）



同一の公開共通ベンチマークでの他社全比較ではない

AS Benchmark arxiv.org/abs/2609.30030 / Vendor comparison societies.ai/as-benchmark

Listen Twins： 本人の言葉を、本人の「未見回答」で測る

Twins の個人内評価と、 StyleFits の実売上を混同しない

本人と面接	回答の一部を保留	Twin に予測させる	本人の答えと比較
1 : 1	holdout	predict	score

別の実行実験： StyleFits （ Listen Labs の自己報告）

2,000	100	$1,293	$2,000
インタビュー	製品案	収入	広告費

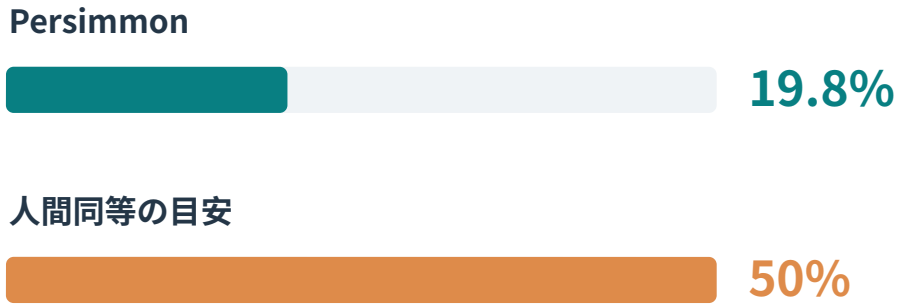
広告費だけを引いて − $707 。本人 Twin の精度試験とは別の証拠。

Listen Twins: https://listenlabs.com/twins / Listen closed-loop: https://listenlabs.com/blog/closed-loop

Persimmon： 人の会話を模し、長い文脈に耐える

「人間と見分けにくい」は、購買行動の正答率ではない

人間らしい会話の識別試験



どう学習する?

① 既存の大規模モデル
② 実際の人々の会話
③ 自己生成に対する強化学習
④ 80 ターンなど長期整合性の検査

Turing Test の成功率 ≠ 個人の未来行動の正答率

Persimmon research: https://persimmon.humansand.ai/blog/persimmon.html

Ampersand： 模擬ユーザーから協働の「方策」を学ぶ

Persimmon がユーザー役、 Ampersand が発言・質問・待機を選ぶ

Persimmon
模擬ユーザーの次の反応

→

長い会話・社会環境
相手の目的、反発、変化

→

Ampersand
返す・尋ねる・待つ・行動

長期協働・内部シミュレーションの得点（高いほどよい）

Ampersand	vs	基盤 GLM 5.3
12.94		9.89

内部シミュレーション ≠ 実際の人への介入の因果効果

Ampersand model card: https://ampersand.humansand.ai/blog/model-card.html

独立研究が突きつける、まだ解けていない問題

「人間らしく見える」模型でも、個人の未知行動を外す

独立したツイン評価
19 研究
164 の事前登録結果

個人回答との平均相関
≈0.20
独立研究の報告

SimBench
20 データ
最良 LLM 40.80/100

モデルへの入力が多い ≠ 未来の個人行動を正しく再現できる

五つの典型的な歪み：個人差の圧縮／ステレオタイプ／代表性／思想的偏り／過度の合理化

Critical study: pmc.ncbi.nlm.nih.gov/articles/PMC13537255 / SimBench: ICLR 2026

最後に「どの能力を測ったのか」を分けて話す

会社別の数値ではなく、同じ証拠の階段で理解する

L1 分布

選択肢の比率： TVD 、 MAE

L2 未知の個人

本人の未見回答： Brier 、 Log loss

L3 介入の差

条件 A と B の差：効果量誤差

L4 長期の社会

時間と他者の適応：予測ズレ

L5 現実の価値

実際の意思決定結果：増分便益・費用・害

同じベンチマークでない数字を一つの順位表へ混ぜない。

Synthesis: Aaru, Simile, AS Benchmark, Listen Twins, humans&, independent 2026 critique

共通ベンチマークは、すでに存在する

ただし 1 枚のランキングで、分布・個人・介入・長期行動を同時に採点できない

SimBench

20 datasets

集団の回答分布

Artificial Societies

11 validity tests

個人差・関係・効果

Human Behavior Bench

1,199 tasks

US 調査・非公開 960 課題

BehaviorBench

20 scenarios

個別・分布／ Be.FM 1.5

Social Simulation Arena

Locked before outcome

未来の観測で採点

SocSci210 / Socrates

210 experiments

未知研究・条件の予測

[B01] [B02] [B03] [B07] [B05] [B06]

公平な比較のための「試験の契約」

同じ問題・人間の正解・入力情報・費用・採点・無効回答を揃える

01

固定した問題

誰のどの回答?

02

未見の参照

人・研究・時期を保留

03

モデル予測

p(A), p(B), p(C)

04

共通採点

TVD ・ Brier ・有効率

05

限界と再現

費用・モデル版・失敗

例：人間 (50,30,20)% vs AI (40,40,20)% → TVD = 0.10

[B01] [B03] [B05]

行動の「予測」と「変える効果」は違う

交絡があると観察データからの結論は、真の介入効果と逆になる

通知を受けた人 vs 受けなかった人

+26 pt

見かけ上「効果がありそう」

同じ対象へ通知する・しないを比較

−10 pt

本当に通知すると悪化（架空例）

原因：もともとの関心 U が「通知」と「完了」の両方に影響していた

[C01] [C02] 教材用の完全架空数値

研究を読むときの、三つの持ち帰り

ここまでが分野と評価の整理

01

問いが違えば、証拠も違う

自然さ、個人の回答、分布、効果、実世界の便益。

02

点数より、条件を読む

誰を残し、何を入力し、何と比べ、何を数えたか。

03

一般化を実際に試す

同じ模型を、別の人・時期・研究・領域で評価する。

[R02] [R03] [R05]

Manager： What-if Machine × Executor

行動を『予測する』から、『介入・実行・検証する』へ

① Behavior

人と状況の状態
反応を予測

→

② What-if

候補施策の因果効果
不確実性を比較

→

③ Executor

同意・権限の範囲で
実際に行動

→

④ Evidence

結果・害・費用を
独立に測定

大きな可能性は研究仮説。どの意思決定が本当に改善したか、実験で反証可能にする。

実証するのは、製品・流通・人への便益

最初に Manager を直接売るのではなく、 Manager が生んだ成果を示す

製品が求められる

実際の課題解決
継続率・返金率
貢献利益

必要な人へ届く

増分の顧客獲得
獲得費用・ LTV
配信後の純利益

苦しみが軽減する

反すう /PTQ
マインドフルネス /FFMQ
生活機能・害・同意

フォロワー数・視聴回数・売上だけでは不十分。費用を差し引いた利益と本人の実測便益で判断する。

『結果で語る』——まだ未検証のことも示す

分野の評価方法を、実世界の製品・方策の検証へつなげる

いま確認できていること

人工データでの因果推論・ RCT
方策価値のコード検証
研究プロトコルと発表資料

これから証明すること

実在研究の未見予測
製品・流通の増分成果
本人の心理・生活の改善

可能な範囲でコード／重みを公開し、第三者に検証してもらう。
問い：最初にどの実験で、この仮説を厳しく試すべきか?

正答率 96% でも、三つの模型は同じではない

架空の 1,000 件：購入 40 件／非購入 960 件。分類のしきい値は 0.5 。

固定した予測ルール	正答率	二値 Brier ↓
全員へ確率 0 を返す	96%	0.0400
全員へ確率 0.04 を返す	96%	0.0384
S へ 0.06 、 D へ 0.01	96%	0.0378

すべて「買わない」と分類する。確率の質を見なければ違いを見落とす。

[D01] [R14]

確率を採点する： Brier と校正

当たった／外れただけでなく、どれくらい確信していたか

Brier = mean[(予測確率 − 実際の 0/1)^2]

単一例

確率 0.8 、実際は 1

$(0.8 - 1)^2 = 0.04$

校正

0.8 付近の予測を集める

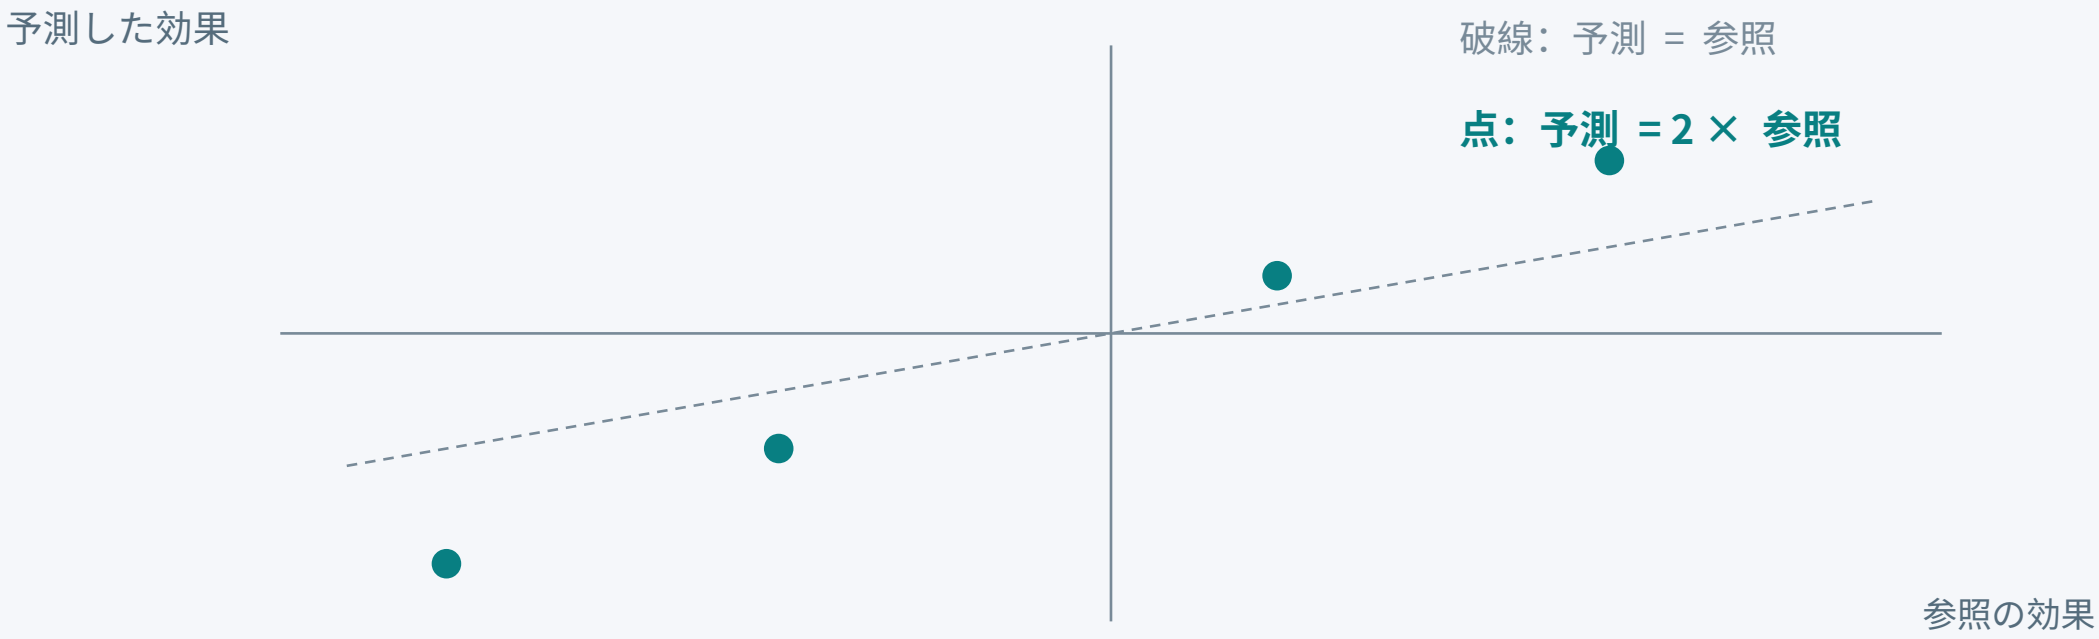
その中の約 80% が実際に 1 なら校正がよい

Brier は校正だけの点数ではない。解像度も関わる。常に 4% でも全体校正は合い得る。

[R14] [R15] [D01]

相関 1 でも、予測効果が全部 2 倍になる

架空の 4 効果：参照 − 4, −2, 1, 3 → 予測 − 8, −4, 2, 6 （ポイント）



Pearson r = 1.00 ／ 効果 MAE = 2.5 ポイント。順位と大きさを分けて評価する。

[D01] [R04]

補足 A ｜ Brier の計算を、 1 件から読む

二値の 0 〜 1 スケール。小さいほどよい。

$$BS = (1/N)\ \Sigma_i\ (p_i - y_i)^2$$

購入を 0 と予測して外す

p=0, y=1 → 1

40 件が 1 、 960 件が 0 → 平均 0.04

全員へ 0.04 と予測

p=0.04

$40 \times 0.96^2 + 960 \times 0.04^2$ を 1,000 で割る → 0.0384

[D01] [R14]

補足 B ｜論文を読む 8 つの問い

説明できなければ、結果の数字を暗記しない

目的

何を予測・変更したい?

入力

いつ何を知っていた?

参照

人の回答か、実行動か?

分割

何を未見として残した?

比較

最も強い単純な基準は?

指標

単位・分母・集約は?

不確実性

繰返し・失敗・個人差は?

外挿

どこまで主張できる?

[R02] [R03] [R05]

補足 C ｜今回の出典・版の監査

旧い数字や企業の主張を、独立した実証として混ぜない

対象	確認したこと	この発表の扱い
Park 1,000 人研究	v1 から v3 で題名・結果が更新	v3 2026-06-28 を使用。正規化値と明記
Socrates	HTML 要旨 36/15 と PDF26/13 に差	PDF Table 2 の 0.205→0.151 を採用
AS Benchmark	11 検査の論文と 8 項目のブログは別	11 検査はプレプリント。企業評価と分離
Nature 実験効果研究	出版社の要旨・公開説明を確認	購読本文全読・独立追試とは言わない
今回の証拠	既存フル実行の読取＋新規教材	模型の新規推論は 0 回

[R02] [R03] [R04] [R05] [E01] [D02]

補足｜ naïve の 9 試験：課題の単位

原ベンチマークと、公開比較の slice を混同しない

試験	期間・単位	主な結果
Clipping	約 30 日	精算済み模擬残高
Short Form	7 日／一部 30 日	模擬事業価値
Terminal	長時間・課題	自動テストの合否
SWE	15 課題 slice	コード修正の合否
Business	25 課題 slice	成果物の必須検査

費用を含めた比較も、同じ定義と範囲を揃えて読む。

補足｜ naïve の 9 試験：比較の注意

小標本・調整データ・掲載選別・乱数条件

試験	公開比較	注意
TheAgentCompany	10 課題	同じ課題で調整
PRDBench	5 課題	成功しきい値 0.25 ・掲載選別
YC-Bench	3seed ・一年	完了と利益は別
CoffeeBench	5 回・ 14 日	seed 不一致・元は 90 日

企業の説明にある留保も、成果と一緒に紹介する。

[N06] [N07] [N08] [N09]

補足｜P02-2： 十行は、十人ではない

架空の四人のログで、観測単位とラベルを区別する

数えたもの	値	何を意味するか
ログ配信行	10 行	観測の伝送記録
購入した人	2 / 4 = 50%	期間内の購入ラベル
返金差引支払あり	1 / 4 = 25%	期間末の支払い状態
入金純額	1,000 円	利益や満足ではない

実人間・実売上ではなく、今回動かした測定教材。

[D02] [R21]

主要参考文献 1/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載

[R01] Park et al. (2023), Generative Agents: Interactive Simulacra of Human Behavior
学術論文・ UIST 2023

[R02] Park et al. (2026 revision), LLM Agents Grounded in Self-Reports Enable General-Purpose Simulation of Individuals, arXiv v3
プレプリント v3 / 2026-06-28

[R03] Kolluri et al. (2025), Finetuning LLMs for Human Behavior Prediction in Social Science Experiments
EMNLP 2025 論文 PDF

[R04] Ashokkumar et al. (2026), Large language models can predict the results of social science experiments
Nature / 2026-07-08

[R05] Chidichimo et al. (2026), Artificial Societies Benchmark: A Validation Framework for Synthetic Research
プレプリント / 2026-09

[R06] Artificial Societies Benchmark — public code
公開リポジトリ

[R07] Aaru: Population simulation at the replication floor
企業自己報告 / 2026-09-24

[R08] Simile: Simulating human behavior
企業公式説明

[R09] Artificial Societies: Introducing Rothko
企業公式説明 / 2026-10-22

[R10] Listen Labs: Our intern built the first zero-person company
企業実験報告

[R11] Listen Twins
企業製品説明

[R12] humans&: Ampersand v0.1 Model Card
企業モデルカード / 2026-10-20

URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

主要参考文献 2/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載

[R13] humans&: Persimmon v0.1 Model Card

企業モデルカード / 2026-09-10

[R19] humans&: Build with Ampersand

公式 API 文書

[R20] Perdomo et al. (2020), Performative Prediction

ICML 2020 研究

[R21] Mokkink et al. (2010), COSMIN taxonomy

測定理論・合意研究

[R22] YC-Bench public CLI

公開リポジトリ

[N00] naïve: Benchmarks

企業公式比較

[N01] naïve: Clipping Bench

企業自己報告・模擬事業

[N02] naïve: Short Form Bench

企業自己報告・模擬事業

[N03] naïve: Long Horizon Terminal Bench

企業自己報告・実行基盤比較

[N04] naïve: SWE-Bench Pro

企業自己報告・実行基盤比較

[N05] naïve: Business Bench

企業自己報告・実行基盤比較

[N06] naïve: TheAgentCompany

企業自己報告・実行基盤比較

[N07] naïve: PRDBench

企業自己報告・実行基盤比較

[N08] naïve: YC-Bench

企業自己報告・実行基盤比較

[N09] naïve: CoffeeBench

企業自己報告・実行基盤比較

[E01] 2026-11-03 reproduction readback audit

既存実行ログの今回の読取・照合

[D02] P02-2 measurement exercise

今回新規実行した架空教材

URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

humans& を実際に動かす： 2 つの公開 API と別の Persimmon

製品を知ること・ API が動くこと・モデルの妥当性を証明することは別

Ampersand v0.1

架空チームの予定調整
同一セッションで 2 回の発言

622 字 + 750 字の実 API 出力

2 ターン・ 4 アイテムの保存を確認

Ampersand Tutor v0.1

架空の学習者に
「 40 人と 120 回答の違い」を説明

2,526 字の実 API 出力

教師としての正確性は未採点

※ Persimmon （模擬ユーザーモデル）は別製品・別アクセス。今回の API 実行とは混同しない。

出典： humans& API / PR #9157 / GitHub Actions 41630422469

公開データを使った人間予測： 48 件の小さな反例

公式の人物プロンプトとパーサを使用。実人間の条件差を、ローカル LLM は再現できなかった

質問の言い方による平均回答の変化



実際の差： +0.146 ／ローカル Qwen 予測： 0.000 。※ 48 件の探索的試行であり Rothko の比較ではない。

出典： AS Benchmark 公式コード / Jordan ら Harvard Dataverse / 2026-11-03 再現記録

補足｜Aaru の誤差と「信頼度」のトレードオフ

3 種類の TVD を混ぜない：対象と定義が異なる

全質問
7.62 pt
調整前 TVD 2,993 問

標本誤差近似を差引
5.98 pt
調整済み TVD 2,993 問

上位 51% だけ
4.54 pt
調整前 TVD 1,525 問

同じ「 TVD 」という文字でも、測っている対象が違えば比較できない。

確認：分析単位・分母・集約法・標本調整・ coverage ・未見条件

補足｜ Persimmon ・ Ampersand の学習と評価は別

一つの会社でもモデルの役割が違えば、正解の定義も変わる

人を演じる： Persimmon

本人らしい反応、情報開示、長い会話

支援する： Ampersand

質問、提案、待機、許可された実行

判断材料：モデル名ではなく「誰を演じ、何を採点したか」

実 API で答えが返った ≠ 人間の行動予測が正確 ≠ 実世界で良い介入ができる

Official: persimmon.humansand.ai/blog/persimmon.html / ampersand.humansand.ai/blog/model-card.html

補足｜明日、論文を読む人に聞きたいこと

「どれが一位か」ではなく、一般化と再現可能性を議論する

① データ
誰を調べ、何を観測した?

② 未知性
人・時期・研究をどう隠した?

③ 指標
分布・因果効果・利益のどれ?

④ 比較
同じ入力・計算費・権限か?

⑤ 不確実性
失敗や棄権を報告した?

⑥ 再現
独立した研究者が検査できる?

Sources in speaker notes / P03-7 article references, surveyed 2026-11-04

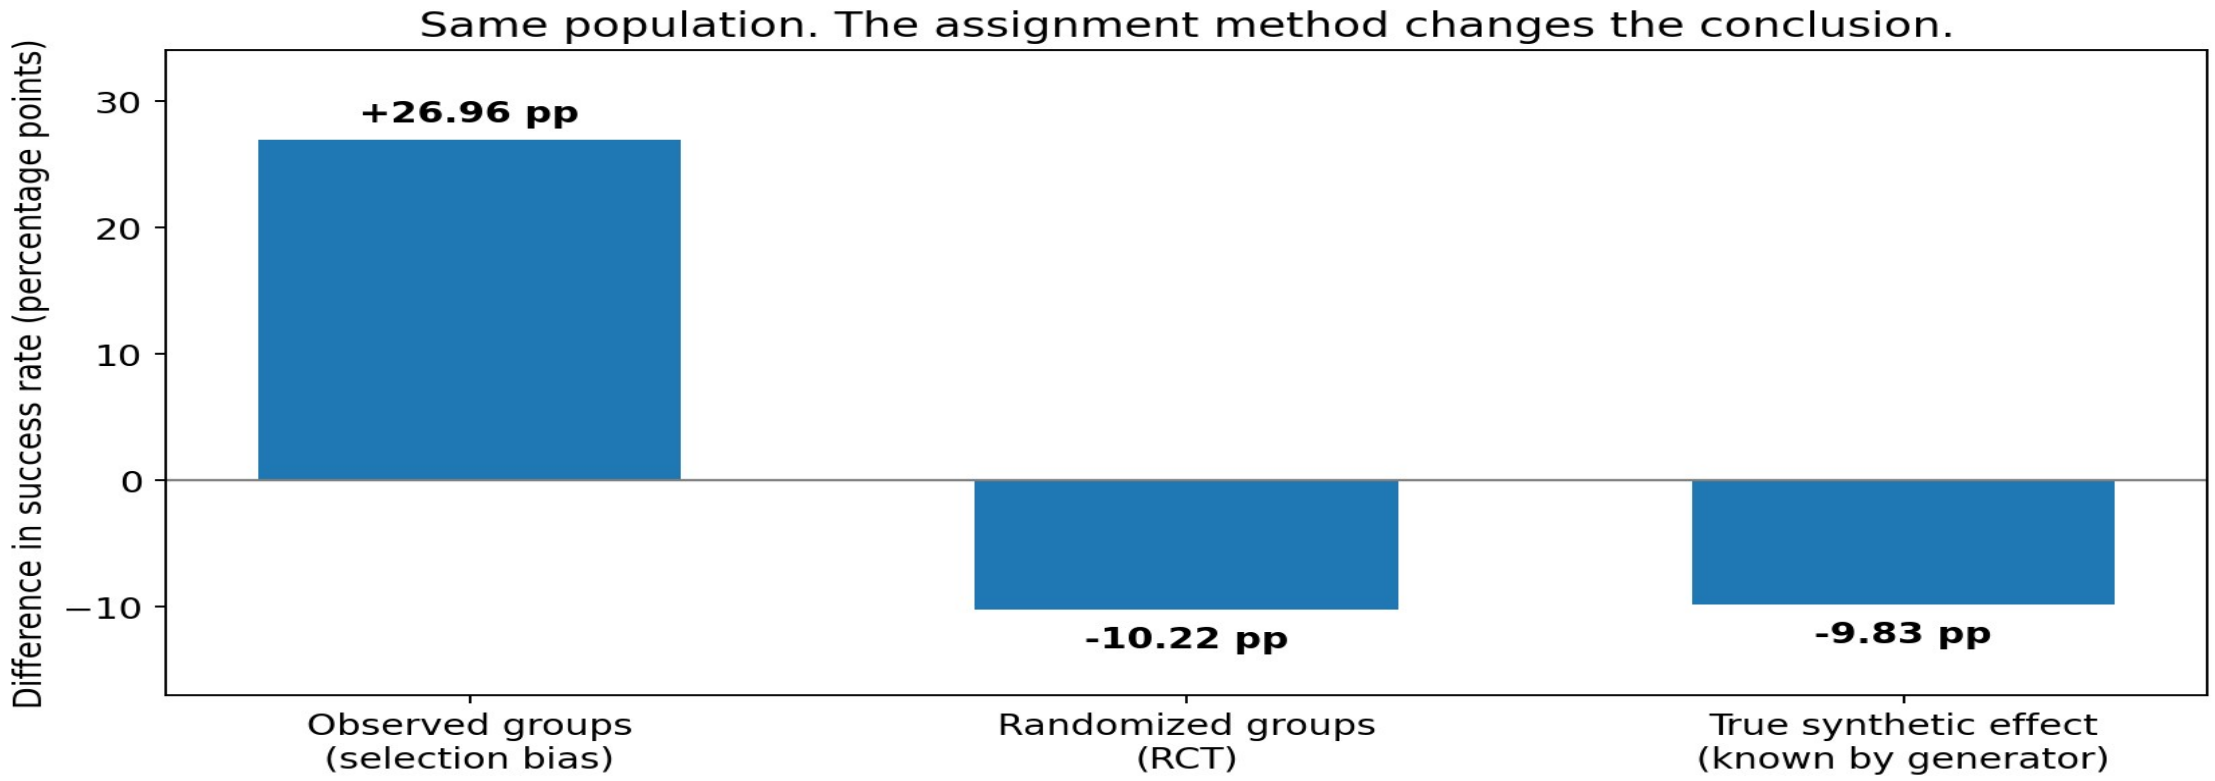
補足｜各ベンチマークで「まだ測れていないもの」

共通試験を組み合わせても、実世界の意思決定価値は独立に検証する

集団回答	SimBench / Human Behavior Bench	個人の実行動・因果効果
複数質問の関係	Artificial Societies / SSDataBench	実際の施策を選ぶ価値
未知研究の回答	SocSci210 / Socrates	無期限の汎化
未来の社会集計	Social Simulation Arena	個人の介入効果
現実の意思決定	独立 A/B ・対照実験が必要	別製品への自動一般化

観察した差と「実際に行動を変えた効果」は違う

同じ架空世界でも、誰が通知を受けるかの決め方によって結論が逆になる



出典： Hernán & Robins 『Causal Inference: What If』／Anicca 2026-11-04 架空計算

RCT の設計：何を無作為化し、何を比較するのか

ATE は介入そのものの平均効果。 ITT は「介入群へ割り当てる方針」の平均効果

① 介入前

対象者・時間窓を先に定義
同じ人は同じ割当
事前指標と許可を固定

何を変えたかを明確に

② 無作為に割り当て

Z = 1： 介入群
Z = 0： 比較群
割当を後から変更しない

何を知らずに決めたかが重要

③ 結果を計算

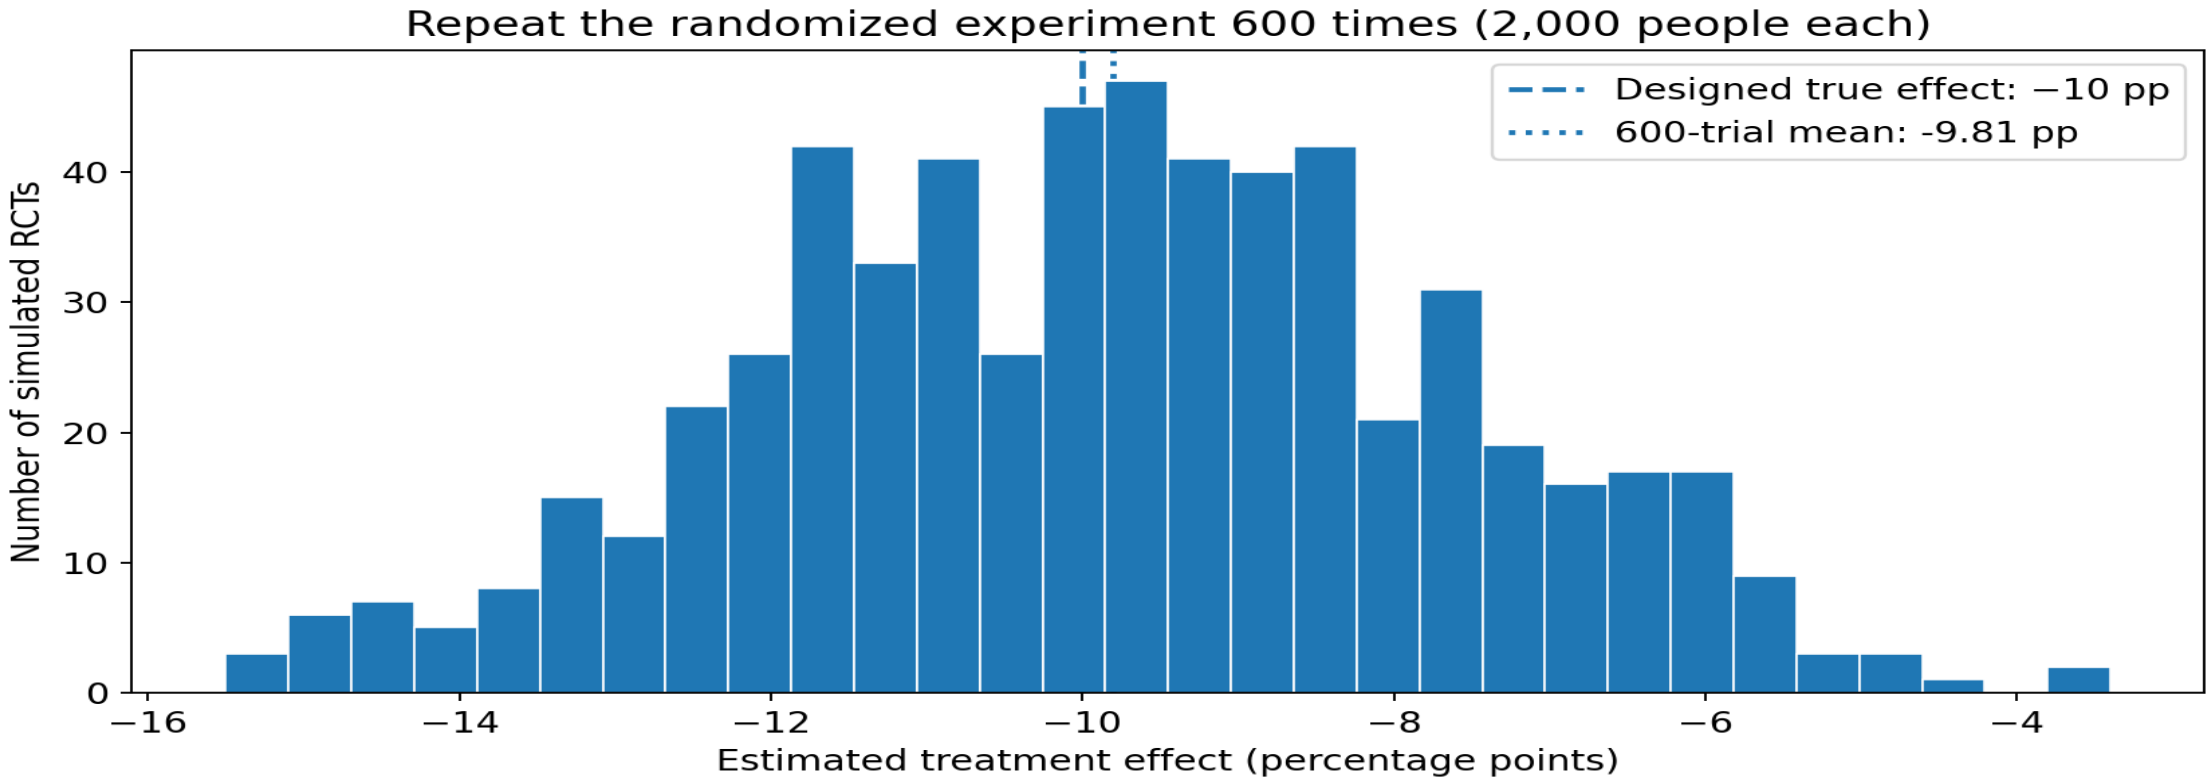
$ATE = E[Y(1)-Y(0)]$
$ITT = E[Y|Z=1]-E[Y|Z=0]$
SE ・ 95%CI ・害も報告

実際に受信したかだけで再分類しない

出典： Hernán & Robins ／ J-PAL Randomization ／ Anicca P04-2

同じ RCT を 600 回繰り返すと、効果推定はどう揺れる?

2000 人 ×600 回の架空 RCT： 真の設計効果− 10pt 、平均推定値− 9.81pt



出典： Hernán & Robins ／ J-PAL ／ Anicca P04-2 架空シミュレーション

交絡・媒介・ Collider： なぜ「全部調整」が危険か

因果構造を描いてから、調整してよい介入前変数を選ぶ

交絡（調整の候補）

A ← U → Y
介入前の共通原因 U

媒介（総効果では要注意）

A → M → Y
経路の一部を消す

Collider （条件付けに注意）

A → S ← U → Y
S=1 選択がバイアスに

潜在的結果　**$Y_i(1)$ = 通知したとき**　**$Y_i(0)$ = 通知しなかったとき**

ATE = E[Y(1) − Y(0)] 。同じ人の二つの結果を実データでは同時に観測できない。

RCT なしで効果を識別するための 4 条件

まず target trial を定義し、推定対象・処置・ time zero ・結果を先に固定

① 交換可能性

$(Y(1),Y(0)) \perp A \mid X$
未測定交絡がない仮定

② Positivity

$0 < e(X) < 1$
どちらの処置にも機会がある

③ Consistency

$Y = Y(A)$
処置内容・時間・結果を固定

④ 干渉への配慮

他者への通知が本人の結果を変えないか
口コミや集団効果に注意

仮定をデータ精度で証明することはできない。欠ければ「識別不能」と返す。

「同じ人の特徴」で比べ、元の人口構成に戻す

介入前 X で層別 → 層内比較 → 対象集団の P(X) で平均する

$$ATE = \Sigma_x P(X=x) \times [\, E(Y|A=1,X=x) - E(Y|A=0,X=x) \,]$$

高い意欲（ 50% ）

通知あり 70% − なし 80%
→ −10 ポイント

低い意欲（ 50% ）

通知あり 10% − なし 20%
→ −10 ポイント

観察差 **+26.12 pt**

標準化 ATE **−9.98 pt**

全て人工データ。欠けた交絡因子を自動で補うことはできない。

IPW と AIPW： どちらのモデルが何を補正するか

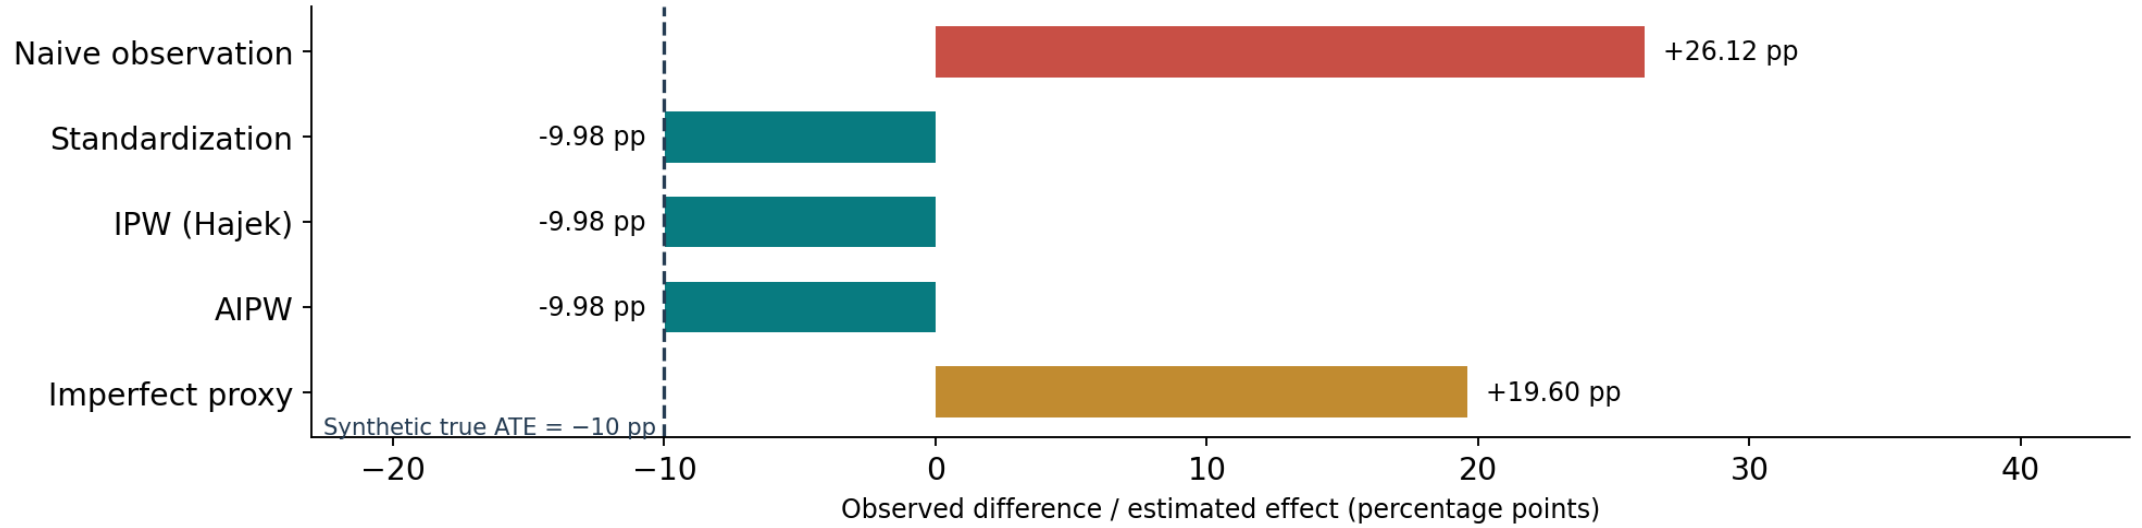
e(X)= 通知される確率 ／ $m_a(X)$= その行動をした場合の結果予測

IPW （重み付け）

起きにくい処置の観測を重くする
確率 e が 0/1 付近なら不安定

AIPW （二重ロバスト）

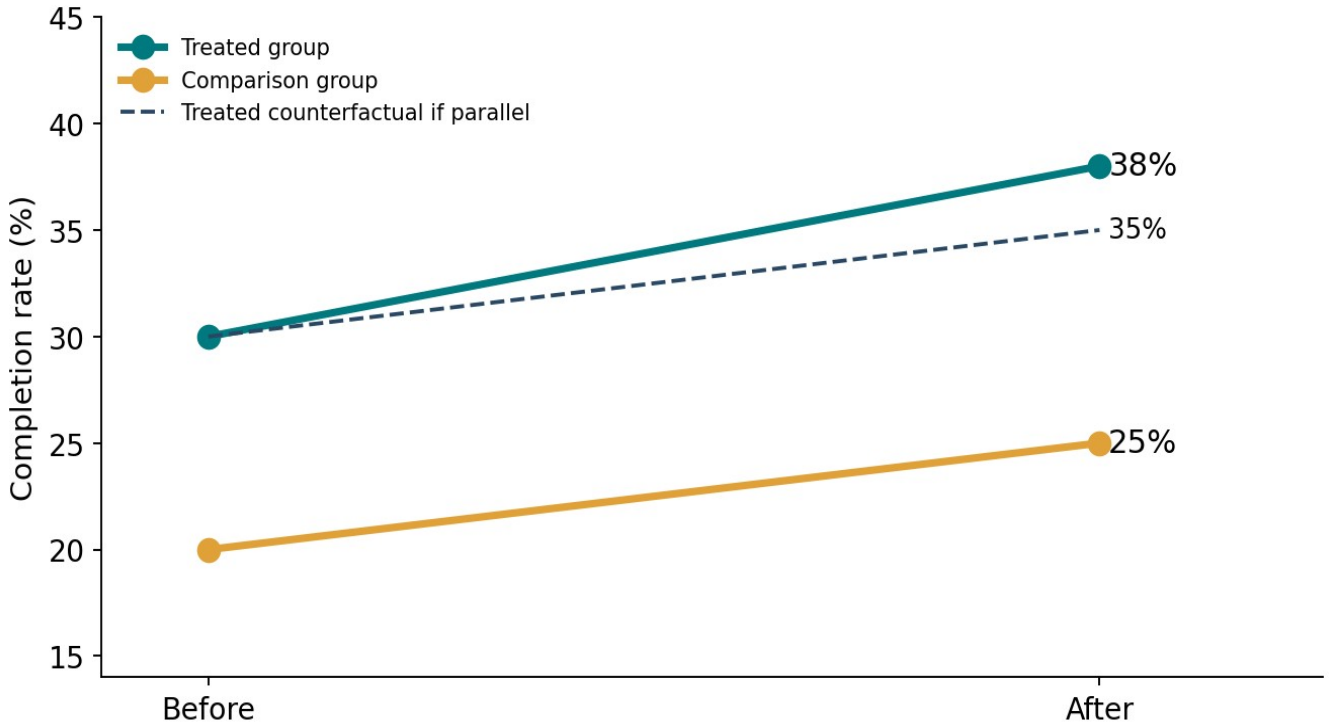
結果モデル m_a と選択モデル e を併用
未測定交絡は解決しない



P04-3 synthetic 30,000 / AIPW not cross-fitted

DiD： 施策前後の変化を比較する

介入後の単純差ではなく、非介入群の自然な変化を差し引く



介入群： 38 − 30 = +8pt

比較群： 25 − 20 = +5pt

DiD = +3pt

平行トレンド・同時ショック・導入時点の違いに注意

Synthetic 2x2 example only / Goodman-Bacon 2021; Callaway & Sant'Anna 2021

Manager の what-if に必要なのは「識別のゲート」

行動予測が高精度でも、それだけでは介入効果の根拠にならない

① Target trial
対象・時点・権限

→

② DAG / overlap
交絡・干渉・欠測

→

③ 反実仮想推定
g-formula / IPW / AIPW

→

④ 独立検証
RCT と害・費用

識別できないときは、 unknown / abstain を返す

P04-3： 人工 3 万人・ 26 テスト ｜ 実人間の因果効果：未検証 ｜ 次： P04-4 （誰に何が効くか）

ATE がプラスでも、全員に介入すべきとは限らない

24,000 人の完全架空 RCT： 介入前の意欲と疲労で効果が変わる

集団平均 ATE

真の ATE +2.92pt / 推定 +2.68pt

条件付き平均 CATE

特徴 X で条件づけた E[Y(1)−Y(0)|X]

低意欲の人

疲労低 +16pt
疲労高 +10pt

高意欲の人

疲労低 − 4pt
疲労高 − 10pt

本質：平均値が良くても、特定の状態では害になることがある

4 つの状態を、別々に推定する

群間差の推定は元の潜在結果生成式とおおむね一致する

状態	理論 CATE	推定 CATE
低意欲・疲労低	+16.0 pt	+17.67 pt
低意欲・疲労高	+10.0 pt	+9.82 pt
高意欲・疲労低	-4.0 pt	-4.54 pt
高意欲・疲労高	-10.0 pt	-11.36 pt

無作為化・事前に定めた 4 群で推定。これは個々人の確定的な効果ではない。

CATE を使い、介入すべき相手を選ぶ

未使用の架空 9,619 人に対して、方策を IPW で独立に評価

学習したルール

低意欲 → 通知する
高意欲 → 通知しない

比較対象

誰にも通知しない
全員に通知する

未通知方策に対する増分 +6.28 pt

近似 95% CI： +4.84 〜 +7.72 pt ｜ 人工世界の理論増分： +6.42 pt

学習と評価を分離しても、現実の人への効果や安全性は証明されない。

「誰に効くか」と「なぜ効くか」は別の問い

媒介分析： A→M→Y と、 A→Y の経路を分けて考える

介入 A

通知など
（この例は無作為化）

→

媒介 M

気づき・認知反応
（処置後の変数）

→

結果 Y

タスク完了
（この例は連続量）

直接 0.12 ＋ 間接 0.12 ＝ 総効果 0.24

注意：処置の RCT だけでは媒介から結果への因果効果は識別できない。

未知の『研究』を予測するベンチマーク

同一研究をまたいだリークを避けるため、 study ID で分割する

学習

90 研究：過去の介入効果から学習

検証

30 研究： Ridge の正則化を選択

未見研究（既知領域）

30 研究： ID は未見、領域は学習済

未見研究（新領域）

30 研究：生成規則に新たなシフト

個人レベルの train/test 分割だけでは、研究単位の汎化を測れない。

予測を先に固定し、それから正解を開く

重要なのは、精度を出す前に採点方法と利用可能情報を確定すること

① 事前情報

研究対象・介入・ baseline

② 予測

ゼロ・平均・ Ridge

③ 予測凍結

CSV + SHA256

④ 採点

保存後に gold を開封

人工 gold は別ファイル保存。本番ではモデル側から物理的にアクセス不能にする。

未知領域では、予測誤差が悪化する

MAE （ポイント、低いほど良い） ｜架空の未見研究 30 件＋ 30 件

予測方法	既知領域	新領域
常に効果 0	2.99 pt	5.77 pt
学習平均	2.27 pt	4.18 pt
Ridge 回帰	**1.55 pt**	**3.99 pt**

新領域の予測誤差は既知領域の約 2.6 倍： OOD 評価を分ける必要がある。

Manager が『現実の実験効果』を予測した証拠はまだない

人工ベンチマークの成功と、未見の公開 RCT での検証を区別する

今回できたこと

180 架空研究の再現可能な split ・凍結・評価
全 80 件の単体テスト成功

研究上まだ必要なこと

実公開 RCT の選定・権利検査
予測の事前登録と独立採点

P04-4： 講義＋人工実験完了
P04-5： 講義＋人工ベンチマーク完了／公開実験検証は未完了

次の講義： P04-6 事前登録・意思決定価値。 P04-5 の公開実験評価も継続。

J-PAL / Many Labs 2 candidate corpora; no empirical validation claimed

分析する前に、予測・仮説・評価方法を固定する

Pre-analysis Plan： 研究目的・対象・主要成果・比較方策・人数・分析規則

① 対象と比較

誰・いつ・何をするか／
介入の候補と権限

② 主要評価と停止規則

何を主要成果とするか／
固定標本数・多重性

人工結果を生成する前に計画 JSON を保存し、 SHA-256 を固定

ローカルのハッシュ保存は、外部機関に登録された RCT の代わりではない。

『施策』ではなく『施策を選ぶ方法』を RCT で比較

完全架空 40,000 人：双方に同じ事前特徴・候補行動を与える

Manager 型の方策

低意欲の人に通知

比較ヒューリスティック

低意欲・低疲労の人に通知

推定増分 +1.61 pt ／ 95%CI +0.69 〜 +2.54 pt

成果 − 通知負担 0.02 ／回 の合成効用を評価

比較相手は合理的な固定ルールだが、あらゆる方策の最強 baseline ではない。

結果を見ながら途中停止すると、偽陽性率が膨らむ

人工 A/A 試験 750 回：真の効果はゼロ、未補正の名目 5% 検定

最終 1 回の検定

偽陽性 4.27%

途中 6 回で有意なら成功

偽陽性 15.20%

途中解析は、群逐次法などで誤判定率を事前に制御できる

すでにある Ontology を組み合わせればいい

『行動を表現する』ことと、『現実を推定・検証する』ことは別

行動科学

COM-B ・ BCTTv1 （93 技法）
BCIO： 介入／対象／文脈

意味・証拠

JSON-LD ・ PROV-O
SHACL： 関係の検証

実行・通信

既存 Manager Core
MCP ・ A2A： 外部接続

BCIO で禁煙介入 971 アームを記述する先行研究あり。
Manager は新しい Ontology より、予測と実行・独立評価の接続を研究する。

Graph は証拠の投影。真実や実行権限そのものではない

予測・提案・送信レシート・観測結果・因果効果を混同しない

観測	推測	候補	receipt	readback
時刻と出典	確信度とモデル版	NO_ACTION も残す	送信≠効果	独立観測

実行許可は Graph から発生しない。
元の ledger と独立した権限・結果確認が正本。後知恵の情報リークを防ぐ。

共通の ID をつなぐ。でも新しい権限は作らない

既存 Job → Effect → Receipt → RuntimeEvent を同じスコープと時点で追跡

Job	Effect	Receipt	Runtime
job_id effect_key	effect_id idempotency_key	receipt_id effect_id	event_id run_id

予測 ID ・判断 ID は既存共通レコードの必須項目ではない。
欠落を勝手に埋めず、 Receipt≠ 人間の改善として扱う。

Listen Labs API へ認証付き GET： HTTP 200

TinyFish で実ブラウザーを操作し、 Mac mini で Study API へ読み取り接続

実 API で確かめたこと

GET /wallets → HTTP 200
GET /studies → HTTP 200
作成・公開・課金・回答保存： 0

人工契約実験で確かめたこと

run ／ effect ／ receipt を厳密に照合
別テナント・時間リークを拒否
P05-2 新規 48 件／累計 193 件 PASS

Listen Twins の予測 API は未確認。
本番発表 33 枚は変えず、研究付録として保存する。

Planner は『許可する人』ではない

複数 AI の提案→独立した権限→限定 Executor

Planner

行動候補・ What-if
実行権限なし

Authority

issuer ・範囲・期限
予算・失効

Executor

署名許可と操作を照合
重複防止

6 つの権限外操作を拒否。 fixture の署名は本番認証・本人の同意ではない。

タイムアウト＝失敗とは限らない

送信後の UNKNOWN は再送せず、元の操作キーで独立に照合する

間違った復旧

タイムアウト → もう 1 回送る
同じ操作が 2 回起きる危険

今回動いた安全な経路

UNKNOWN → readback → PRESENT
同じ key の send は 1 回

独立した人工センサーの確認も P0 。人への因果効果は別に測る。

Shadow で比べてから、実行範囲を一つずつ広げる

現場の成果と AI の提案を分ける。稼働率より誤実行を防ぐ。

S0 テスト

型・権限・重複
オフラインで成功

S1 Shadow

候補を同条件で比較
本番 write なし

S2 限定 Live

自社所有・可逆な 1 操作
正規許可と独立確認

今回は S0 と既存 Shadow テストまで。実業務 S1 ・本番 S2 は未実施。

Existing manager_core.owned_provider_shadow; 41 tests

モデル公開と、会社運営と、人の改善は別の進行線

独自重みの完成を待たず、既存 AI を使う Manager の制御層から検証する

会社の Engine

Shadow → 1 つの限定操作
→ 比較して範囲拡大

Behavior Model

Qwen/LoRA 研究 → 権利と
独立評価 → 公開可能な重み

実際の行動変容

本人の希望と同意 → 尺度
→ 比較実験 → 長期再現

本当の価値＝実際に使われる製品・費用込み利益・本人の便益と害。
未実証の数字は実績と呼ばない。

何人必要? いつ結果を見てもよい?

サンプル比率・事前計画・途中停止を同時に固定する

必要標本数

架空の 25% → 28%
各群 3,395 人

4 回の無補正のぞき見

人工 A/A の偽陽性
11.92% （2400 反復）

正規の品質検査

SRM ・停止・ Guardrail
外部の結果確認

全て人工の設計例。実参加者 0 ／外部の事前登録なし。
本番は Statsig など既存の逐次検定・品質 Gate を再利用する。

statsmodels NormalIndPower / SciPy chisquare & A/A simulation

利益が増えても、苦情が増えれば採用しない

購入・返金・原価・運用・推論・害を同時に評価

人工の貢献利益

+56.84 円 / 割当
95%CI +36.55 〜 +77.12 円

人工の苦情・停止率

+0.942 ポイント悪化
許容悪化は +0.3 ポイント

判定： DO NOT SHIP 。利益だけでなく Guardrail を満たす必要。
実際の会社利益・実ユーザーの影響は未測定。

30,000 synthetic assignments / SciPy Welch t-test

実績は『独立した証拠』からつくる

観測できた事実と、まだ測れていない人の便益を混ぜない

人工研究

凍結計画 9 ファイル
ハッシュ照合 OK

実公開サイト

Manifest + HTML6
配信・ハッシュ確認

本当の便益

利益・反すう
NOT MEASURED

Phase 6 の講義・人工実験は完了 → 次は P07 。
本番の S1/S2 ・実会社 / 人間への介入効果は未完了。

Reward alone does not fully explain choices

Same real trials, disjoint participants, held-out experiments

Reward-only

Log loss 0.5108
Expe1: 10,461 held-out trials

Habit-only

Log loss 0.6874
Same held-out trials

Reward+Habit+Memory

Log loss 0.4866
Best validated model

5 real experimental datasets | 269,603 eligible observed trials
Prediction only: does not establish a psychological mechanism or benefit.

Repeating an action is not proof of a habit

Observed repeated choices after NO reward, split by feedback type

Mostly deterministic feedback

After no reward:
Low load 9.3% | High load 21.4%

Probabilistic feedback

After no reward:
Low load 50.7% | High load 48.3%

No reward ≠ wrong choice in a stochastic world.
X posting: 2,696 real users; hybrid reward+habit studied independently.

Collins WMH (2026); Turner et al. Nat Commun (2026)

The same action can reflect different inner states

Observe behavior and self-report; infer attention, affect and thoughts probabilistically

Observations

Choice / response time
Experience sampling / EEG

Latent hypotheses

Attention / affect / awareness
Rumination / worry

Evaluation

Hold out people and time
Check probes and uncertainty

Mind wandering ≠ rumination ≠ harm.
Predictive state inference is not a validated intervention.

Forecast next self-report — with real people

Participant-disjoint heldout tests; strong last-value baseline

Brooding / rumination-related

40 people | 1,450 transitions
RMSE: 30.80 → 25.98

Stress / affect — distinct label

100 people | 6,890 transitions
RMSE: 27.30 → 24.54

Self-reports forecast only. No mind-wandering probe/EEG was analyzed.
No real intervention or reduced rumination demonstrated.

OpenESM Hoebeke (2022), Dejonckheere (2019) | CC BY 4.0

COM-B

Why desired behavior does not happen

CAPABILITY	**Physical / Psychological** Skills, knowledge, attention, physical ability
OPPORTUNITY	**Physical / Social** Time, environment, resources, supportive peers
MOTIVATION	**Reflective / Automatic** Values, goals, learned cues, emotions & habit

COM-B is a diagnosis framework, not a verified individual causal mechanism.

Behavior-change technology has reusable parts

Never confuse intervention function, technique, and delivery channel

FUNCTION

What kind of intervention?

Training, education, enablement, environmental restructuring

TECHNIQUE

What exactly changes?

Action planning 1.4, prompts/cues 7.1, social support 3.1

DELIVERY

How is it delivered?

Voice, calendar, peers, physical environment; permissioned

93 BCTTv1 techniques • BCIO: machine-readable evidence context • efficacy is not inherited

Michie et al. (2011, 2013); Human Behaviour Change Project

Predicting action is not predicting intervention impact

A known next-action probability does not identify a causal response

PREDICTION

P(Y | history)

Who will act?

CAUSAL EFFECT

P(Y | do(action))

What changes if we intervene?

A safe policy compares benefits, costs and harms — including NO_ACTION.

A benchmark is a scientific instrument

Independent tracks; strong baselines; study-disjoint holdouts

01 CHOICE	Log loss / Brier / ECE	P07-1 previously measured
02 LONGITUDINAL STATE	RMSE / MAE / subject bootstrap	P07-2 previously measured
03 HUMAN DISTRIBUTION	TVD / subgroup calibration	Not yet measured
04 CAUSAL RESPONSE	Heldout RCT effect error, ITT	Real out-of-study RCT pending
05 SAFE POLICY	NO_ACTION / cost / harm	No human policy trial
06 REAL BENEFIT	Goals / autonomy / burden	No independent RCT

Do not mix benchmark fixture tests with real-human results or causal welfare.

The Behavior Foundation Model starts with evaluation

No shared-weights foundation model trained yet; credible steps must be earned

NOW • B0	Baseline scorer, leakage checks, 13 synthetic software tests passed
NEXT • B1	Replay P07-1/P07-2 actual public-data benchmarks with rights audit
BUILD • B2–B3	Shared temporal model; unseen-study transfer; Centaur/BeFM comparisons
CAUSE • B4–B5	Licensed randomized interventions, consent, harm and durable benefit
OPEN • B6	Community OSS harness; external replication; honest model cards

NEXT CLASS: P07-4 CBT / ACT. P07-5 Vipassana. P07-6 welfare and harm.

A message is not a result. Walking is.

Actual micro-randomized intervention and measured next-30-minute steps

ACTUAL PEOPLE

37

6 weeks, original micro-randomized study

DECISIONS

8,274

6,590 marked available for intervention

ESTIMATE

+12.95 steps

95% participant bootstrap: -16.99 to +39.43

Exploratory complete-case contrast only. Missing tracking data; CI includes zero.
Not the paper's adjusted estimand. Not a Manager product trial.

Source: Klasnja et al. (2019) | klasnja/HeartStepsV1 | own GitHub Actions run 42099736589

Quality of life can be measured in real trials.

Public RCT Bench has expanded from 50 to 125 individually randomized trials.

TRIAL 20	Walking exercise adherence	+345 min / 12 weeks 95% interval [+17, +688]
TRIAL 103	Observed 90-day QALY	+0.0110 95% interval [-.0054, +.0289]
TRIAL 116	FACT-G quality of life	Group2 - Group1 +8.02 95% interval [-2.70, +19.44]

Different populations and units. Trial 116 treatment coding not yet verified.

Source: Bingkai Wang RCT Bench / trials 20, 103, 116 | own cloud run 42099736589

An intervention predictor already existed.

405 studies / 971 smoking-cessation trial arms; ontology-annotated real data.

TRAIN-FOLD MEAN	**9.99 pp**	Simple baseline
RIDGE	**9.65 pp**	Shared linear predictors
RANDOM FOREST	**9.45 pp**	Best of three in this reproduction

Study-disjoint MAE, lower is better. Authors reported RuleNN 9.15 pp under a different protocol: not a head-to-head comparison.

Source: Human Behaviour-Change Project semantic-prediction | run 42100293105

Introducing Manager: useful first.

Reuse existing models, effect estimators, evidence and safe execution.

1 / UNDERSTAND	Centaur / Be.FM / actual observed behavior
2 / CHOOSE	COM-B / BCIO / HBCP / NO_ACTION
3 / EXECUTE	Permissioned Manager Core, stop and revoke
4 / VERIFY	HeartSteps / RCT Bench / HBCP / user welfare

Model + product, not an endless research-only prototype. No Manager RCT yet.

INTRODUCING MANAGER / BEHAVIORAL FOUNDATION MODEL

Understand. Simulate. Improve.

Reuse the giants. Measure the difference. Ship only what helps.

UNDERSTAND

Existing models

Centaur / Be.FM

Predict choices and human states

SIMULATE

Social systems

Simile / Societies / ABM

Test hypotheses, not truth claims

INTERVENE

Prior RCT evidence

HBCP / HeartSteps

Estimate effects, respect NO_ACTION

VERIFY

Outcome evaluation

BehaviorBench / RCT Bench

Measure outcomes, uncertainty and harm

MODEL PRODUCT / OPEN-WEIGHT MANAGER IN DEVELOPMENT / NO MANAGER USER-BENEFIT RCT YET

The vocabulary is part of the product.

Six core terms everyone should understand before benchmarking a model.

FOUNDATION MODEL	Reusable learned representations across many tasks
INFERENCE	Run an already-trained model on new input
RCT / MRT	Random assignment once / at repeated daily moments
CAUSAL EFFECT	Outcome difference caused by an intervention, not correlation
QALY	Lifetime weighted by health-related quality of life
COM-B / BCT	Why behavior fails / reusable intervention techniques

Sources: Michie et al. COM-B; Klasnja et al. HeartSteps MRT; BehaviorBench; HBCP

Learn → Run → Measure → Integrate → Ship → Publish

One work queue, one definition of done—not separate research and engineering tracks.

NEXT · BFM-01	Be.FM 1.5-4B GPU inference vs Qwen3 base; authorized and logged
VERIFY	Licensed human holdout, calibration, model revision, real cost
INTEGRATE	Read-only model response in permissioned Manager product
SHIP + MEDIA	Usable bounded feature and source-backed EN/JA article + FAQ + slides

Be.FM access + cloud credentials still needed; NO independent Manager benefit RCT yet.

From behavior triggers to values-aligned actions

CBT and ACT overlap, but their core intervention questions differ

CBT

Thoughts, feelings and behavior

Behavioral activation, experiments, examining interpretations

ACT

Psychological flexibility

Acceptance, defusion, present moment, self-as-context

VALUES

Chosen direction and committed action

One meaningful user-chosen next step, with permission to rest

Evidence for therapy is NOT evidence that Manager treats distress.

An opt-in plan is not an autonomous intervention.

Reuse the Habit Designer; connect only the missing permission gate

USER CHOICE	Self-chosen value, anchor, tiny action, 1–5 minutes
REUSE	Existing Habit Designer JSON with safe_t_flag
SAFETY	No consent / revoked / unavailable / clinical -> NO_ACTION
READ-ONLY	Explicit nonclinical case -> DRAFT_ONLY, zero external effects
EVIDENCE	Software 15 tests passed; no human-benefit trial

NEXT CLASS: P07-5 Vipassana / suffering. BFM-01 stays active in the ONE roadmap.