JOURNAL CLUB · 2026.11.05 13:00–14:00 JST

# AI は人間の行動を どこまで再現できるか?

人間模型・行動介入・社会的協働・事業エージェントを「測定」から読む

人間データ | シミュレーション | 介入 | 評価

成田 大祐 ｜ 人間行動・協働・事業エージェントの方法と評価

# 今日の問いは、三つ

分野の整理 → 代表論文 → 評価の落とし穴 → 今後の研究

01

## 何をシミュレーションしている?

個人の回答／選択／相互作用／長期の変化

02

## 何をもって「正しい」とする?

自然さ、分布、個人差、介入効果は別

03

## 現実の意思決定へ使える?

比較対象・不確実性・移植・害を見る

# 二つの「エージェント」を混ぜない

人を演じる模型と、人のために行動する AI は別の役割

### 人間・世界モデル

**「どう反応しそうか?」**

プロフィール＋履歴＋状況 → 反応の分布

### 方策・実行エージェント

**「何をするべきか?」**

目標＋予測＋制約 → 発言・変更・待機

[R12] [R13]

# 人間行動シミュレーションの共通構造

人口を作るだけでは、行動モデルは完成しない

01 実人間の情報 › 02 個人・集団の表現 › 03 反応モデル › 04 相互作用・時間 › 05 集計・比較

参照データと照合し、適用範囲を更新する

**観測データで検証し、模型に戻す。すべての方式が全層を持つわけではない。**

[R01] [R02] [R07]

# 方法の違いは「何を学び、何を固定するか」

排他的な五択ではなく、組み合わせる設計要素

| 系統 | 主な表現・入力 | 強み／主な検証課題 |
| --- | --- | --- |
| **統計・選択モデル** | 数値特徴、選択肢、効用 | 単純な基準／未知の文脈への移植 |
| **エージェントベース** | 状態・規則・ネットワーク | 相互作用／規則の根拠 |
| **LLM ＋ペルソナ** | 属性・指示・会話 | 言語の柔軟性／型にはめた反応 |
| **インタビューで個人を表現** | 本人の自己報告・記憶 | 個人固有の文脈／未知の結果 |
| **行動データで追加学習** | 実験・調査・行動の記録 | 共有表現／リークと一般化 |

[R01] [R02] [R03] [R09]

# 「よいアシスタント」と「忠実な人間模型」は同じではない

もっともらしい説明 ≠ 実際の選択を生む原因

## 使える力

知識・言語・文脈を広く扱える

未知の質問を、自然言語で与えられる

## ずれ得る目的

迎合や一貫性が、人の反応を歪める可能性

個人差や揺らぎを平均化する可能性

[R05] [R09]

# 起点① Generative Agents： 記憶から行動へ

Park et al., UIST 2023 ｜ 25 体のエージェントの仮想社会

01 観察 › 02 記憶ストリーム › 03 関連記憶を検索 › 04 振り返り・計画 › 05 行動

参照データと照合し、適用範囲を更新する

**示したのは、構成要素が「もっともらしい振る舞い」に寄与すること。**

[R01]

# 起点② 実際の人の情報で個人模型を作る

Park et al., arXiv v3 （2026-06-28） | 1,052 人の米国成人

01 本人の情報 › 02 面接／調査／両方 › 03 LLM へ文脈として入力 › 04 隠した項目を予測 › 05 本人の回答と比較

参照データと照合し、適用範囲を更新する

**新しい人の予測とは限らない。「本人の未提示の結果」を何で測ったかが重要。**

[R02]

# 「86%」は、生の正答率ではない

本人の 2 週間後の再回答一致率に対する正規化値｜ GSS の未提示項目




**分母・正規化・対象項目・論文の版を読む。 1.00 はこの評価の本人再回答基準。**

[R02]

# 起点③ Socrates： 反応を追加学習する

Kolluri et al., EMNLP 2025 | SocSci210

01 210 の公開実験 › 02 条件＋属性＋回答 › 03 事前学習済み LLM › 04 SFT ／ DPO 等 › 05 未見の研究で評価

参照データと照合し、適用範囲を更新する

**約 290 万回答・ 400,491 参加者。「行数」と「人数」と「研究数」は別。**

[R03]

# 追加学習の効果は、指標ごとに読む

Socrates ・ PDF Table 2 ｜未見研究の正規化 1-Wasserstein 距離（低いほどよい）




**0.205 → 0.151： 距離が約 26.3% 減少。正答率が 26.3 ポイント上がったのではない。**

[R03]

# 起点④ 条件間の差を予測する

Ashokkumar et al., Nature 2026 ｜社会科学実験の効果予測

**データ**

## 70 実験／ 469 効果

事前登録された米国調査実験。119,330 参加者。

**方法**

## 刺激を条件別に提示

模擬回答の条件間差から、介入効果を予測。

**重要な限界**

## 相関は高いが過大推定

強い相関だけで、効果の大きさが正しいとは言えない。

[R04]

# 企業の違いを、入出力と検証から読む

ここは企業公式説明。原理の比較であり、独立した性能ランキングではない。

| 組織 | 公表している主なアプローチ | 読むべき未確認点 |
| --- | --- | --- |
| **Aaru** | 人口を構成し、非 LLM の中核行動モデルで応答 | 対象範囲・時間制約・分布と実行動 |
| **Simile** | 実人間データで行動モデルと信頼度を学ぶ | 信頼度の検証・データ更新・移植 |
| **Rothko / Artificial Societies** | 事前学習モデルを変更し、意思決定を出力 | 非公開の構造・学習データ・独立再現 |

[R07] [R08] [R09]

# Listen Labs： 速い模型と、現実のフィードバック

Twins と StyleFits の報告は、別の証拠として扱う

### Listen Twins

## 実人間に対応する模型

インタビューを入力し、隠した回答と比較。出典・信頼度を提示。

### StyleFits 実験

## 調査 → 開発 → 実ユーザー → 修正

約 2,000 インタビュー。売上 $1,293 、広告 $2,000 。人の介助あり。

[R10] [R11]

# humans&：人間模型で支援モデルを訓練する

模擬ユーザーと方策を分ける、具体例

Persimmon

## 人間側の反応を生成

履歴・プロフィール・状況 → 会話の続きを生成

Ampersand

## 支援の行動を学ぶ

長期の模擬社会シナリオで RL 。発言する／待つ。

[R12] [R13]

# Persimmon： 人間らしさを五つに分ける

評価名だけでなく、何を人間の参照にしているかを見る

| 試験 | 主に観察するもの | 主張の限界 |
| --- | --- | --- |
| **Multi-User Turing** | 本物／生成の会話群の識別 | 個人の未来正答率ではない |
| **Profile Turing** | プロフィールと会話の対応 | 内心の読取ではない |
| **User-Sim Index** | 文体・質問・情報・誤りへの反応 | パターン依存 |
| **Trickle Test** | 情報の段階的な開示 | 生成情報の真実性とは別 |
| **Long Context** | 長い会話の整合性 | 人への長期利益とは別 |

**会話の自然さ・整合性・実行動の予測は、別の評価対象。**

[R13] [R23]

# Ampersand： 支援の結果を、長い時間で測る

訓練環境のユーザーモデルと採点者への依存を検査する

訓練

## 長い社会的やり取り

Persimmon の反応から学ぶ

行動

## 発言・ツール・待つ

多く動く＝よい支援ではない

外部検証

## 未知の相手と状況

模型・ grader への適合を点検

**模型内の協働得点から、実人間の便益へは別の証拠が必要。**

[R12]

# 「人間らしい」から「役立つ」まで、証拠は飛べない

一つの点数で、すべての主張を代用しない

| | |
|---|---|
| **自然さ** | 会話や物語としてもっともらしい |
| **分布・個人** | 割合、ばらつき、同じ人の回答を再現する |
| **構造・効果** | 回答の関係、条件を変えた差を再現する |
| **意思決定** | 同じ予算で、よりよい選択をする |
| **現実の結果** | 実際の利益・生活・負担・害を測る |

[R01] [R02] [R04] [R05]

# ベンチマークは、データセットだけではない

問いと採点条件を固定する「試験の設計書」

## 課題

何を予測・選択する?

## 参照データ

何を正解の根拠にする?

## 分割

何を未知として残す?

## 入力・実行

情報、ツール、回数、予算

## 比較対象

単純模型と強い既存法

## 指標・集計

単位、重み、欠測、失敗

## 不確実性

人・研究単位での変動

## 再現条件

版、コード、出典、費用

[R05] [R16]

# 一問ずつは完全一致。しかし、組み合わせは逆

教育用：質問 A と B 、各 100 人。 1= はい／ 0= いいえ。

## 参照集団

| | B=0 | B=1 |
|---|---|---|
| A=0 | 50 人 | 0 人 |
| A=1 | 0 人 | 50 人 |

## 人工集団

| | B=0 | B=1 |
|---|---|---|
| A=0 | 0 人 | 50 人 |
| A=1 | 50 人 | 0 人 |

**各質問の周辺 TVD は 0 。同時分布の TVD は 1 。割合だけでは「誰が何を答えたか」が消える。**

[D01] [R05]

# 正しい方向でも、効果量を外す

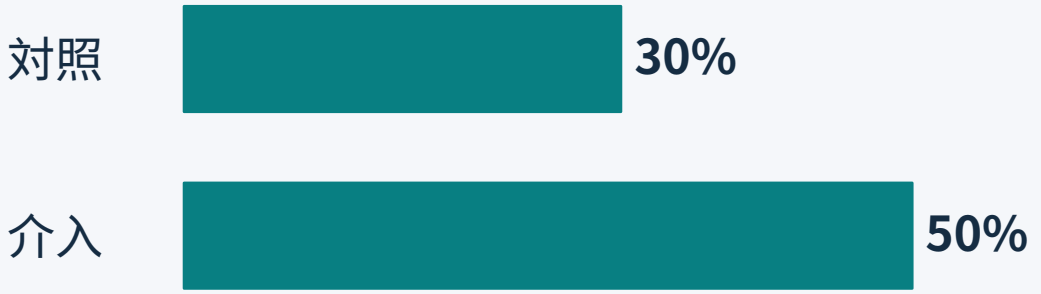
架空例：対照から介入後への結果の変化

## 参照




**差： +8 ポイント**

## 模型




**差： +20 ポイント**

**参照： +8 ポイント。模型： +20 ポイント。効果の絶対誤差は 12 ポイント。**

[D01] [R04]

# AS Benchmark： 11 の検査で用途を確かめる

Chidichimo et al., 2026 preprint ｜ 20 人間データソース、 9 つの汎用 LLM

## 回答過程（ IV ）

IV-1 同じ質問の繰り返し

IV-2 関連項目の論理

IV-3 言い換え

IV-4 順番・形式の変更

## 測定構造（ CV ）

CV-1 項目間の共分散

CV-2 外部基準との関係

CV-3 異なる特性の区別

## 人口・実験（ EV ）

EV-1 回答分布

EV-2 個人・部分集団

EV-3 実験効果

EV-4 因子・測定構造

※ IV は本論文の回答忠実性の診断分類。因果識別そのものを保証する用語ではない。

[R05] [R06]

# 公開コードを、入出力の流れとして読む

データの意味は、提示・解析・欠測処理の実装にも宿る

01 課題・人物 › 02 提示・収集 › 03 解析・欠測 › 04 指標と比較 › 05 スコアカード

参照データと照合し、適用範囲を更新する

**正常に終了したことと、人間を正しく予測したことは別。**

[R06]

# AS 再現：公開された計算経路を確認する

本日作成済みの Mac 実行ログ・ XML ・出力レシートを今回照合

| 検査 | 確認した記録 | 言える範囲 |
| --- | --- | --- |
| **環境・全テスト** | 68 成功／ 7 スキップ | 元個票が必要な 7 件は残る |
| **スコアカード** | 7,128 セルの行内容一致 | 保存済み集計からの再構築 |
| **図** | 10 図 × PNG/PDF | PDF デバイスを移植 |
| **新規模型推論** | 0 回 | 模型の性能比較は未実施 |

**既存実行の照合。今回、全推論を新しく実行したという報告ではない。**

[R06] [E01]

# 「再現できる範囲」を正確に切り分ける

専有モデルへの認証と、公開コードの実行は別の問題

| 対象 | 確認した範囲 | 別に必要なもの |
| --- | --- | --- |
| **AS Benchmark** | 固定環境・全テスト起動・再集計 | 元調査データ／新規回答 |
| **Ampersand** | 公式 SDK 準備、API401 | 許可されたアカウントのキー |
| **Persimmon** | 公開方法・評価・制限 | 利用承認と再現用の資料 |
| **内部ベンチ全体** | 公開説明を検討 | シナリオ・ grader ・原出力 |

**未知の部分を埋めたふりをしないことも、再現研究の成果。**

[R19] [R06] [E01]

# naïve： 二つのベンチマーク群

同じモデルで実行基盤を替えるか、同じ基盤でモデルを替えるか

**モデル比較**

## 同じ環境・違う模型

Clipping ／ Short Form

**実行基盤比較**

## 同じ模型・違う実行系

業務・コード・会社運営

**共通の問い**

## 何を完成と呼ぶか

成功・費用・失敗の単位

**企業名やモデル名だけの順位表では、改善の原因は分からない。**

[N00]

# Clipping Bench： 模擬メディア事業の一か月

単発の投稿ではなく、権利・時間・疲労・遅れた入金を扱う

01 素材・案件 › 02 編集・選択 › 03 投稿・状態 › 04 審査と保留 › 05 精算と費用

参照データと照合し、適用範囲を更新する

**高いゲーム残高は、実際のプラットフォームでの入金証拠ではない。**

[N01]

# Short Form： 売上ではなく、状態と負債も読む

投稿・店舗・在庫・顧客・スポンサーを一つの環境へ

**経済**

## 現金＋資産−債務

売上だけで採点しない

**運用**

## 重複入金・在庫・顧客

状態を独立に照合する

**価値**

## 不具合への対応

金額順位＝良い行為ではない

**人への利益と経済的な得点は、同じ指標へ押し込まない。**

[N02]

# 業務ベンチマーク：実行系を比較する

模型を固定して、完成率・時間・費用を測る

| 課題群 | 主な検査 | 分けて読むもの |
| --- | --- | --- |
| **Terminal / SWE** | コマンド・コードの完成 | 時間枠・課題 slice |
| **Business Bench** | 提出ファイルの検証 | 25 課題の比較 |
| **TheAgentCompany** | 複数業務ツールの完了 | 全完了と部分点 |
| **PRDBench** | 要件別の採点 | judge と成功しきい値 |
| **YC / Coffee** | 長期状態・資金・納期 | 模擬日数・背景役・ seed |

**同じ模型で差が出ても、それは「重みを学習して改善した」証拠とは限らない。**

[N04] [N05] [N06] [N07] [N08] [N09]

# 比較表の脚注が、研究の解釈を変える

naïve が自ら明記している限定条件を読む

### TheAgentCompany

**同じ課題で調整**

未見課題の結果ではない

### CoffeeBench

**14 日・異なる seed**

対応した公平比較ではない

### PRDBench

**掲載対象の選別**

全競合の順位表ではない

**公開された限定条件を省略せず、比較の範囲を伝える。**

[N06] [N07] [N09]

# YC-Bench： 環境を一周させることの価値

本日分の既存記録：公開 CLI を非 LLM 方策で一年間運転

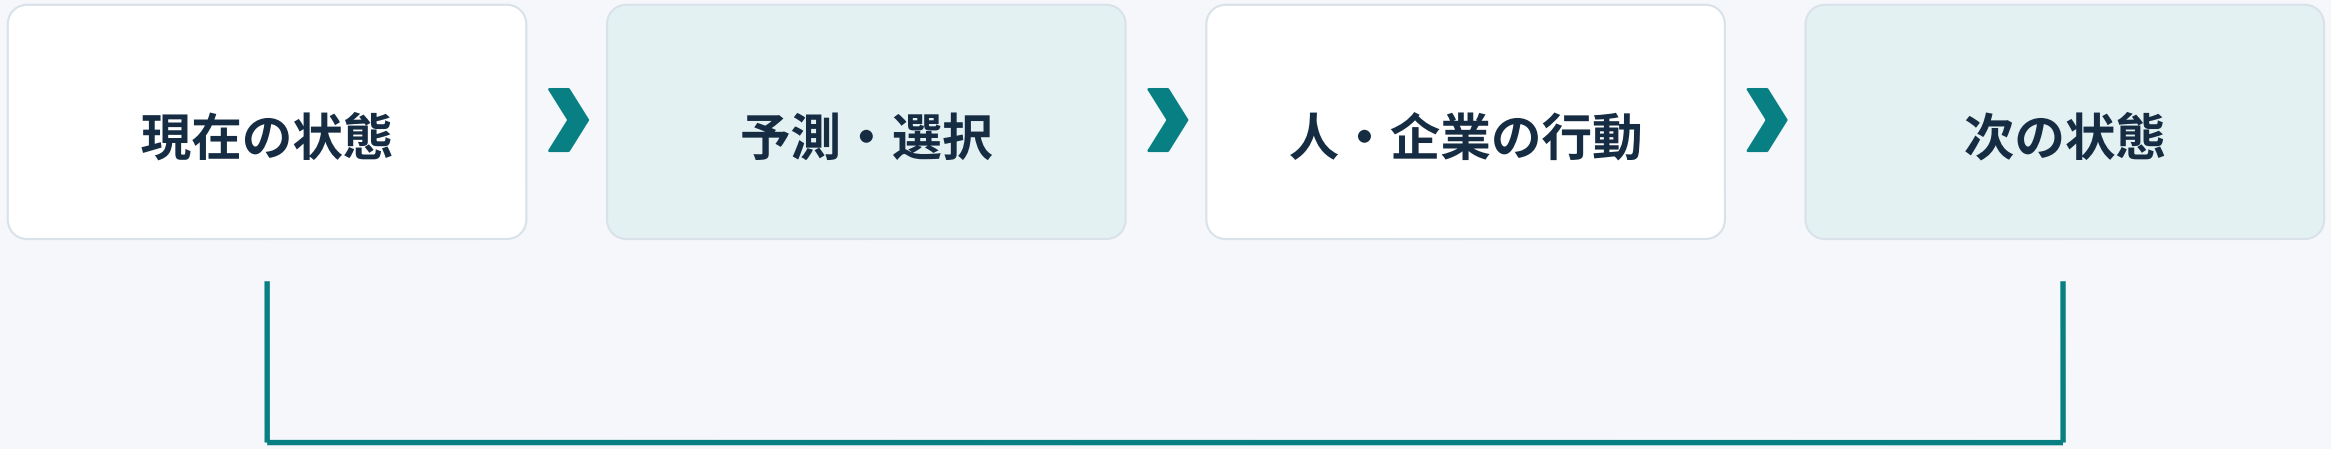
| seed | 一年の終端の模擬残高 | 観測した終了状態 |
|---|---|---|
| **1** | 217,935.98 | horizon_end ／破産なし |
| **2** | 471,150.37 | horizon_end ／破産なし |
| **3** | 533,761.21 | horizon_end ／破産なし |

**初期模擬現金 200,000 。新規の研究対象システム推論・実通貨利益ではない。**

[R22] [E01]

# 予測が使われると、予測対象も変わる

反応の反応まで、動的な模型の研究対象にする




**行動によって、次のデータ分布そのものが変わる**

「人の反応は変わる」を模型に入れる。ただし、完全予知とは主張しない。

[R20]

# 何を未知として残したのか?

同じテスト点でも、一般化の主張は変わる

### 人物

未見の人を予測

### 時間

既知の人の未来を予測

### 研究

新しい実験を予測

### 領域

別の製品や文化へ移植

### 入力時点

未来情報・答えの混入を排除

### 生成器

別の模擬ユーザーでも試す

### 採点器

自己採点の癖から分離

### 欠測・失敗

無効出力と未回答も報告

[R16] [R17] [R05]

# Aaru： 2,993 問で「集団分布」を検証する

対象集団 → 人工人口 → 回答比率 → 人間調査との距離

調整前の平均 TVD

**7.62 pt**

2,993 問を等重みで平均

標本誤差調整後

**5.98 pt**

調整前と定義が異なる

信頼度上位約 51%

**4.54 pt**

1,525 問だけで評価

## 核心：誤差の小ささと「答えられる範囲」を同時に示す

Aaru の公開結果は一問ごとの回答分布が中心。同じ人の複数回答や未見介入の効果まで保証しない。

# Simile： 人の「行動」と「理由」を同時に使う

購買ログだけ、インタビューだけ、では答えられない「なぜ変わったか」

**WHAT ｜実行動**
購入、閲覧、取引など

**WHY ｜自己報告**
インタビュー、調査

**CHANGE ｜実験**
条件変更後の反応

**Human Behavior Foundation Model**

内部評価
**10,000+**
人間の参照があるシナリオ

信頼度評価
**約 8,600 問**
5 分割交差検証の報告

Simile research https://www.simile.com/blog/evals /blog/what-if-machine /blog/confidence?v=2

# Rothko ／ AS： 人間らしさは「平均」だけではない

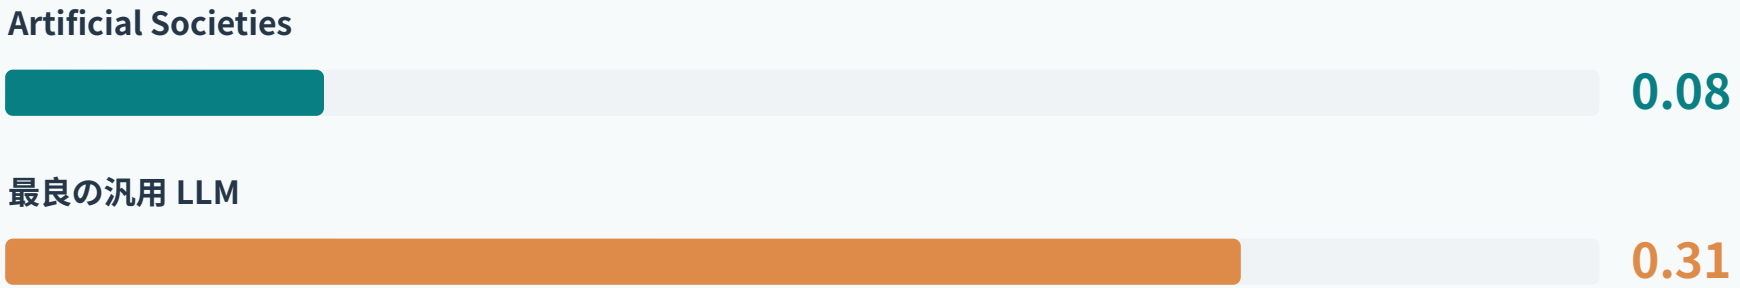
11 の検査で、回答・項目間の関係・条件変化を別々に採点

**① 回答過程**
再回答、順序、言い換え、情報提示

**② 測定構造**
同じ特性を測る質問同士の関係

**③ 外的な一致**
集団・個人差・実験効果

## 企業による 7 ソースの分布 TVD 比較（低いほどよい）




同一の公開共通ベンチマークでの他社全比較ではない

AS Benchmark arxiv.org/abs/2609.30030 / Vendor comparison societies.ai/as-benchmark

# Listen Twins： 本人の言葉を、本人の「未見回答」で測る

Twins の個人内評価と、 StyleFits の実売上を混同しない

| 本人と面接 | 回答の一部を保留 | Twin に予測させる | 本人の答えと比較 |
| --- | --- | --- | --- |
| 1 : 1 | holdout | predict | score |

## 別の実行実験： StyleFits （ Listen Labs の自己報告）

| 2,000 | 100 | $1,293 | $2,000 |
| --- | --- | --- | --- |
| インタビュー | 製品案 | 収入 | 広告費 |

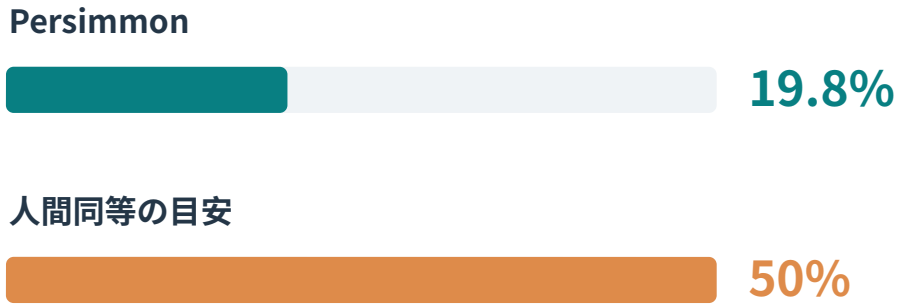
広告費だけを引いて − $707 。本人 Twin の精度試験とは別の証拠。

Listen Twins: https://listenlabs.com/twins / Listen closed-loop: https://listenlabs.com/blog/closed-loop

# Persimmon： 人の会話を模し、長い文脈に耐える

「人間と見分けにくい」は、購買行動の正答率ではない

## 人間らしい会話の識別試験




## どう学習する?

① 既存の大規模モデル
② 実際の人々の会話
③ 自己生成に対する強化学習
④ 80 ターンなど長期整合性の検査

**Turing Test の成功率 ≠ 個人の未来行動の正答率**

Persimmon research: https://persimmon.humansand.ai/blog/persimmon.html

# Ampersand： 模擬ユーザーから協働の「方策」を学ぶ

Persimmon がユーザー役、 Ampersand が発言・質問・待機を選ぶ

**Persimmon**
模擬ユーザーの次の反応

→

**長い会話・社会環境**
相手の目的、反発、変化

→

**Ampersand**
返す・尋ねる・待つ・行動

**長期協働・内部シミュレーションの得点（高いほどよい）**

| Ampersand | vs | 基盤 GLM 5.3 |
|---|---|---|
| 12.94 | | 9.89 |

内部シミュレーション ≠ 実際の人への介入の因果効果

Ampersand model card: https://ampersand.humansand.ai/blog/model-card.html

# 独立研究が突きつける、まだ解けていない問題

「人間らしく見える」模型でも、個人の未知行動を外す

独立したツイン評価
**19 研究**
164 の事前登録結果

個人回答との平均相関
**≈0.20**
独立研究の報告

SimBench
**20 データ**
最良 LLM 40.80/100

## モデルへの入力が多い ≠ 未来の個人行動を正しく再現できる

五つの典型的な歪み：個人差の圧縮／ステレオタイプ／代表性／思想的偏り／過度の合理化

Critical study: pmc.ncbi.nlm.nih.gov/articles/PMC13537255 / SimBench: ICLR 2026

# 最後に「どの能力を測ったのか」を分けて話す

会社別の数値ではなく、同じ証拠の階段で理解する

### L1 分布

選択肢の比率： TVD 、 MAE

### L2 未知の個人

本人の未見回答： Brier 、 Log loss

### L3 介入の差

条件 A と B の差：効果量誤差

### L4 長期の社会

時間と他者の適応：予測ズレ

### L5 現実の価値

実際の意思決定結果：増分便益・費用・害

**同じベンチマークでない数字を一つの順位表へ混ぜない。**

Synthesis: Aaru, Simile, AS Benchmark, Listen Twins, humans&, independent 2026 critique

# 共通ベンチマークは、すでに存在する

ただし 1 枚のランキングで、分布・個人・介入・長期行動を同時に採点できない

### SimBench

**20 datasets**

集団の回答分布

### Artificial Societies

**11 validity tests**

個人差・関係・効果

### Human Behavior Bench

**1,199 tasks**

US 調査・非公開 960 課題

### SSDataBench

**5 statistical patterns**

相関・系列・統計的現実性

### Social Simulation Arena

**Locked before outcome**

未来の観測で採点

### SocSci210 / Socrates

**210 experiments**

未知研究・条件の予測

[B01] [B02] [B03] [B04] [B05] [B06]

# 公平な比較のための「試験の契約」

同じ問題・人間の正解・入力情報・費用・採点・無効回答を揃える

**01**

### 固定した問題

誰のどの回答?

**02**

### 未見の参照

人・研究・時期を保留

**03**

### モデル予測

p(A), p(B), p(C)

**04**

### 共通採点

TVD ・ Brier ・有効率

**05**

### 限界と再現

費用・モデル版・失敗

**例：人間 (50,30,20)% vs AI (40,40,20)% → TVD = 0.10**

[B01] [B03] [B05]

# 行動の「予測」と「変える効果」は違う

交絡があると観察データからの結論は、真の介入効果と逆になる

**通知を受けた人 vs 受けなかった人**

**+26 pt**

見かけ上「効果がありそう」

**同じ対象へ通知する・しないを比較**

**−10 pt**

本当に通知すると悪化（架空例）

**原因：もともとの関心 U が「通知」と「完了」の両方に影響していた**

[C01] [C02] 教材用の完全架空数値

# 研究を読むときの、三つの持ち帰り

ここまでが分野と評価の整理

01

## 問いが違えば、証拠も違う

自然さ、個人の回答、分布、効果、実世界の便益。

02

## 点数より、条件を読む

誰を残し、何を入力し、何と比べ、何を数えたか。

03

## 一般化を実際に試す

同じ模型を、別の人・時期・研究・領域で評価する。

[R02] [R03] [R05]

# Manager：What-if Machine × Executor

行動を『予測する』から、『介入・実行・検証する』へ

### ① Behavior

人と状況の状態
反応を予測

→

### ② What-if

候補施策の因果効果
不確実性を比較

→

### ③ Executor

同意・権限の範囲で
実際に行動

→

### ④ Evidence

結果・害・費用を
独立に測定

**大きな可能性は研究仮説。どの意思決定が本当に改善したか、実験で反証可能にする。**

# 実証するのは、製品・流通・人への便益

最初にManagerを直接売るのではなく、Managerが生んだ成果を示す

### 製品が求められる

実際の課題解決
継続率・返金率
貢献利益

### 必要な人へ届く

増分の顧客獲得
獲得費用・LTV
配信後の純利益

### 苦しみが軽減する

反すう/PTQ
マインドフルネス/FFMQ
生活機能・害・同意

**フォロワー数・視聴回数・売上だけでは不十分。費用を差し引いた利益と本人の実測便益で判断する。**

# 『結果で語る』——まだ未検証のことも示す

分野の評価方法を、実世界の製品・方策の検証へつなげる

### いま確認できていること

人工データでの因果推論・RCT
方策価値のコード検証
研究プロトコルと発表資料

### これから証明すること

実在研究の未見予測
製品・流通の増分成果
本人の心理・生活の改善

**可能な範囲でコード／重みを公開し、第三者に検証してもらう。**
**問い：最初にどの実験で、この仮説を厳しく試すべきか？**

# 正答率 96% でも、三つの模型は同じではない

架空の 1,000 件：購入 40 件／非購入 960 件。分類のしきい値は 0.5 。

| 固定した予測ルール | 正答率 | 二値 Brier ↓ |
|---|---|---|
| **全員へ確率 0 を返す** | 96% | 0.0400 |
| **全員へ確率 0.04 を返す** | 96% | 0.0384 |
| **S へ 0.06 、 D へ 0.01** | 96% | 0.0378 |

**すべて「買わない」と分類する。確率の質を見なければ違いを見落とす。**

[D01] [R14]

# 確率を採点する： Brier と校正

当たった／外れただけでなく、どれくらい確信していたか

**Brier = mean[( 予測確率 − 実際の 0/1)$^2$]**

## 単一例

### 確率 0.8 、実際は 1

$(0.8 - 1)^2 = 0.04$

## 校正

### 0.8 付近の予測を集める

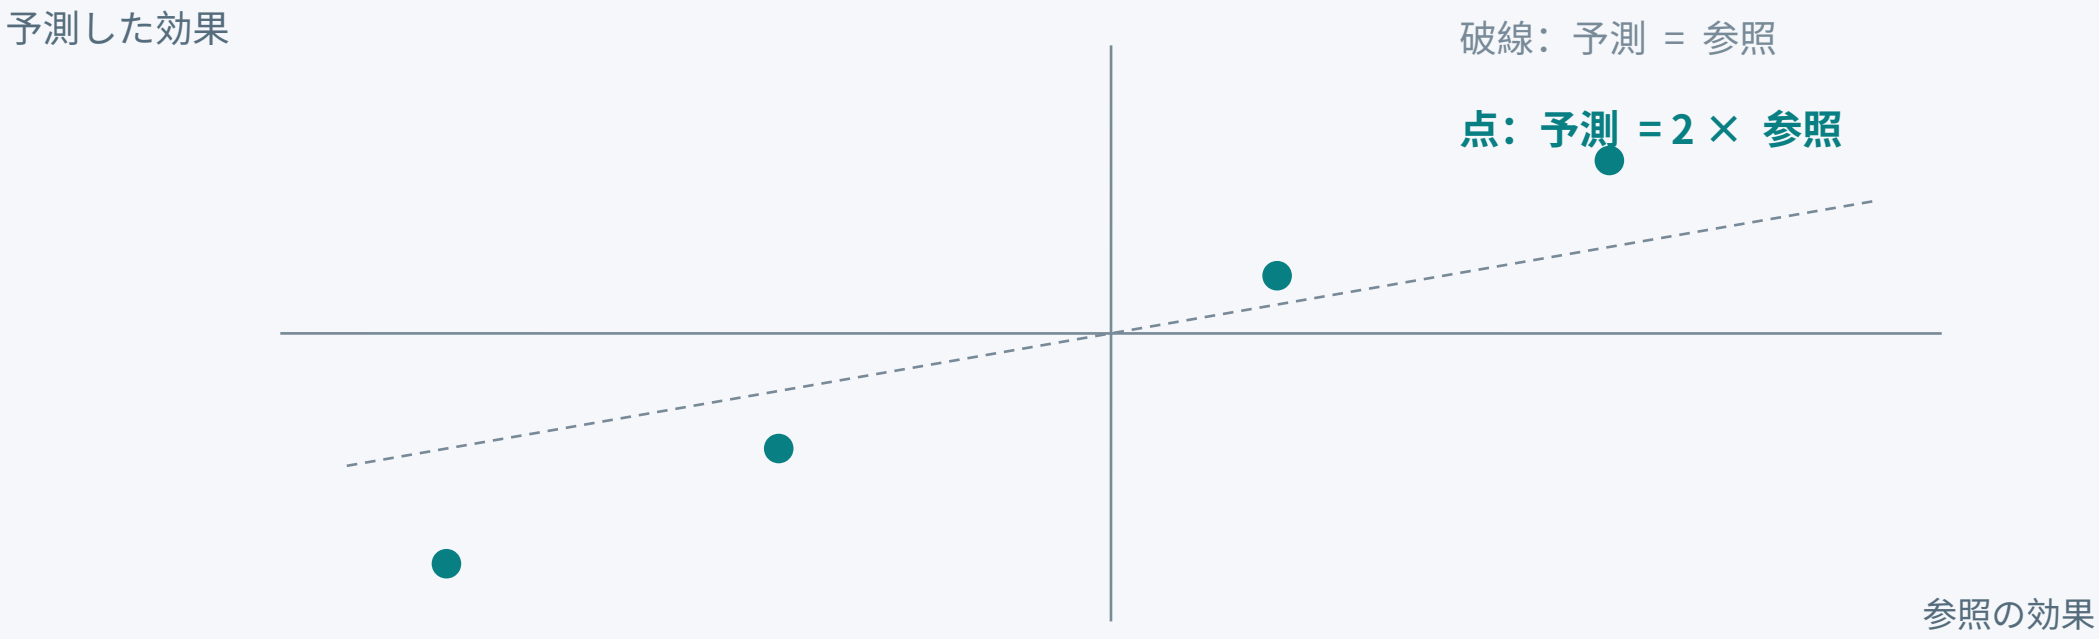
その中の約 80% が実際に 1 なら校正がよい

**Brier は校正だけの点数ではない。解像度も関わる。常に 4% でも全体校正は合い得る。**

[R14] [R15] [D01]

# 相関 1 でも、予測効果が全部 2 倍になる

架空の 4 効果：参照 − 4, −2, 1, 3 → 予測 − 8, −4, 2, 6 （ポイント）




**Pearson r = 1.00 ／ 効果 MAE = 2.5 ポイント。順位と大きさを分けて評価する。**

[D01] [R04]

# 補足 A ｜ Brier の計算を、 1 件から読む

二値の 0 〜 1 スケール。小さいほどよい。

$$BS = (1/N)\ \Sigma_i\ (p_i - y_i)^2$$

### 購入を 0 と予測して外す

**p=0, y=1 → 1**

40 件が 1 、 960 件が 0 → 平均 0.04

### 全員へ 0.04 と予測

**p=0.04**

$40 \times 0.96^2 + 960 \times 0.04^2$ を 1,000 で割る → 0.0384

[D01] [R14]

# 補足 B ｜論文を読む 8 つの問い

説明できなければ、結果の数字を暗記しない

### 目的

何を予測・変更したい?

### 入力

いつ何を知っていた?

### 参照

人の回答か、実行動か?

### 分割

何を未見として残した?

### 比較

最も強い単純な基準は?

### 指標

単位・分母・集約は?

### 不確実性

繰返し・失敗・個人差は?

### 外挿

どこまで主張できる?

[R02] [R03] [R05]

# 補足 C ｜今回の出典・版の監査

旧い数字や企業の主張を、独立した実証として混ぜない

| 対象 | 確認したこと | この発表の扱い |
| --- | --- | --- |
| **Park 1,000 人研究** | v1 から v3 で題名・結果が更新 | v3 2026-06-28 を使用。正規化値と明記 |
| **Socrates** | HTML 要旨 36/15 と PDF26/13 に差 | PDF Table 2 の 0.205→0.151 を採用 |
| **AS Benchmark** | 11 検査の論文と 8 項目のブログは別 | 11 検査はプレプリント。企業評価と分離 |
| **Nature 実験効果研究** | 出版社の要旨・公開説明を確認 | 購読本文全読・独立追試とは言わない |
| **今回の証拠** | 既存フル実行の読取＋新規教材 | 模型の新規推論は 0 回 |

[R02] [R03] [R04] [R05] [E01] [D02]

# 補足｜ naïve の 9 試験：課題の単位

原ベンチマークと、公開比較の slice を混同しない

| 試験 | 期間・単位 | 主な結果 |
| --- | --- | --- |
| **Clipping** | 約 30 日 | 精算済み模擬残高 |
| **Short Form** | 7 日／一部 30 日 | 模擬事業価値 |
| **Terminal** | 長時間・課題 | 自動テストの合否 |
| **SWE** | 15 課題 slice | コード修正の合否 |
| **Business** | 25 課題 slice | 成果物の必須検査 |

**費用を含めた比較も、同じ定義と範囲を揃えて読む。**

[N00] [N01] [N02] [N03] [N04] [N05]

# 補足｜ naïve の 9 試験：比較の注意

小標本・調整データ・掲載選別・乱数条件

| 試験 | 公開比較 | 注意 |
| --- | --- | --- |
| **TheAgentCompany** | 10 課題 | 同じ課題で調整 |
| **PRDBench** | 5 課題 | 成功しきい値 0.25 ・掲載選別 |
| **YC-Bench** | 3seed ・一年 | 完了と利益は別 |
| **CoffeeBench** | 5 回・ 14 日 | seed 不一致・元は 90 日 |

**企業の説明にある留保も、成果と一緒に紹介する。**

[N06] [N07] [N08] [N09]

# 補足｜P02-2： 十行は、十人ではない

架空の四人のログで、観測単位とラベルを区別する

| 数えたもの | 値 | 何を意味するか |
| --- | --- | --- |
| **ログ配信行** | 10 行 | 観測の伝送記録 |
| **購入した人** | 2 / 4 = 50% | 期間内の購入ラベル |
| **返金差引支払あり** | 1 / 4 = 25% | 期間末の支払い状態 |
| **入金純額** | 1,000 円 | 利益や満足ではない |

**実人間・実売上ではなく、今回動かした測定教材。**

[D02] [R21]

# 主要参考文献 1/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載


**[R01] Park et al. (2023), Generative Agents: Interactive Simulacra of Human Behavior**
学術論文・ UIST 2023

**[R02] Park et al. (2026 revision), LLM Agents Grounded in Self-Reports Enable General-Purpose Simulation of Individuals, arXiv v3**
プレプリント v3 / 2026-06-28

**[R03] Kolluri et al. (2025), Finetuning LLMs for Human Behavior Prediction in Social Science Experiments**
EMNLP 2025 論文 PDF

**[R04] Ashokkumar et al. (2026), Large language models can predict the results of social science experiments**
Nature / 2026-07-08

**[R05] Chidichimo et al. (2026), Artificial Societies Benchmark: A Validation Framework for Synthetic Research**
プレプリント / 2026-09

**[R06] Artificial Societies Benchmark — public code**
公開リポジトリ

**[R07] Aaru: Population simulation at the replication floor**
企業自己報告 / 2026-09-24

**[R08] Simile: Simulating human behavior**
企業公式説明

**[R09] Artificial Societies: Introducing Rothko**
企業公式説明 / 2026-10-22

**[R10] Listen Labs: Our intern built the first zero-person company**
企業実験報告

**[R11] Listen Twins**
企業製品説明

**[R12] humans&: Ampersand v0.1 Model Card**
企業モデルカード / 2026-10-20


URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

# 主要参考文献 2/2

リンク・確認範囲・証拠の分類は各ページのノートにも記載


**[R13] humans&: Persimmon v0.1 Model Card**

企業モデルカード / 2026-09-10

**[R19] humans&: Build with Ampersand**

公式 API 文書

**[R20] Perdomo et al. (2020), Performative Prediction**

ICML 2020 研究

**[R21] Mokkink et al. (2010), COSMIN taxonomy**

測定理論・合意研究

**[R22] YC-Bench public CLI**

公開リポジトリ

**[N00] naïve: Benchmarks**

企業公式比較

**[N01] naïve: Clipping Bench**

企業自己報告・模擬事業

**[N02] naïve: Short Form Bench**

企業自己報告・模擬事業

**[N03] naïve: Long Horizon Terminal Bench**

企業自己報告・実行基盤比較

**[N04] naïve: SWE-Bench Pro**

企業自己報告・実行基盤比較

**[N05] naïve: Business Bench**

企業自己報告・実行基盤比較

**[N06] naïve: TheAgentCompany**

企業自己報告・実行基盤比較

**[N07] naïve: PRDBench**

企業自己報告・実行基盤比較

**[N08] naïve: YC-Bench**

企業自己報告・実行基盤比較

**[N09] naïve: CoffeeBench**

企業自己報告・実行基盤比較

**[E01] 2026-11-03 reproduction readback audit**

既存実行ログの今回の読取・照合

**[D02] P02-2 measurement exercise**

今回新規実行した架空教材


URL ・確認範囲・証拠区分はノートと同梱 SOURCES.md を参照。

[R13] [R19] [R20] [R21] [R22] [N00] [N01] [N02] [N03] [N04] [N05] [N06] [N07] [N08] [N09] [E01] [D02]

# humans& を実際に動かす： 2 つの公開 API と別の Persimmon

製品を知ること・ API が動くこと・モデルの妥当性を証明することは別

## Ampersand v0.1

架空チームの予定調整
同一セッションで 2 回の発言

**622 字 + 750 字の実 API 出力**

2 ターン・ 4 アイテムの保存を確認

## Ampersand Tutor v0.1

架空の学習者に
「 40 人と 120 回答の違い」を説明

**2,526 字の実 API 出力**

教師としての正確性は未採点

**※ Persimmon （模擬ユーザーモデル）は別製品・別アクセス。今回の API 実行とは混同しない。**

出典： humans& API / PR #9157 / GitHub Actions 41630422469

# 公開データを使った人間予測： 48 件の小さな反例

公式の人物プロンプトとパーサを使用。実人間の条件差を、ローカル LLM は再現できなかった

## 質問の言い方による平均回答の変化




実際の差： +0.146 ／ ローカル Qwen 予測： 0.000 。※ 48 件の探索的試行であり Rothko の比較ではない。

出典： AS Benchmark 公式コード / Jordan ら Harvard Dataverse / 2026-11-03 再現記録

# 補足｜Aaru の誤差と「信頼度」のトレードオフ

3 種類の TVD を混ぜない：対象と定義が異なる

全質問
**7.62 pt**
調整前 TVD 2,993 問

標本誤差近似を差引
**5.98 pt**
調整済み TVD 2,993 問

上位 51% だけ
**4.54 pt**
調整前 TVD 1,525 問

**同じ「 TVD 」という文字でも、測っている対象が違えば比較できない。**

確認：分析単位・分母・集約法・標本調整・ coverage ・未見条件

# 補足｜ Persimmon ・ Ampersand の学習と評価は別

一つの会社でもモデルの役割が違えば、正解の定義も変わる

**人を演じる： Persimmon**

本人らしい反応、情報開示、長い会話

**支援する： Ampersand**

質問、提案、待機、許可された実行

## 判断材料：モデル名ではなく「誰を演じ、何を採点したか」

実 API で答えが返った ≠ 人間の行動予測が正確 ≠ 実世界で良い介入ができる

Official: persimmon.humansand.ai/blog/persimmon.html / ampersand.humansand.ai/blog/model-card.html

# 補足｜明日、論文を読む人に聞きたいこと

「どれが一位か」ではなく、一般化と再現可能性を議論する

### ① データ
誰を調べ、何を観測した?

### ② 未知性
人・時期・研究をどう隠した?

### ③ 指標
分布・因果効果・利益のどれ?

### ④ 比較
同じ入力・計算費・権限か?

### ⑤ 不確実性
失敗や棄権を報告した?

### ⑥ 再現
独立した研究者が検査できる?

Sources in speaker notes / P03-7 article references, surveyed 2026-11-04

# 補足｜各ベンチマークで「まだ測れていないもの」

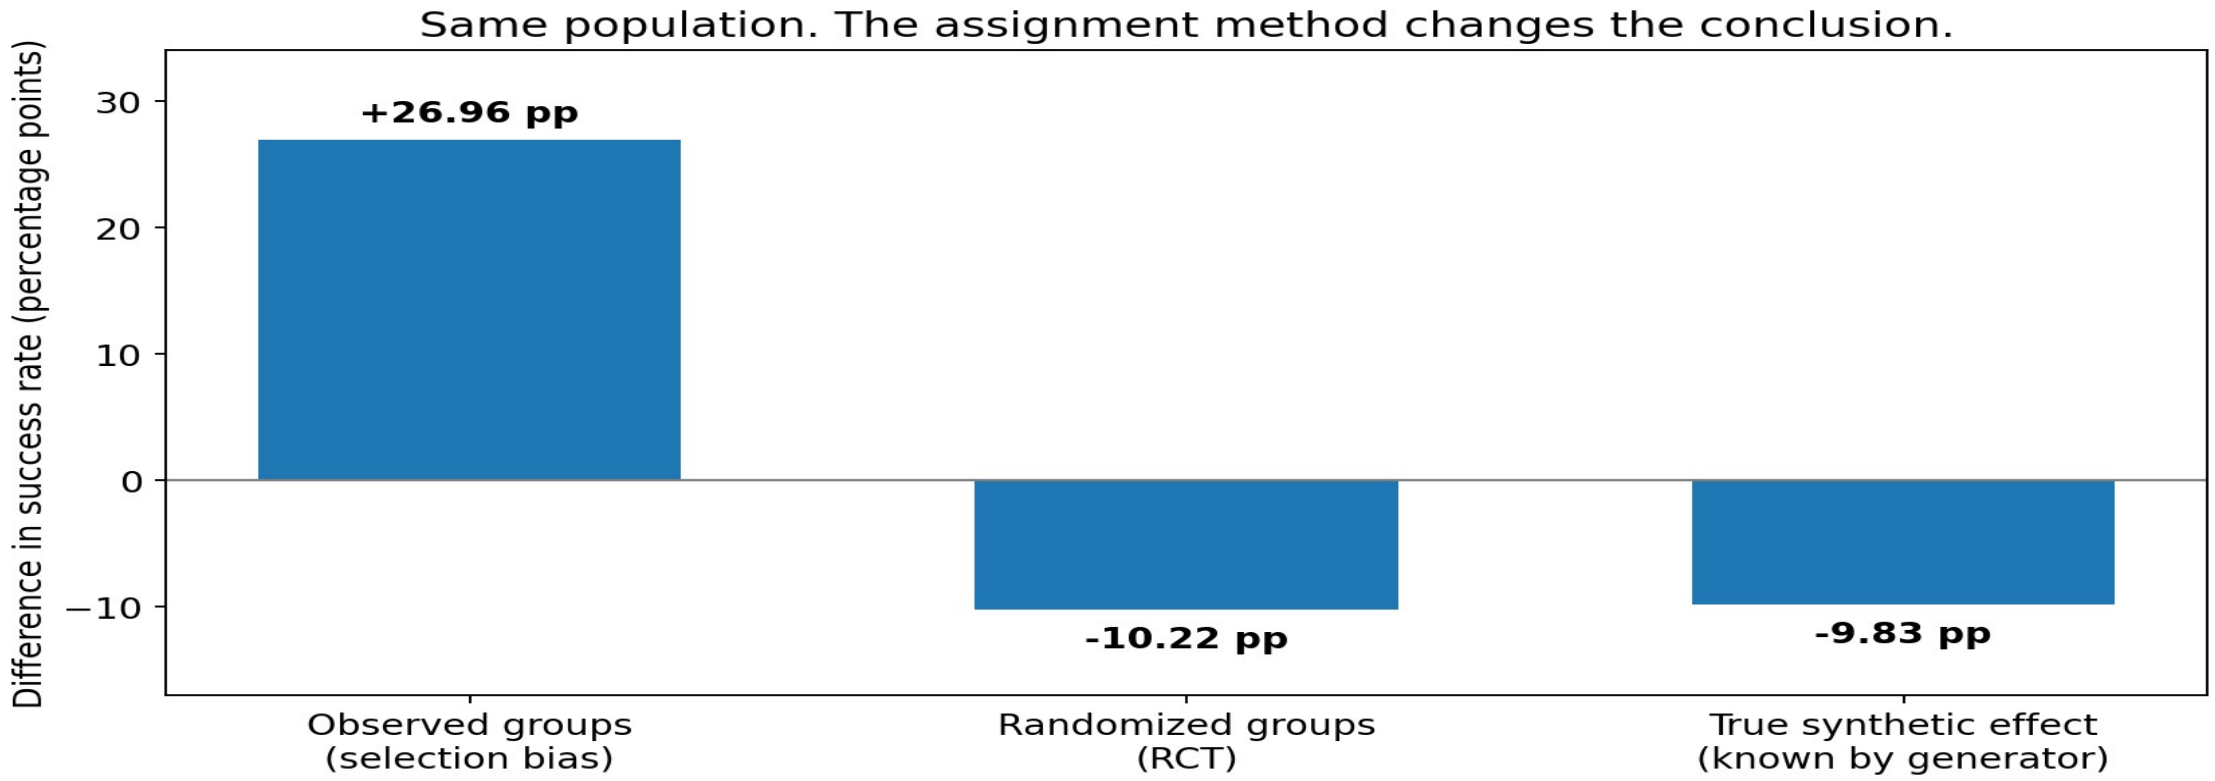
共通試験を組み合わせても、実世界の意思決定価値は独立に検証する

| | | |
|---|---|---|
| **集団回答** | SimBench / Human Behavior Bench | 個人の実行動・因果効果 |
| **複数質問の関係** | Artificial Societies / SSDataBench | 実際の施策を選ぶ価値 |
| **未知研究の回答** | SocSci210 / Socrates | 無期限の汎化 |
| **未来の社会集計** | Social Simulation Arena | 個人の介入効果 |
| **現実の意思決定** | 独立 A/B ・対照実験が必要 | 別製品への自動一般化 |

SimBench / AS Benchmark / Rehearsals / Social Simulation Arena / Nature 2026

# 観察した差と「実際に行動を変えた効果」は違う

同じ架空世界でも、誰が通知を受けるかの決め方によって結論が逆になる




出典： Hernán & Robins 『Causal Inference: What If』／Anicca 2026-11-04 架空計算

# RCT の設計：何を無作為化し、何を比較するのか

ATE は介入そのものの平均効果。 ITT は「介入群へ割り当てる方針」の平均効果

## ① 介入前

対象者・時間窓を先に定義
同じ人は同じ割当
事前指標と許可を固定

何を変えたかを明確に

## ② 無作為に割り当て

Z = 1： 介入群
Z = 0： 比較群
割当を後から変更しない

何を知らずに決めたかが重要

## ③ 結果を計算

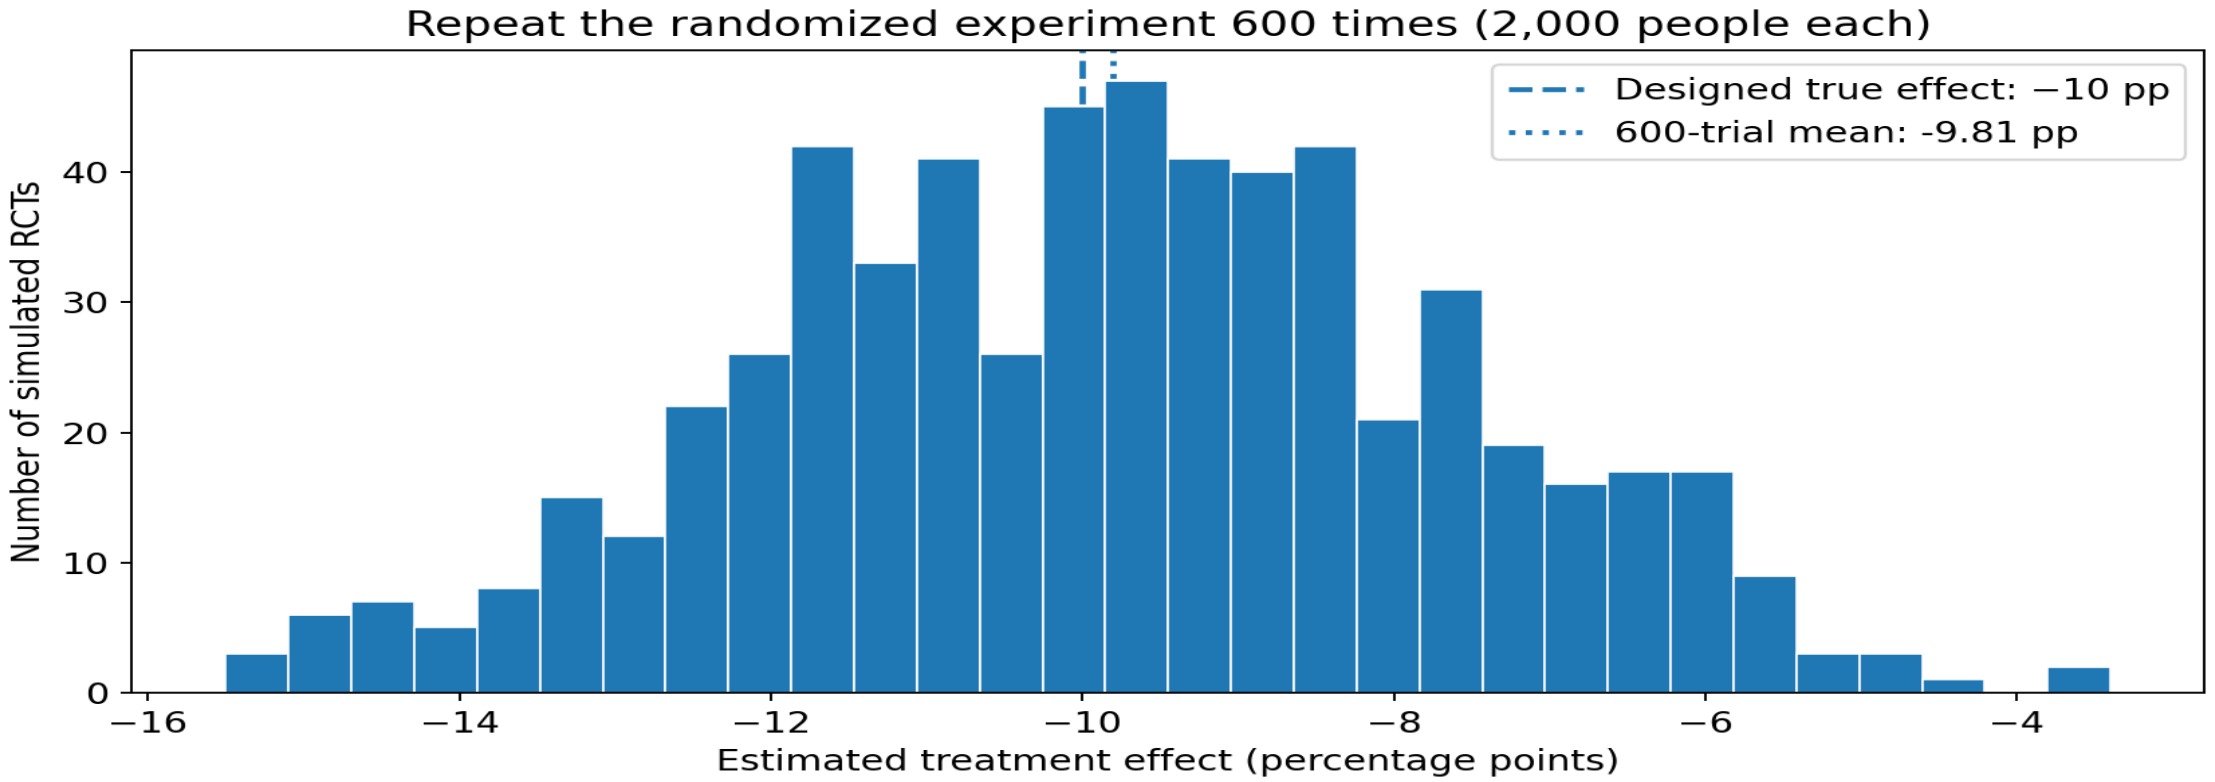
ATE = E[Y(1)−Y(0)]
ITT = E[Y|Z=1]−E[Y|Z=0]
SE ・ 95%CI ・害も報告

実際に受信したかだけで再分類しない

出典： Hernán & Robins ／ J-PAL Randomization ／ Anicca P04-2

# 同じ RCT を 600 回繰り返すと、効果推定はどう揺れる?

2000 人 ×600 回の架空 RCT： 真の設計効果− 10pt 、平均推定値− 9.81pt




出典： Hernán & Robins ／ J-PAL ／ Anicca P04-2 架空シミュレーション

# 交絡・媒介・ Collider： なぜ「全部調整」が危険か

因果構造を描いてから、調整してよい介入前変数を選ぶ

### 交絡（調整の候補）

A ← U → Y
介入前の共通原因 U

### 媒介（総効果では要注意）

A → M → Y
経路の一部を消す

### Collider （条件付けに注意）

A → S ← U → Y
S=1 選択がバイアスに

**潜在的結果**　**$Y_i(1)$ = 通知したとき**　**$Y_i(0)$ = 通知しなかったとき**

ATE = E[Y(1) − Y(0)] 。同じ人の二つの結果を実データでは同時に観測できない。

# RCT なしで効果を識別するための 4 条件

まず target trial を定義し、推定対象・処置・ time zero ・結果を先に固定

### ① 交換可能性

$(Y(1),Y(0)) \perp A \mid X$
未測定交絡がない仮定

### ② Positivity

$0 < e(X) < 1$
どちらの処置にも機会がある

### ③ Consistency

$Y = Y(A)$
処置内容・時間・結果を固定

### ④ 干渉への配慮

他者への通知が本人の結果を変えないか
口コミや集団効果に注意

**仮定をデータ精度で証明することはできない。欠ければ「識別不能」と返す。**

# 「同じ人の特徴」で比べ、元の人口構成に戻す

介入前 X で層別 → 層内比較 → 対象集団の P(X) で平均する

$$ATE = \Sigma_x P(X=x) \times [\, E(Y|A=1,X=x) - E(Y|A=0,X=x) \,]$$

**高い意欲（ 50% ）**

通知あり 70% − なし 80%
→ −10 ポイント

**低い意欲（ 50% ）**

通知あり 10% − なし 20%
→ −10 ポイント

**観察差** **+26.12 pt**

**標準化 ATE** **−9.98 pt**

全て人工データ。欠けた交絡因子を自動で補うことはできない。

# IPW と AIPW： どちらのモデルが何を補正するか

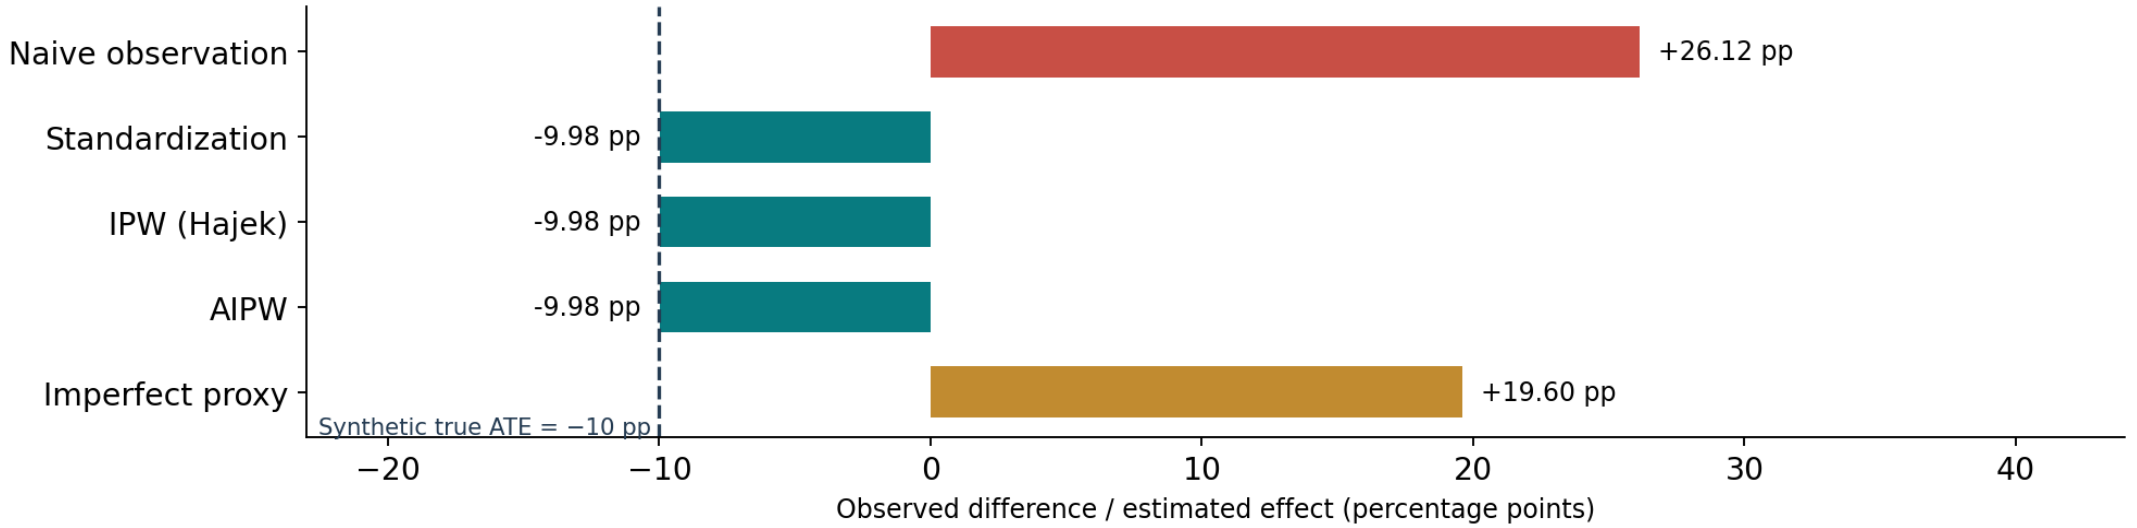
e(X)= 通知される確率 ／ $m_a(X)$= その行動をした場合の結果予測

## IPW （重み付け）

起きにくい処置の観測を重くする
確率 e が 0/1 付近なら不安定

## AIPW （二重ロバスト）

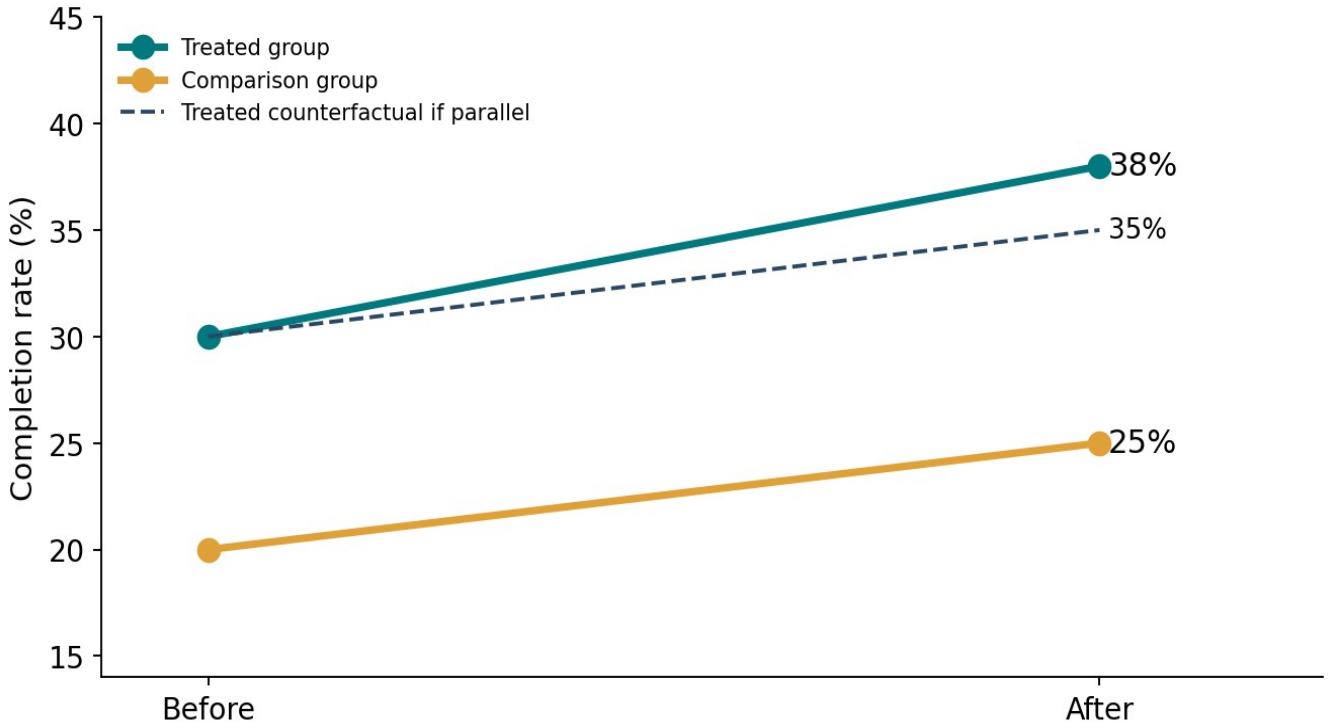
結果モデル $m_a$ と選択モデル e を併用
未測定交絡は解決しない




P04-3 synthetic 30,000 / AIPW not cross-fitted

# DiD： 施策前後の変化を比較する

介入後の単純差ではなく、非介入群の自然な変化を差し引く




介入群： 38 − 30 = +8pt

比較群： 25 − 20 = +5pt

**DiD = +3pt**

平行トレンド・同時ショック・導入時点の違いに注意

Synthetic 2x2 example only / Goodman-Bacon 2021; Callaway & Sant'Anna 2021

# Manager の what-if に必要なのは「識別のゲート」

行動予測が高精度でも、それだけでは介入効果の根拠にならない

**① Target trial**
対象・時点・権限

→

**② DAG / overlap**
交絡・干渉・欠測

→

**③ 反実仮想推定**
g-formula / IPW / AIPW

→

**④ 独立検証**
RCT と害・費用

## 識別できないときは、 unknown / abstain を返す

P04-3： 人工 3 万人・ 26 テスト ｜ 実人間の因果効果：未検証 ｜ 次： P04-4 （誰に何が効くか）

# ATEがプラスでも、全員に介入すべきとは限らない

24,000人の完全架空RCT：介入前の意欲と疲労で効果が変わる

### 集団平均 ATE

真のATE +2.92pt / 推定 +2.68pt

### 条件付き平均 CATE

特徴 X で条件づけた E[Y(1)−Y(0)|X]

### 低意欲の人

疲労低 +16pt
疲労高 +10pt

### 高意欲の人

疲労低 −4pt
疲労高 −10pt

**本質：平均値が良くても、特定の状態では害になることがある**

# 4つの状態を、別々に推定する

群間差の推定は元の潜在結果生成式とおおむね一致する

| 状態 | 理論CATE | 推定CATE |
| --- | --- | --- |
| 低意欲・疲労低 | +16.0 pt | +17.67 pt |
| 低意欲・疲労高 | +10.0 pt | +9.82 pt |
| 高意欲・疲労低 | -4.0 pt | -4.54 pt |
| 高意欲・疲労高 | -10.0 pt | -11.36 pt |

無作為化・事前に定めた4群で推定。これは個々人の確定的な効果ではない。

# CATEを使い、介入すべき相手を選ぶ

未使用の架空9,619人に対して、方策をIPWで独立に評価

### 学習したルール

低意欲 → 通知する
高意欲 → 通知しない

### 比較対象

誰にも通知しない
全員に通知する

## 未通知方策に対する増分 +6.28 pt

近似95% CI：+4.84〜+7.72 pt ｜ 人工世界の理論増分：+6.42 pt

**学習と評価を分離しても、現実の人への効果や安全性は証明されない。**

# 「誰に効くか」と「なぜ効くか」は別の問い

媒介分析：A→M→Y と、A→Y の経路を分けて考える

**介入 A**

通知など
（この例は無作為化）

→

**媒介 M**

気づき・認知反応
（処置後の変数）

→

**結果 Y**

タスク完了
（この例は連続量）

**直接 0.12 ＋ 間接 0.12 ＝ 総効果 0.24**

**注意：処置のRCTだけでは媒介から結果への因果効果は識別できない。**

# 未知の『研究』を予測するベンチマーク

同一研究をまたいだリークを避けるため、study IDで分割する

**学習**

90研究：過去の介入効果から学習

**検証**

30研究：Ridgeの正則化を選択

**未見研究（既知領域）**

30研究：IDは未見、領域は学習済

**未見研究（新領域）**

30研究：生成規則に新たなシフト

**個人レベルのtrain/test分割だけでは、研究単位の汎化を測れない。**

P04-5 synthetic studies=180 / no actual published RCT evaluated

# 予測を先に固定し、それから正解を開く

重要なのは、精度を出す前に採点方法と利用可能情報を確定すること

### ① 事前情報

研究対象・介入・baseline

### ② 予測

ゼロ・平均・Ridge

### ③ 予測凍結

CSV + SHA256

### ④ 採点

保存後にgoldを開封

**人工goldは別ファイル保存。本番ではモデル側から物理的にアクセス不能にする。**

# 未知領域では、予測誤差が悪化する

MAE（ポイント、低いほど良い）｜架空の未見研究30件＋30件

| 予測方法 | 既知領域 | 新領域 |
|---|---|---|
| 常に効果0 | 2.99 pt | 5.77 pt |
| 学習平均 | 2.27 pt | 4.18 pt |
| **Ridge回帰** | **1.55 pt** | **3.99 pt** |

**新領域の予測誤差は既知領域の約2.6倍：OOD評価を分ける必要がある。**

# Managerが『現実の実験効果』を予測した証拠はまだない

人工ベンチマークの成功と、未見の公開RCTでの検証を区別する

### 今回できたこと

180架空研究の再現可能なsplit・凍結・評価
全80件の単体テスト成功

### 研究上まだ必要なこと

実公開RCTの選定・権利検査
予測の事前登録と独立採点

**P04-4：講義＋人工実験完了**
**P04-5：講義＋人工ベンチマーク完了／公開実験検証は未完了**

**次の講義：P04-6 事前登録・意思決定価値。P04-5の公開実験評価も継続。**

J-PAL / Many Labs 2 candidate corpora; no empirical validation claimed

# 分析する前に、予測・仮説・評価方法を固定する

Pre-analysis Plan：研究目的・対象・主要成果・比較方策・人数・分析規則

### ① 対象と比較

誰・いつ・何をするか／
介入の候補と権限

### ② 主要評価と停止規則

何を主要成果とするか／
固定標本数・多重性

**人工結果を生成する前に計画JSONを保存し、SHA-256を固定**

**ローカルのハッシュ保存は、外部機関に登録されたRCTの代わりではない。**

# 『施策』ではなく『施策を選ぶ方法』をRCTで比較

完全架空40,000人：双方に同じ事前特徴・候補行動を与える

### Manager型の方策

低意欲の人に通知

### 比較ヒューリスティック

低意欲・低疲労の人に通知

**推定増分 +1.61 pt ／ 95%CI +0.69〜+2.54 pt**

成果 – 通知負担0.02／回 の合成効用を評価

**比較相手は合理的な固定ルールだが、あらゆる方策の最強baselineではない。**

# 結果を見ながら途中停止すると、偽陽性率が膨らむ

人工A/A試験750回：真の効果はゼロ、未補正の名目5%検定

### 最終1回の検定

偽陽性 4.27%

### 途中6回で有意なら成功

偽陽性 15.20%

**途中解析は、群逐次法などで誤判定率を事前に制御できる**

# すでにあるOntologyを組み合わせればいい

『行動を表現する』ことと、『現実を推定・検証する』ことは別

### 行動科学

COM-B・BCTTv1（93技法）
BCIO：介入／対象／文脈

### 意味・証拠

JSON-LD・PROV-O
SHACL：関係の検証

### 実行・通信

既存Manager Core
MCP・A2A：外部接続

**BCIOで禁煙介入971アームを記述する先行研究あり。**
**Managerは新しいOntologyより、予測と実行・独立評価の接続を研究する。**

# Graphは証拠の投影。真実や実行権限そのものではない

予測・提案・送信レシート・観測結果・因果効果を混同しない

| 観測 | 推測 | 候補 | receipt | readback |
| --- | --- | --- | --- | --- |
| 時刻と出典 | 確信度とモデル版 | NO_ACTIONも残す | 送信≠効果 | 独立観測 |

**実行許可はGraphから発生しない。**
**元のledgerと独立した権限・結果確認が正本。後知恵の情報リークを防ぐ。**

# 共通のIDをつなぐ。でも新しい権限は作らない

既存Job → Effect → Receipt → RuntimeEventを同じスコープと時点で追跡

### Job

job_id
effect_key

### Effect

effect_id
idempotency_key

### Receipt

receipt_id
effect_id

### Runtime

event_id
run_id

**予測ID・判断IDは既存共通レコードの必須項目ではない。**
**欠落を勝手に埋めず、Receipt≠人間の改善として扱う。**

# Listen Labs APIへ認証付きGET：HTTP 200

TinyFishで実ブラウザーを操作し、Mac miniでStudy APIへ読み取り接続

## 実APIで確かめたこと

GET /wallets → HTTP 200
GET /studies → HTTP 200
作成・公開・課金・回答保存：0

## 人工契約実験で確かめたこと

run／effect／receiptを厳密に照合
別テナント・時間リークを拒否
P05-2新規48件／累計193件PASS

**Listen Twinsの予測APIは未確認。**
**本番発表33枚は変えず、研究付録として保存する。**